

Politechnika Wrocławska

Hurtownie i eksploracja danych

Robert Burduk
robert.burduk@pwr.edu.pl
C4 p. 232

Cele przedmiotu

- C1 Nabycie wiedzy dotyczącej tworzenia analitycznych baz danych.
- C2 Nabycie wiedzy dotyczącej metod eksploracji danych oraz ich wykorzystania.
- C3 Zdobycie umiejętności związanych z projektowaniem i tworzeniem analitycznych baz danych.
- C4 Zdobycie umiejętności związanych z wykorzystaniem wybranych algorytmów eksploracji danych.

Cele z zakresu wiedzy

- PEK_W01 – zna etapy procesu odkrywania wiedzy w bazach danych
- PEK_W02 – zna modele i warstwy logiczne hurtowni danych
- PEK_W03 – zna etapy procesu ekstrakcji, transformacji i ładowania danych
- PEK_W04 – zna wybrane algorytmy eksploracji danych

Projekt — etapy realizacji (HD)

- Sformułować pytania analityczne — odpowiedź na pytania wymaga uwzględnienia danych z różnych „baz danych” (wielu źródeł danych)
  - Analiza zgłoszeń serwisowych
  - Analiza sprzedaży produktów/usług
- Zdefiniować pojęcia modelu przetwarzania wielowymiarowego — fakt, miara, wymiar, atrybut, hierarchia
- Przestawić model logiczny hurtowni danych — model relacyjny hurtowni danych
- Dla danych syntetycznych przestawić wizualizację wyników — np. tabele przestawne .xls

Projekt — etapy realizacji (ED)

- Wybrać dane do analizy — np. UCI MLR
- Zdefiniować cel — klasyfikacja nadzorowana, nienadzorowana, krzywe przeżycia, analiza koszykowa
- Wybrać algorytm ED
- Zdefiniować przestrzeń przeszukiwania parametrów, hiperparametrów (zależy od wybranego algorytmu)
- Wykonać eksperymenty — np. Phyton, Weka
- Sformułować wnioski z przeprowadzonych eksperymentów, analiza statystyczna wyników (opcjonalnie)

Warunki zaliczenia

OCENA OSIĄGNIĘCIA PRZEDMIOTOWYCH EFEKTÓW UCZENIA SIĘ

Oceny (F – formująca (w trakcie semestru), P – podsumowująca (na koniec semestru)	Numer efektu uczenia się	Sposób oceny osiągnięcia efektu uczenia się
F1	PEU_W01 - PEU_W04	Odpowiedzi ustne, sprawdzian pisemny w formie testu
F2	PEU_U01 - PEU_U04	Ocena przygotowania projektu, obrona projektu, udział w dyskusjach problemowych.
P = 1/2*F1 +1/2*F2 Warunkiem uzyskania pozytywnej oceny podsumowującej jest uzyskanie pozytywnych ocen F1 oraz F2		

Test wielokrotnego wyboru + zadania otwarte, do zdobycia 50 punktów

Ocena z projektu ustalana jest indywidualnie podczas oddania projektu – obrony projektu. W grupie studenckiej realizującej dany projekt oceny mogą się między sobą różnić. Obowiązkowa obecność podczas omawiania „kamieni milowych” projektu.

Wprowadzenie do HD

System transakcyjny -(*On-Line Transactional Processing*, przetwarzanie transakcyjne)

- wspomaga codzienną pracę przedsiębiorstwa. System tego typu ma za zadanie wspomagać funkcjonowanie przedsiębiorstwa przez dokładne i efektywne realizowanie transakcji. Operacje wykonywane na tej bazie to odczyt, zapis, modyfikacja, usuwanie.

Wprowadzenie do HD

Bazy danych wykorzystują model przetwarzania OLTP.

- wykonywanie dużej liczby prostych zapytań pochodzących od wielu użytkowników (nierzadko są to setki zapytań na sekundę)
- system bazodanowy powinien być zoptymalizowany pod kątem szybkiego wyszukiwania danych
- częste operacje dodawania, usuwania i modyfikacji pojedynczych rekordów
- wymagany natychmiastowy dostęp do aktualnych informacji

Wprowadzenie do HD

Bazy danych wykorzystują model przetwarzania OLTP.

- duża wydajność wprowadzania i modyfikacji danych
- sprawna obsługa wielkiej liczby niewielkich transakcji
- efektywna obsługa wielu użytkowników

Wprowadzenie do HD

- Rozproszone
  - Wiele systemów informatycznych
  - Dane niejednorodne
  - Systemy niezintegrowane
- Heterogeniczne
  - Pochodzenie od wielu producentów
  - Różne bazy danych i systemy zapisu
  - Różne formaty i modele danych
  - Zróżnicowane systemy identyfikatorów
- W niewłaściwym układzie
  - Układ dostosowany do wprowadzania i modyfikacji danych
- Bez historii
  - Dane odzwierciedlają stan aktualny
  - Dane historyczne dla krótkiego okresu

Wprowadzenie do HD

System analityczny - jest aplikacją służącą do przetwarzania danych w celu wspomagania decyzji strategicznych i decyzji związanych z zarządzaniem.

- Decyzje strategiczne (po analizie kilkuletnich sprzedaży określonych usług)
- Decyzje operacyjne (np. planowanie produkcji na kilka dni)

Definicja

Hurtownia danych była definiowana na wiele sposobów. Jeden z najbardziej powszechnych pochodzi od Inmon'a (1992):

Hurtownia danych jest

- **zorientowaną tematycznie,**
- **zintegrowaną**
- **chronologiczną w czasie**
- **trwałą**

kolekcją danych dla wspomagania procesów podejmowania decyzji zarządczych.

Definicja

- **Zorientowane tematycznie** – hurtownia danych jest zorganizowana raczej wokół tematów dla jakich będą wykonywane analizy i zestawienia, niż wokół dziedzin zastosowań (fakturowanie, zarządzanie magazynem, rejestracja itp.). Przechowywane dane mają wspomagać procesy decyzyjne niż być zorientowane na aplikacje.

- **Zintegrowane** – gromadzą dane z różnych źródeł, w szczególności z systemów transakcyjnych (aplikacyjnych) pracujących w całym przedsiębiorstwie.

Definicja

- **Chronologiczne w czasie** – dane w hurtowni są dokładne i poprawne tylko w odniesieniu do pewnego punktu czasu lub przedziału czasowego. Najczęściej chronologię stanowi czas, dzięki któremu obrazowane są stany przedsiębiorstwa.

- **Trwałe** – dane nie są aktualizowane w czasie rzeczywistym, ale wprowadzane z systemów transakcyjnych w regularnych odstępach czasu. Nowe dane dokładane są jako rozszerzenie istniejących danych. Czas przechowywania zazwyczaj jest znacznie dłuższy niż w systemach aplikacyjnych i ściśle zależy od przeprowadzanych analiz.

Definicja

Hurtownia danych jest dedykowanym systemem baz danych, który jest oddzielony od systemu transakcyjnego bazującego na danych operacyjnych.

Różni się on od systemu transakcyjnego tym, że:

- dane są utrzymywane w dużo dłuższym horyzoncie czasowym.
- dane są pozyskiwane z różnorodnych źródeł przy czym zapewniona jest ich jednolitość (tzw "czyste dane" ang. clean data).
- utrzymywanie danych jest optymalizowane pod kątem odpowiadania na złożone zapytania pochodzące od zarządzających oraz analityków.

Odkrywanie wiedzy w bazach danych

Odkrywanie wiedzy w bazach danych,
(*knowledge discovery in databases*)
to nietrywialny proces odkrywania

- obowiązujących,
- dotychczas nieznanych,
- potencjalnie użytecznych,
- zrozumiałych wzorców

w zbiorach danych.

Odkrywanie wiedzy w bazach danych

Jego celem jest przejście od “surowych” danych do zbioru wzorców, które mogą być następnie wykorzystane w procesie wspomagania podejmowania decyzji.

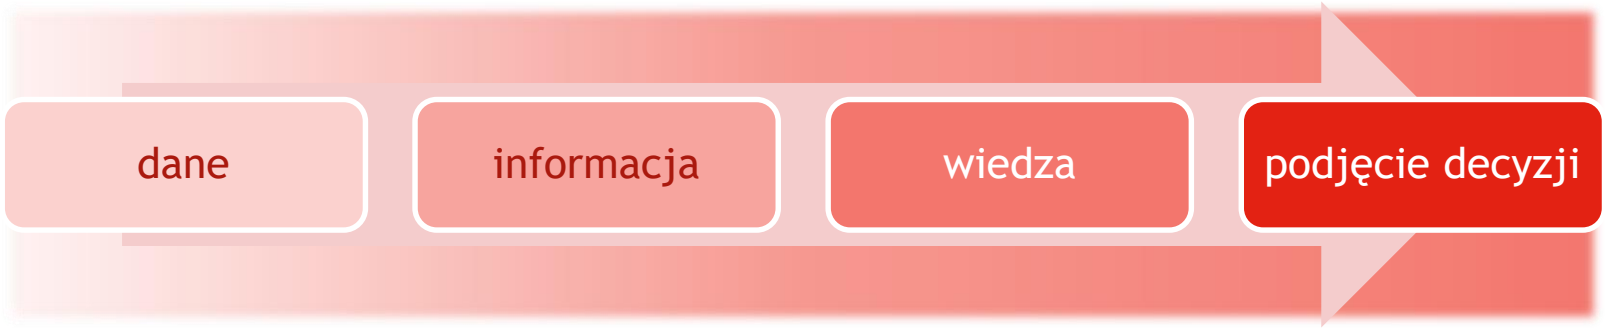
Odkrywanie wiedzy w bazach danych

Etapy procesu odkrywania wiedzy:

- Wszechstronna analiza problemu
- Selekcja, transformacja, czyszczenie danych
- Eksploracja danych
- Wizualizacja
- Analiza i ocena uzyskanych wyników
- Zastosowanie zdobytej wiedzy w praktyce

Dane, informacja, wiedza

- **Dane** – zgromadzone i zapisane fakty dotyczące zjawisk i obiektów.
- **Informacja** – dane, które zostały przekształcone, tak aby miały użyteczną dla człowieka postać.
- **Wiedza** = informacje + kontekst (wiedza znana) + doświadczenie w przetwarzaniu informacji.



Dane, informacja, wiedza

Zapytania SQL

- Kto dokonała największych zakupów, lista klientów …

Wielowymiarowa analiza (model OLAP)

- Średnie zakupy klientów, w regionie i czasie …

Eksploracja danych (opis lub predykcja)

- Jakie są cechy charakterystyczne klientów, którzy kupowali produkt X …

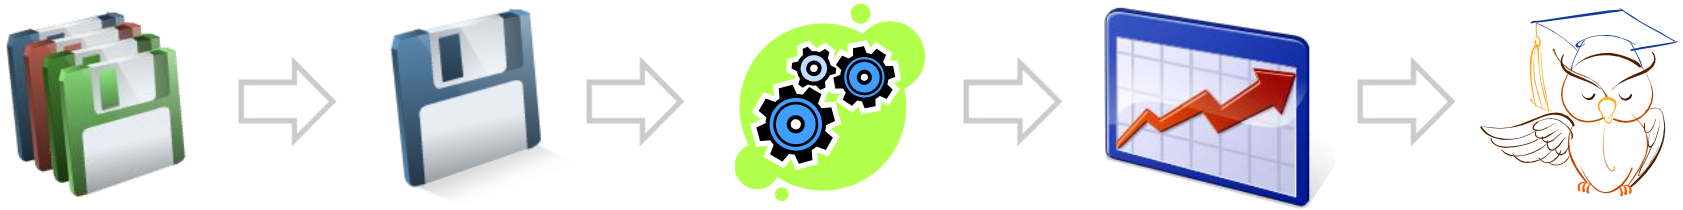
Eksploracja danych

Eksploracja danych to proces odkrywania nietrywialnych, dotychczas nieznanych, potencjalnie użytecznych reguł, zależności, wzorców, trendów w dużych zbiorach danych.



Eksploracja danych

eksploracja danych



selekcja, czyszczenie danych

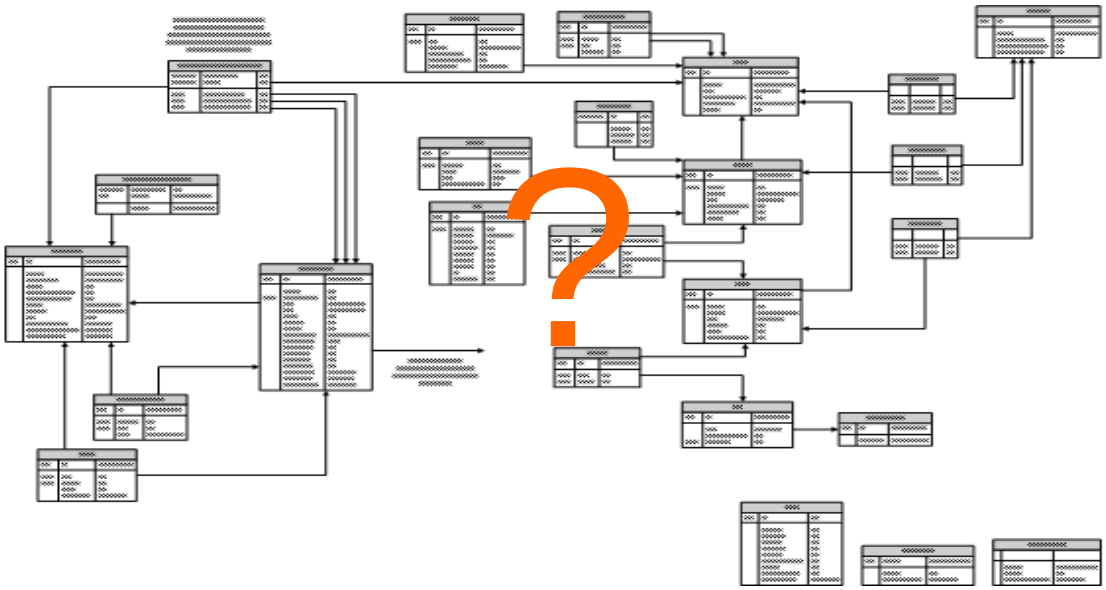
wybór metody

Interpretacja, analiza, ocena wyników

wiedza

Data mining - cel?

- Jest możliwe, że gromadzone dane są z sobą w jakiś sposób powiązane, ale nie wiemy jak. Chcemy poznać te relacje (*data mining*).



Data mining - cel?

- klasyfikacja/regresja
- grupowanie
- odkrywanie sekwencji
- analiza przebiegów czasowych
- odkrywanie asocjacji
- wykrywanie zmian i odchyleń
- analiza połączeń (eksploracja Web'u)

Hurtownia Danych Finansowych dla TUiR WARTA S.A. - COMARCH

Celem projektu hurtowni danych dla WARTA SA było:

- Zaprojektowanie kompleksowej architektury dla Korporacyjnej Hurtowni Danych i systemu Business Intelligence,
- Wykonanie i wdrożenie hurtowni danych finansowych zasilanej z systemów produkcyjnych,
- Wykonanie i wdrożenie hurtowni danych sprzedażowych i szkodowych,

Hurtownia Danych Finansowych dla TUiR WARTA S.A. - COMARCH

- Wdrożenie centralnego repozytorium metadanych biznesowych,
- Przygotowanie i automatyzacja procesu tworzenia raportów i sprawozdawczości do KNF,
- Umożliwienie przeprowadzania wielowymiarowych analiz ad-hoc,
- Zaprojektowanie, wykonanie i udostępnienie dla użytkowników raportów działających na danych hurtowni.

Hurtownia Danych Finansowych dla TUiR WARTA S.A. - COMARCH

Korzyści operacyjne:

- Możliwość utworzenia dowolnej ilości raportów bezpośrednio przez biznes,
- Skrócenie czasu niezbędnego do sporządzania raportów oraz uzgadniania danych do minimum,
- Uporządkowanie struktury raportów oraz dostępu do danych,
- Weryfikacja posiadanych zasobów informacyjnych, zdefiniowanie zakresów oraz sposobu raportowania,

Hurtownia Danych Finansowych dla TUiR WARTA S.A. - COMARCH

- Bazowanie na jednolitych danych przy sporządzaniu różnego rodzaju raportów i analiz, a w rezultacie eliminacja rozbieżności pomiędzy przygotowywanymi raportami
- Gromadzenie słowników wymiarów utrzymywanych dotychczas w plikach Excel w centralnym repozytorium metadanych i aplikacji Comarch MetaSource.

Hurtownie danych dla windykacji - BAKK Sp. z o.o.

Miary:

- Liczba odzyskanych wierzytelności - Wymiar opisuje liczbę wierzytelności odzyskanych od dłużników
- Liczba nieodzyskanych wierzytelności - Opisuje liczbę wierzytelności nieodzyskanych
- Kwota odzyskanych wierzytelności - Wymiar opisuje zbiorczą kwotę wierzytelności odzyskanych

Hurtownie danych dla windykacji -BAKK Sp. z o.o.

- Kwota nieodzyskanych wierzytelności - Opisuje zbiorczą kwotę nieodzyskanych długów
- Czas połączeń telefonicznych - Wymiar opisuje czas wykonanych rozmów telefonicznych

Hurtownie danych dla windykacji -BAKK Sp. z o.o.

Wymiary:

- Rodzaj zabezpieczenia zobowiązania dłużnika - Opisuje zobowiązanie pod kątem rodzaju jego zabezpieczenia (poręczenie, hipoteka, gwarancja)
- Czas zalegania z płatnościami dłużnika/kontrahenta przed przekazaniem do windykatora - Opisuje długość zalegania ze zobowiązaniem
- Czas odzyskania wierzytelności - Wymiar opisuje sumaryczny czas odzyskania wierzytelności, w podziale na okresy, np. 0--7 dni 8--30 dni, 31--90 dni

Hurtownie danych dla windykacji -BAKK Sp. z o.o.

Wymiary:

- Typ dłużnika - osoba fizyczna, osoba prawna, jednostka nie posiadająca osobowości prawnej
- Region siedziby dłużnika - geograficzna prezentacja siedziby dłużnika
- Branża dłużnika - branża, w której dłużnik prowadzi działalność gospodarczą

Hurtownie danych dla windykacji -BAKK Sp. z o.o.

Wymiary:

- Wiek windykatora - Opisuje przedziałowy wiek windykatora (np. 20-25 lat)
- Etap pracy nad kontem dłużnym - Przykładowe wartości: zgłoszone do windykacji, czeka na egzekucję komorniczą, windykacja zakończona
- Pracownik odpowiedzialny za konto dłużne - Opisuje kto się zajmuje kontem, wraz z hierarchią np. departament-zespół-pracownik.

Hurtownie danych dla windykacji -BAKK Sp. z o.o.

Grupa raportów koncentrująca się na efektywności zespołu windykacyjnego

Analiza efektywności zespołu windykacyjnego posiada dwa aspekty, aspekt osobowy oraz aspekt narzędziowy. Przy pomocy tej analizy można monitorować jakość pracy windykatorów, określić tych którzy są najbardziej skuteczni. W ramach osobowego aspektu tej analizy wykonuje się następujące raporty:

Hurtownie danych dla windykacji -BAKK Sp. z o.o.

- raport podjętych czynności windykacyjnych
- raport skuteczności czynności windykacyjnych (czy nastąpiła reakcja dłużnika, jaka jest reakcja, po jakim czasie reakcja nastąpiła)
- raport pracy konsultantów
- raport czasu połączeń telefonicznych
- raport kosztu działań windykatora

Pojęciowy model wielowymiarowy

Fakt - Wielkości i informacje charakteryzujące obserwowane procesy.

Wielkości te mogą być mierzone bezpośrednio (np. dostępne informacje o poziomach sprzedaży, cenach, stanach magazynowych) lub też mogą być pewnymi wartościami wyliczanymi (np. ilość klientów, która w danym dniu zakupiła dany towar - wielkość wyliczona na podstawie rodzaju i ilości zawartych transakcji). Fakty są podstawą budowy metryk, które dalej podlegają wszechstronnej analizie biznesowej i mogą służyć m.in. do monitorowania ważnych dla przedsiębiorstwa wskaźników ekonomicznych, badania skuteczności przeprowadzanej akcji promocyjnej itp.

Pojęciowy model wielowymiarowy

Słowo ***wymiar*** jest pojęciem-koncepcją stosowanym w nazewnictwie związanym z hurtowniami danych i oznacza pewien obszar zainteresowań lub kierunek potencjalnych analiz. Wymiary dostarczają perspektyw, z których końcowy użytkownik będzie mógł analizować dane związane z faktami.

Pojęciowy model wielowymiarowy

Fakty, to dane zależne, są funkcją wielu czynników (***wymiarów***) traktowanych jako dane niezależne.

Miary są wartościami opisującymi ***fakty***, które reprezentują wielkości i zjawiska podlegające ocenie.

Pojęciowy model wielowymiarowy

Wymiary (klasy opisów ***faktu***) to zmienne niezależne względem których analizowany jest dany ***fakt***, są opisane wartościami dyskretnymi, nazywanymi ***atrybutami***.

Atrybuty mogą tworzyć ***hierarchię***.

Pojęciowy model wielowymiarowy

Przykład powyższych pojęć dla analizy sprzedaży:

- Fakt → sprzedaż
- Miary → wartość, ilość, zysk
- Wymiary → czas, klient, produkt, region
- Atrybuty dla czasu → tydzień, miesiąc, kwartał, powyższe atrybuty tworzą hierarchię wymiaru czas

Pojęciowy model wielowymiarowy

Miara vs. wymiar - różnica miedzy nimi polega na tym, ze miara zawiera wartości liczbowe opisujące dany fakt, natomiast wymiar wartości opisowe (tekstowe) danego faktu, przechowywane w atrybutach wymiaru, np. jeśli chcemy opisać sprzedasz samochodów to ilość sprzedanych samochodów to miara, natomiast marka to atrybut wymiaru. Wymiary są informacjami referencyjnymi i określają kontekst analiz miar. W modelu wielowymiarowym każda miara jest powiązana z kilkoma wymiarami. Wymiar najczęściej posiada strukturę hierarchiczna, określającą sposób agregacji wartości skojarzonych z nim miar.

OLAP

OLAP (On-Line Analytical Processing) - narzędzie do wygodnej i szybkiej analizy danych z różnych obszarów działalności przedsiębiorstwa. Najważniejszą, a zarazem jedyną zgodnie podawaną przez wszystkie popularne definicje, cechą technologii OLAP jest wielowymiarowość.

OLAP

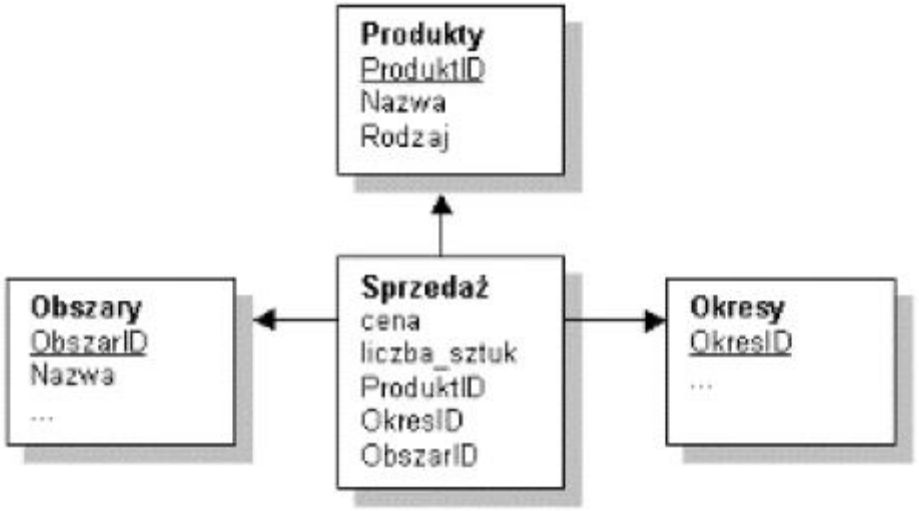
OLAP - technologia oprogramowania pozwalająca na szybką i intuicyjną analizę dużej ilości danych dostosowanych do potrzeb w rożnych przekrojach i na rożnym poziomie szczegółowości. Określenie klasy analitycznych systemów informatycznych.

Modele OLAP

W hurtowni danych wyróżnia się trzy modele przetwarzania analitycznego:

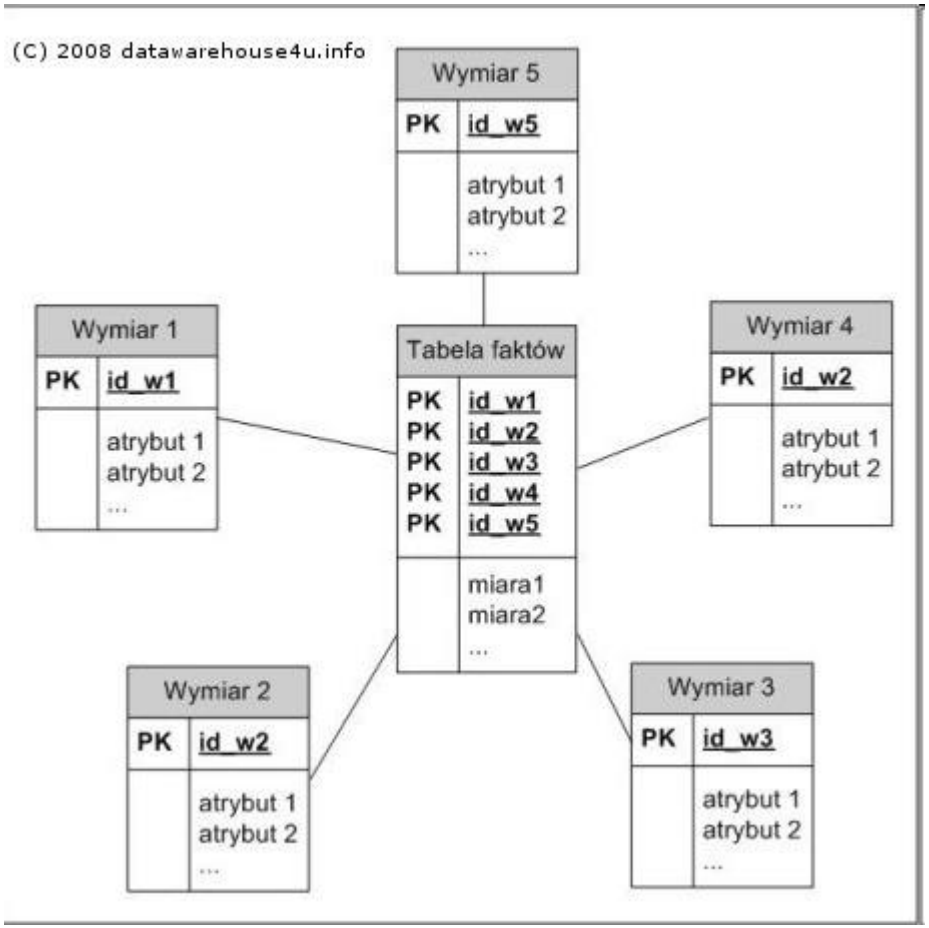
1. **Wielowymiarowe, analityczne przetwarzanie** on-line (MOLAP)
2. **Relacyjne, analityczne przetwarzanie** on-line (ROLAP).
3. **Hybrydowe, analityczne przetwarzanie** online (HOLAP).

ROLAP

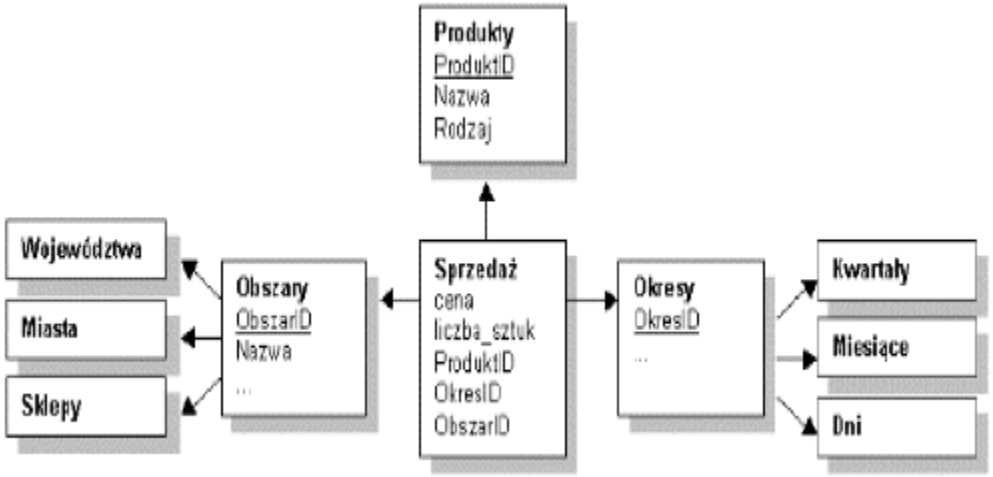


Schemat gwiazdy

ROLAP

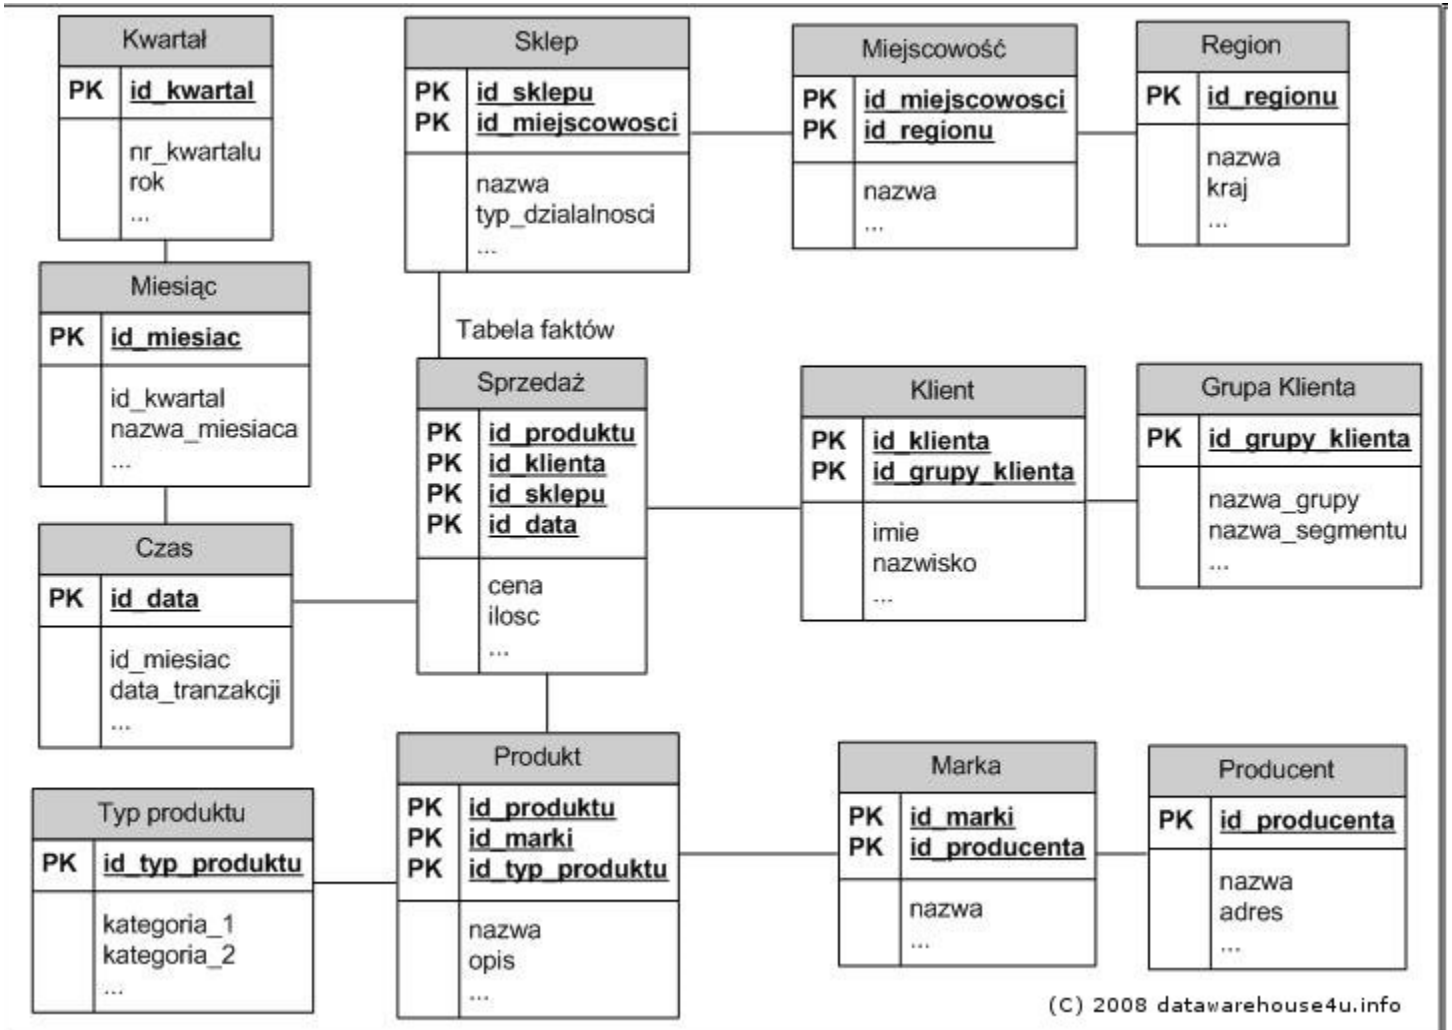

(C) 2008 datawarehouse4u.info
Wymiar 5
PK id_w5
atrybut 1
atrybut 2
...
Wymiar 1
PK id_w1
atrybut 1
atrybut 2
...
Tabela faktów
PK id_w1
PK id_w2
PK id_w3
PK id_w4
PK id_w5
miara1
miara2
...
Wymiar 4
PK id_w2
atrybut 1
atrybut 2
...
Wymiar 2
PK id_w2
atrybut 1
atrybut 2
...
Wymiar 3
PK id_w3
atrybut 1
atrybut 2
...

ROLAP

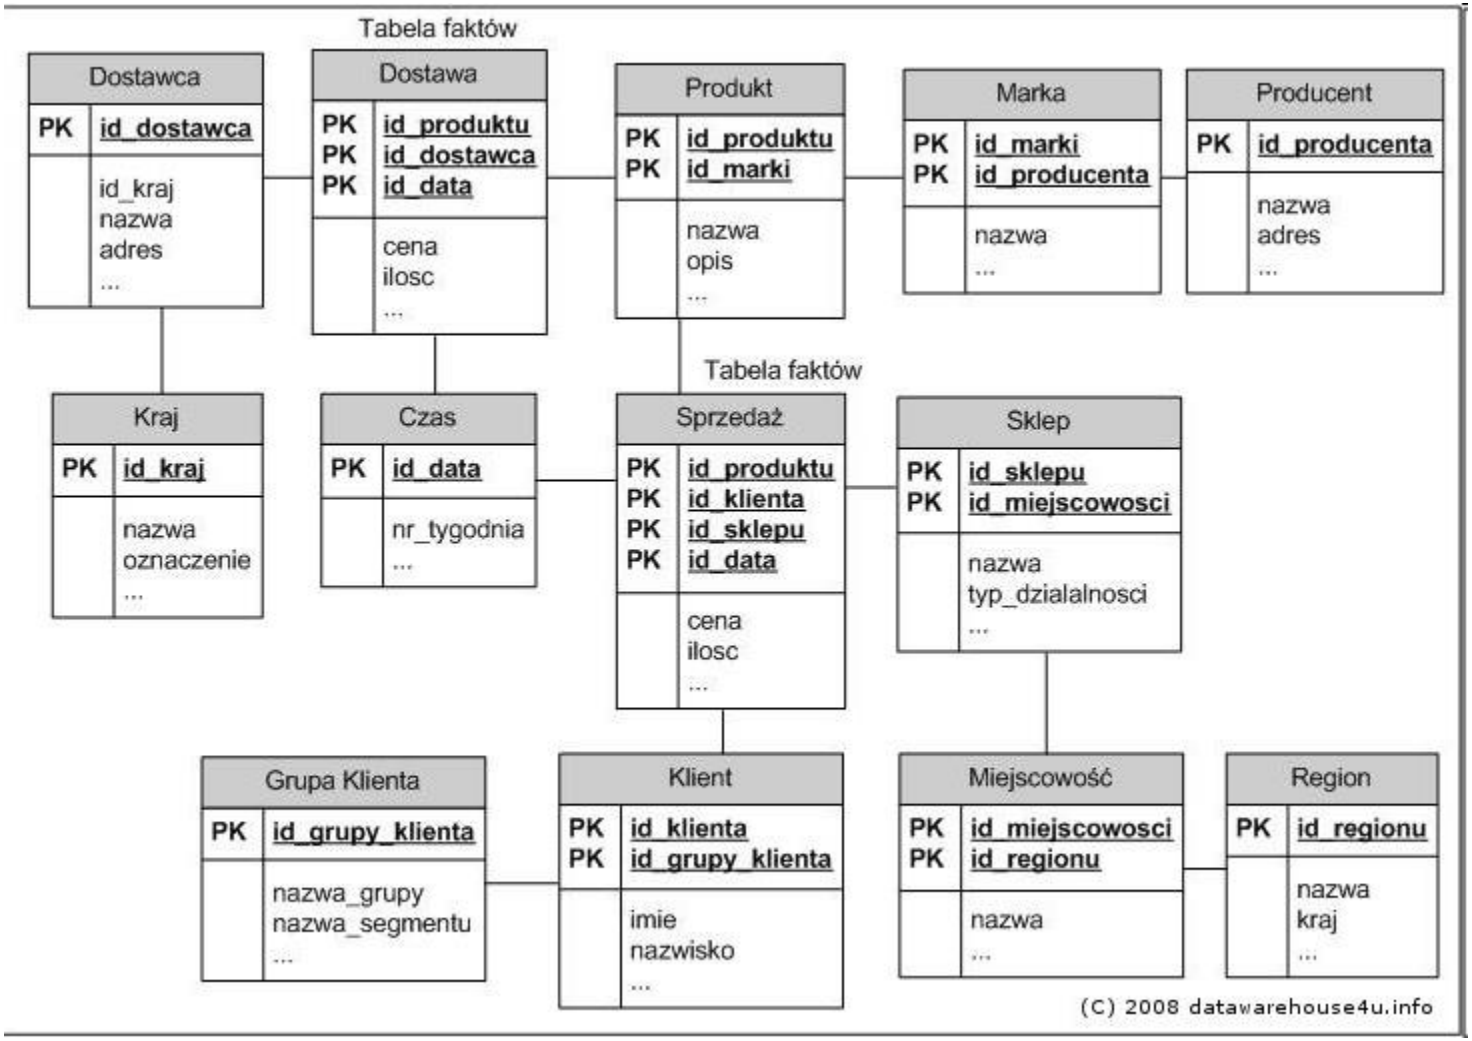


Schemat płatka śniegu

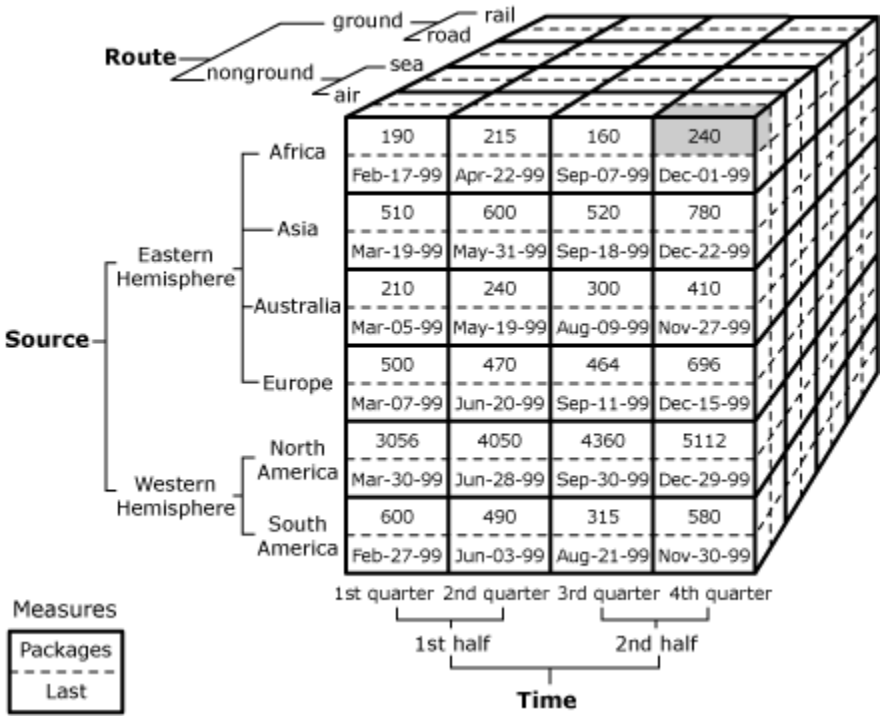
ROLAP


Kwartał
PK id_kwartal
nr_kwartalu
rok
...
Sklep
PK id_sklepu
PK id_miejscowosci
nazwa
typ_dzialalnosci
...
Miejscowość
PK id_miejscowosci
PK id_regionu
nazwa
...
Region
PK id_regionu
nazwa
kraj
...
Miesiąc
PK id_miesiac
id_kwartal
nazwa_miesiaca
...
Tabela faktów
Sprzedaż
PK id_produktu
PK id_klienta
PK id_sklepu
PK id_data
cena
ilosc
...
Klient
PK id_klienta
PK id_grupy_klienta
imie
nazwisko
...
Grupa Klienta
PK id_grupy_klienta
nazwa_grupy
nazwa_segmentu
...
Czas
PK id_data
id_miesiac
data_tranzakcji
...
Produkt
PK id_produktu
PK id_marki
PK id_typ_produktu
nazwa
opis
...
Marka
PK id_marki
PK id_producenta
nazwa
...
Producent
PK id_producenta
nazwa
adres
...
Typ produktu
PK id_typ_produktu
kategoria_1
kategoria_2
...
(C) 2008 datawarehouse4u.info

ROLAP


Tabela faktów
Dostawca
PK id_dostawca
id_kraj
nazwa
adres
...
Dostawa
PK id_produktu
PK id_dostawca
PK id_data
cena
ilosc
...
Produkt
PK id_produktu
PK id_marki
nazwa
opis
...
Marka
PK id_marki
PK id_producenta
nazwa
...
Producent
PK id_producenta
nazwa
adres
...
Tabela faktów
Kraj
PK id_kraj
nazwa
oznaczenie
...
Czas
PK id_data
nr_tygodnia
...
Sprzedaż
PK id_produktu
PK id_klienta
PK id_sklepu
PK id_data
cena
ilosc
...
Sklep
PK id_sklepu
PK id_miejscowosci
nazwa
typ_dzialalnosci
...
Grupa Klienta
PK id_grupy_klienta
nazwa_grupy
nazwa_segmentu
...
Klient
PK id_klienta
PK id_grupy_klienta
imie
nazwisko
...
Miejscowość
PK id_miejscowosci
PK id_regionu
nazwa
...
Region
PK id_regionu
nazwa
kraj
...
(C) 2008 datawarehouse4u.info

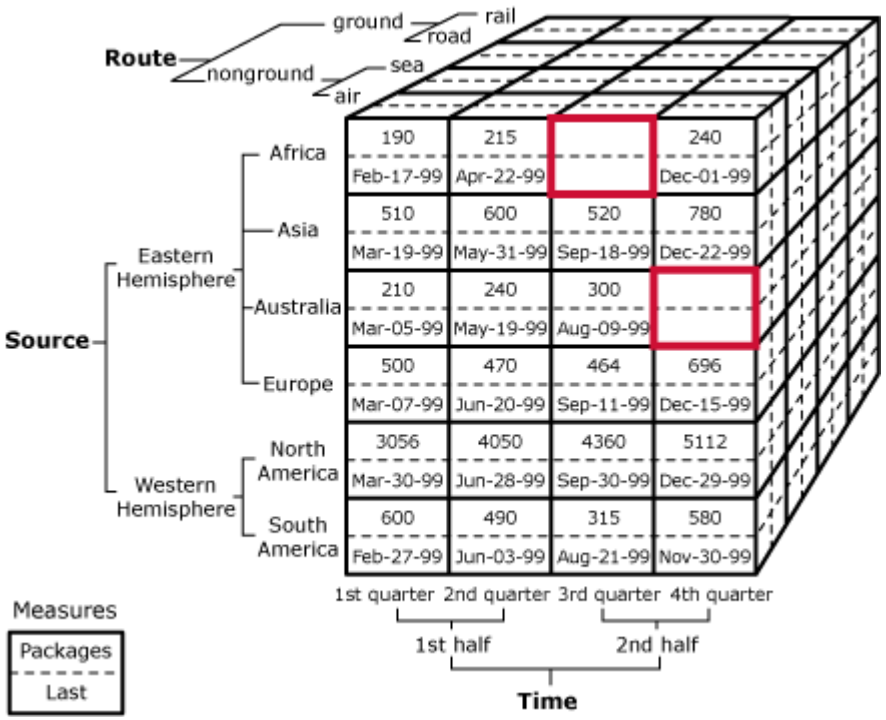
MOLAP



Logika MOLAP

Źródło https://docs.microsoft.com/en-us/analysis-services/

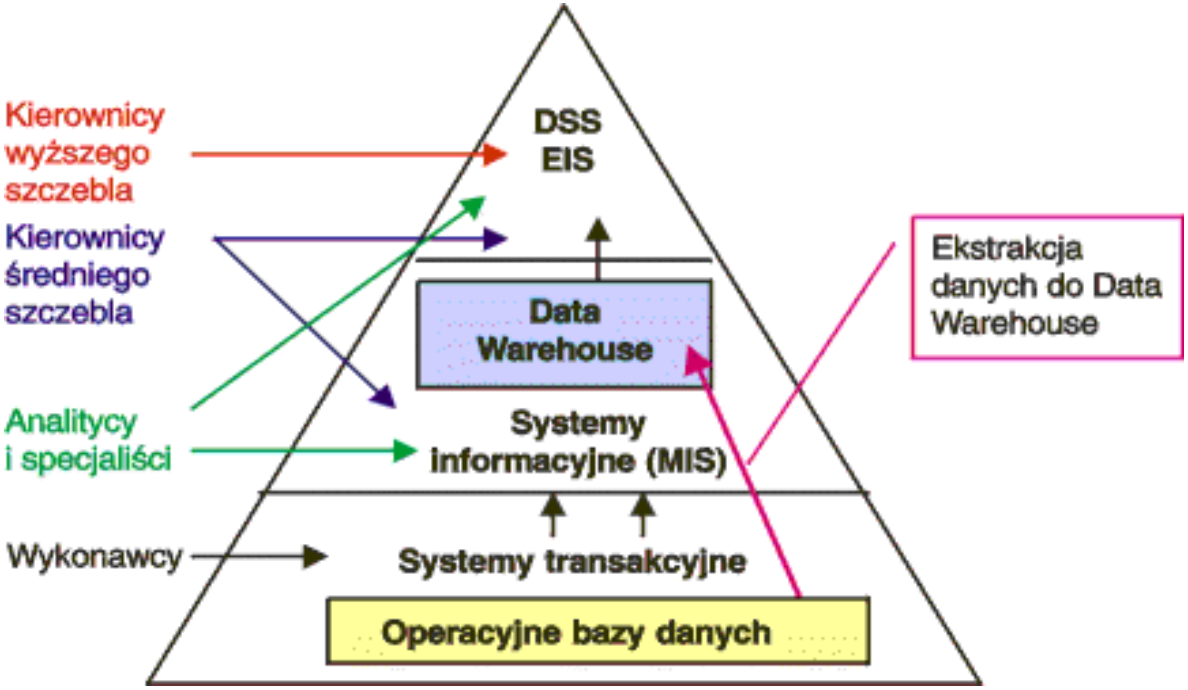
MOLAP



Logika MOLAP

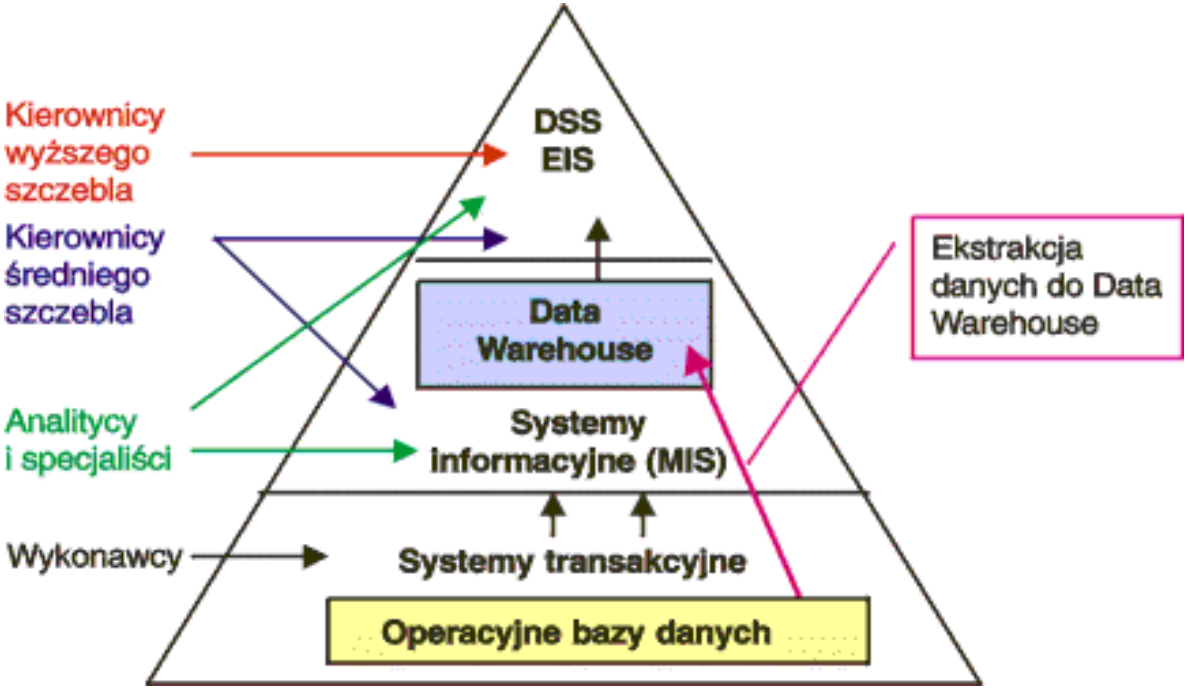
Źródło https://docs.microsoft.com/en-us/analysis-services/

Miejsce hurtowni danych w strukturze informatycznej przedsiębiorstwa



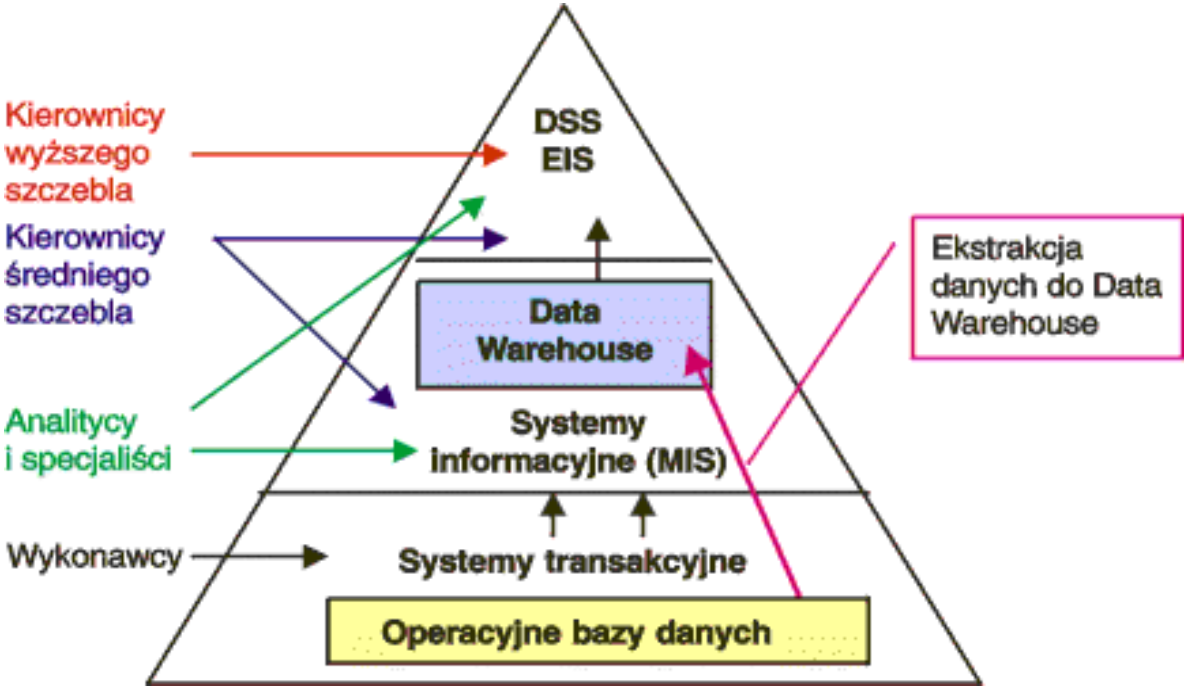
- **Systemy transakcyjne - aplikacje wspierające bieżącą aktywność** przedsiębiorstwa w zakresie księgowości, finansów, kadr, produkcji, gromadzące dane i udostępniające dane w postaci raportów i zestawień - wykorzystywane przez bezpośrednich wykonawców operacji.

Miejsce hurtowni danych w strukturze informatycznej przedsiębiorstwa



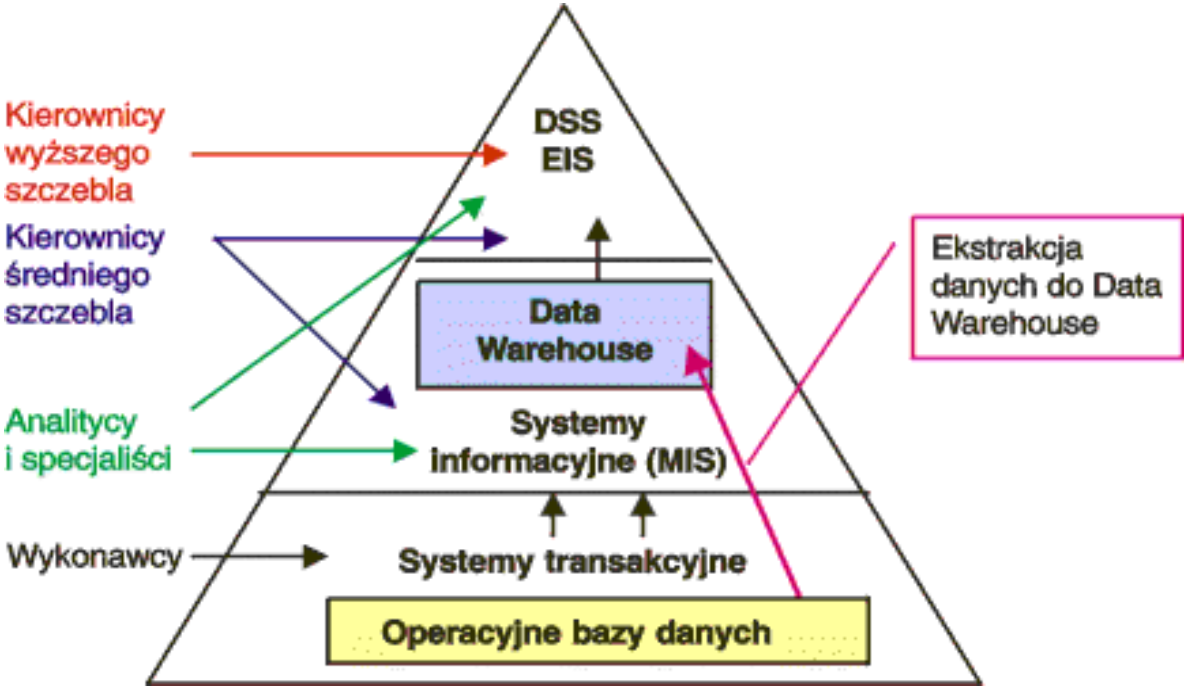
- **Systemy informacyjne (ang. Management Information Systems -** MIS) - aplikacje wspierające zarządzanie, dostarczające informacji, działające na bazach transakcyjnych (np. FK, Kadry, Płace, Magazyn, itp.), wykorzystywane przez analityków i kierowników średniego szczebla.

Miejsce hurtowni danych w strukturze informatycznej przedsiębiorstwa



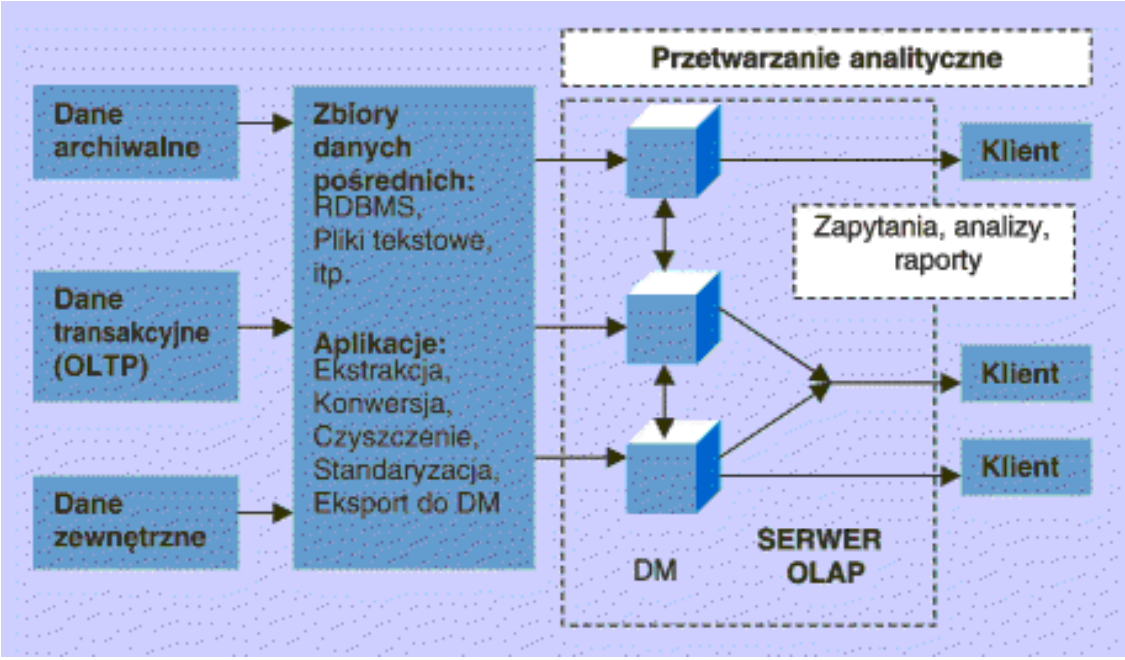
- **Systemy Wspomagające Podejmowanie Decyzji (ang. Decision** Support Systems - DSS) - aplikacje dostarczające wiedzy, wykorzystywane przez kierownictwo średniego i wysokiego szczebla oraz analityków biznesu.

Miejsce hurtowni danych w strukturze informatycznej przedsiębiorstwa



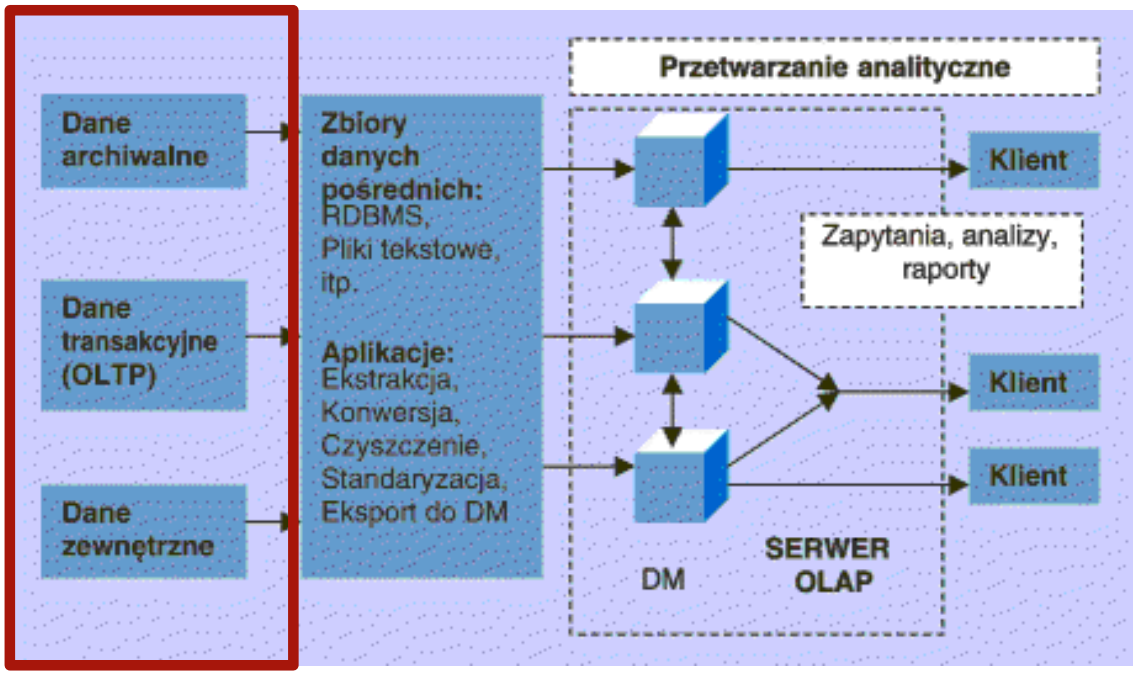
- **Systemy Informowania Kierownictwa (ang. Executive** Information Systems - EIS) - aplikacje dostarczające kierownictwu wybrane zestawienia i raporty z systemu DSS.

Model warstwowy hurtowni danych



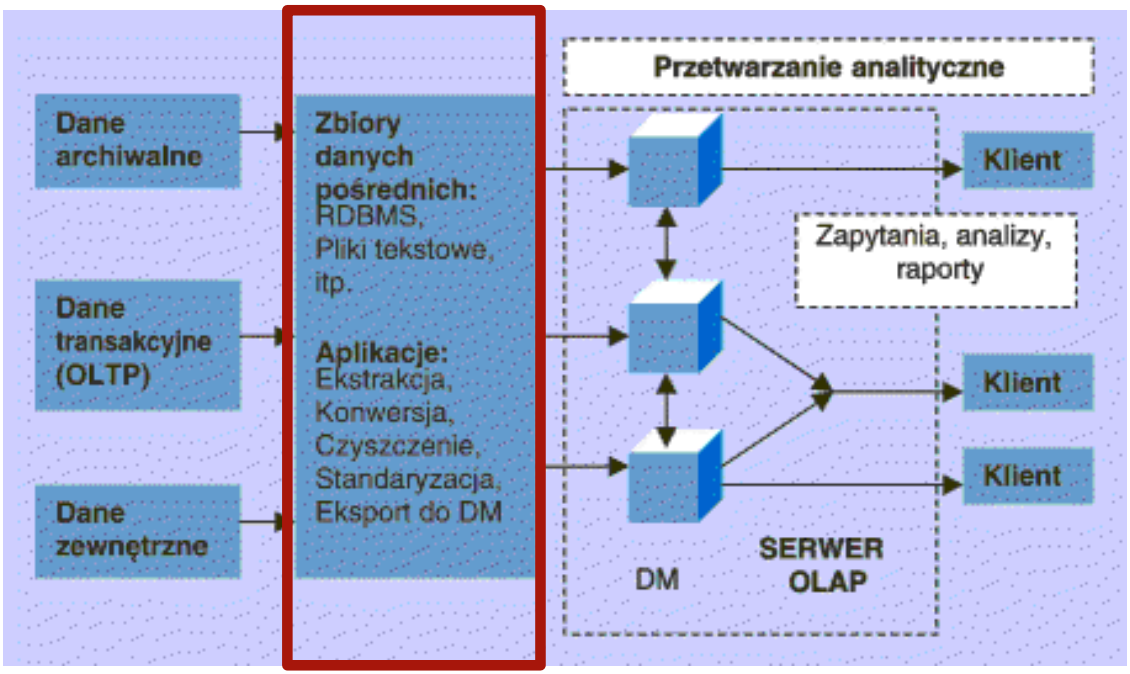
Architektura warstwowa środowiska HD

Model warstwowy hurtowni danych



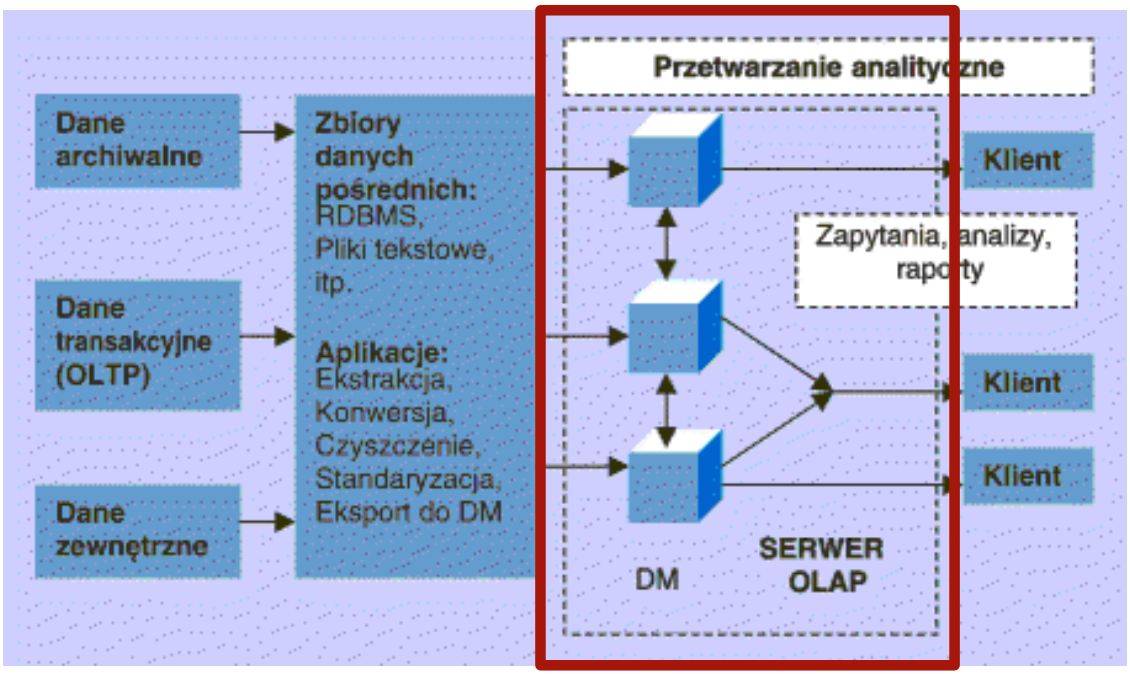
- **Warstwa danych źródłowych (dane** transakcyjne - OLTP, dane historyczne i archiwalne, dane ze źródeł zewnętrznych).

Model warstwowy hurtowni danych



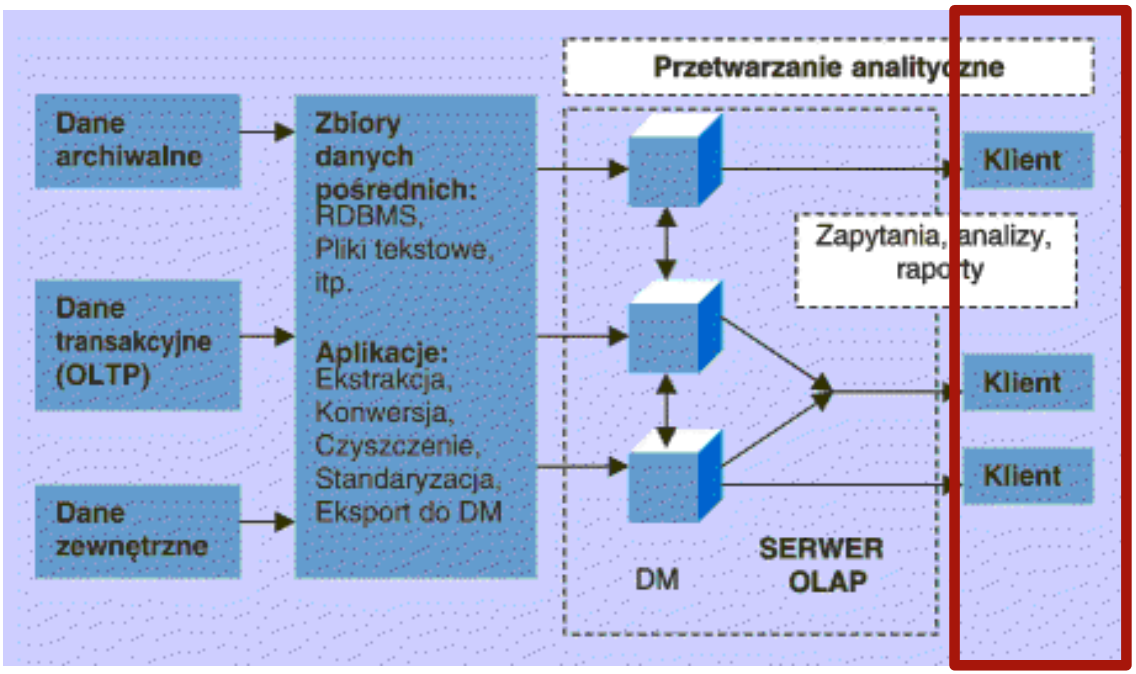
- **Warstwa konwersji danych (zbiory przejściowe** i tymczasowe oraz oprogramowanie ekstrakcji i konwersji danych).

Model warstwowy hurtowni danych



- **Warstwa hurtowni danych, na którą składają** się hurtownie tematyczne (DM - Data Mart) w architekturze odpowiedniej do przetwarzania MOLAP lub ROLAP oraz narzędzia modelowania analitycznego.

Model warstwowy hurtowni danych



- **Warstwa prezentacji (na stacjach klientów).**

Cechy ROLAP i MOLAP

ROALP

- **relacyjne odwzorowanie modelu wielowymiarowego**
- **względnie łatwa modyfikacja danych**
- **brak ograniczeń dotyczących liczby wymiarów**
- **często stosowane do budowy centralnej hurtowni danych**

Cechy ROLAP i MOLAP

MOALP

- **intuicyjna agregacja danych**
- **naturalna reprezentacja struktur wielowymiarowych**
- **duża wydajność analizy wielowymiarowej**
- **znacznie trudniejsza modyfikacja danych**
- **często stosowane do budowy data mart**

Hurtownia i składnica danych

Hurtownia danych

•przeznaczona dla całej organizacji

niezależna od zastosowania

• obejmuje wszystkie przewidywane analizy (w firmie)

• scentralizowana

jedna hurtownia w organizacji

• przechowuje dane mało zagregowane (najczęściej)

• przechowuje dane bez powtórzeń

wiele źródeł danych

• dane operacyjne z wielu baz + inne dane zewnętrzne

Hurtownia i składnica danych

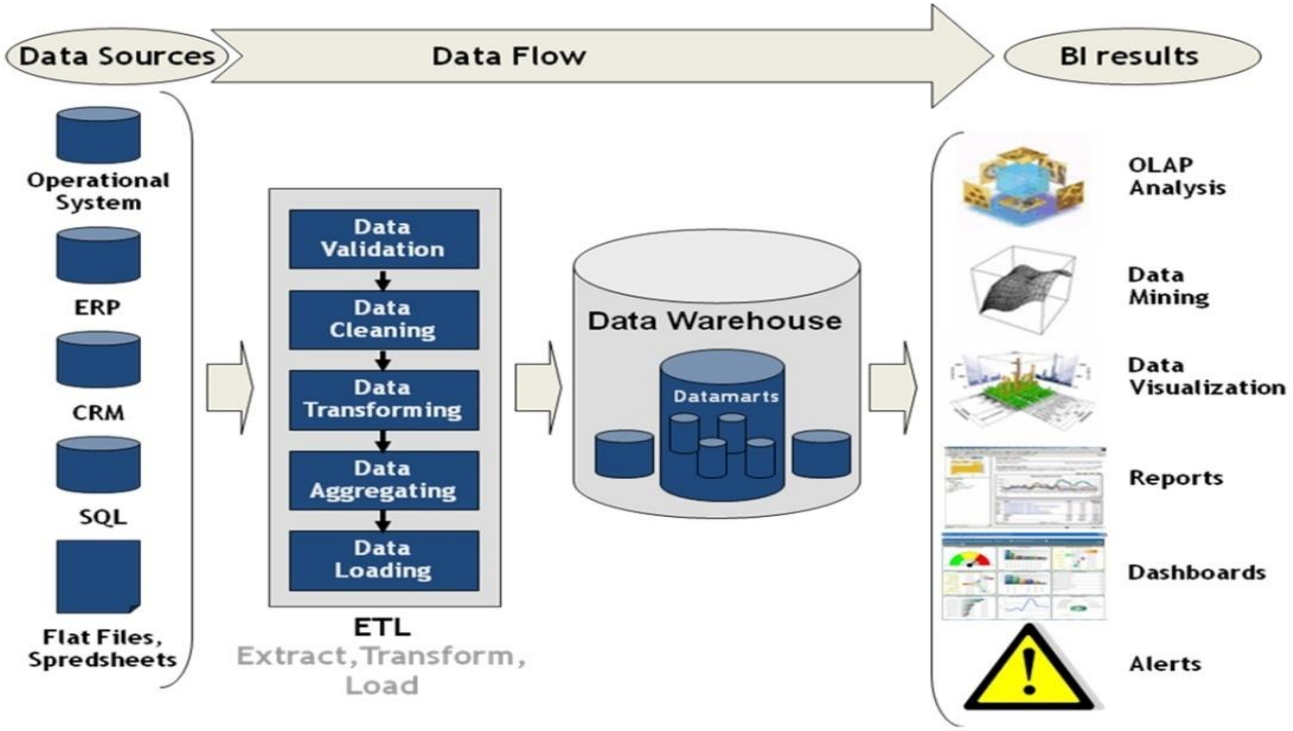
Składnica danych

- przeznaczona dla określonych działów

  specyficzna dla zastosowania
- obejmuje wszystkie przewidywane analizy w dziale
- dane w różnych składnicach mogą się powtarzać

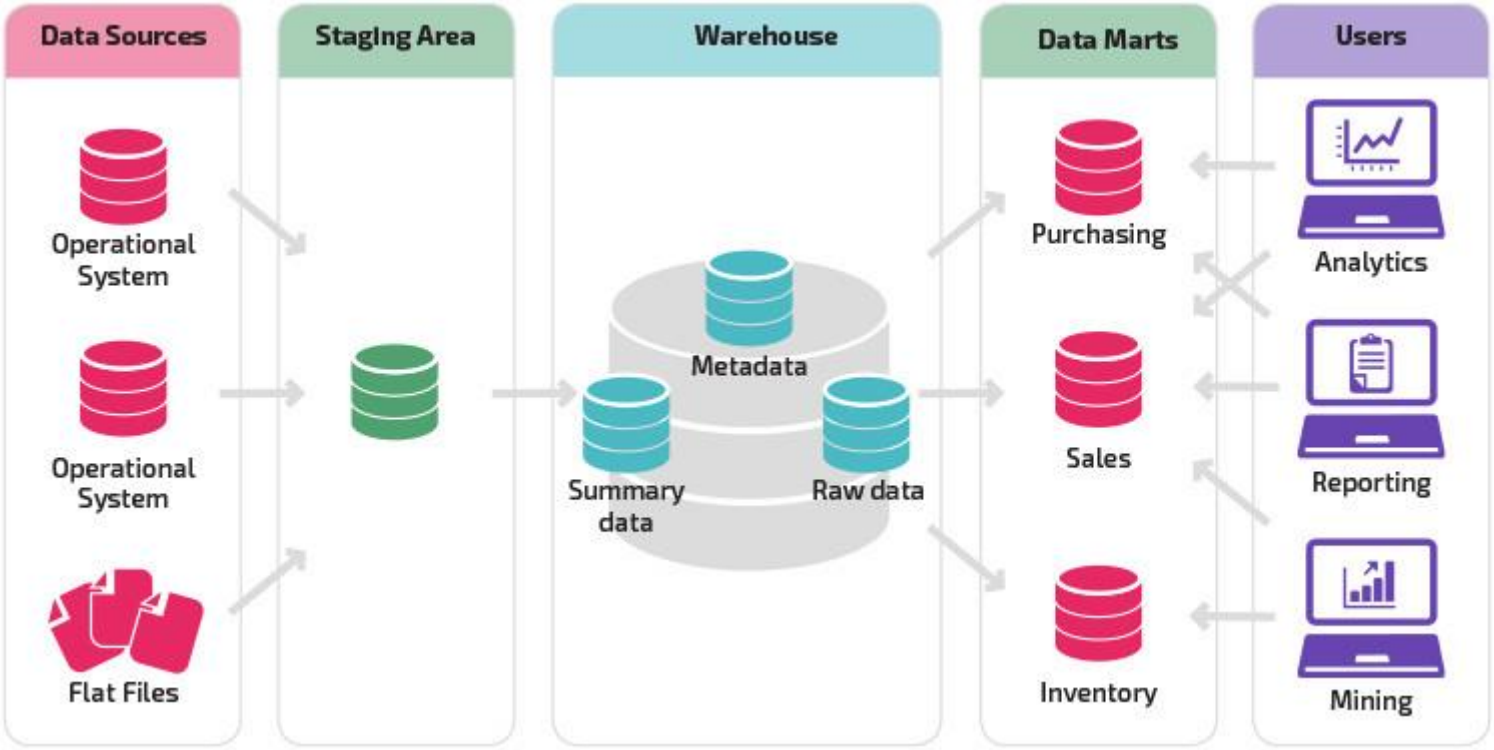
  Wiele składnic w organizacji
- przechowuje dane silnie zagregowane
- zazwyczaj jedno źródło danych – centralna hurtowania danych

Model warstwowy hurtowni danych



- Model warstwowy

Model warstwowy hurtowni danych



- Model warstwowy – składnice danych

SAS Institute - TP

Potrzeba biznesowa TP

Głównymi powodami projektu budowy Hurtowni Danych były:

- ✓ Brak informacji zarządczej na poziomie Zarządu i Dyrektorów Spółki,
- ✓ Brak centralnego repozytorium danych,
- ✓ Pięć różnych systemów bilingowych i ponad 20 baz danych.
- ✓ W trakcie procesu restrukturyzacyjnego w obszarze IT w TP, powstała jedna, spójna platforma bilingowa działająca w jednej lokalizacji

SAS Institute - TP

W systemie zidentyfikowano kilka podsystemów między innymi - Datamart KLIENT i system STRATUS. W Datamart KLIENT każdy klient jest opisany w jednym wierszu tabeli (rekordzie). Do charakterystyki klientów wykorzystuje się około **1700** zmiennych (cech), z czego 1100 zmiennych pochodzi z "surowych" danych historycznych, natomiast około **600** zostało stworzonych przez pracowników SAS Institute Polska

Eksploracja danych

Eksploracja danych to proces odkrywania nietrywialnych, dotychczas nieznanych, potencjalnie użytecznych reguł, zależności, wzorców, trendów w dużych zbiorach danych

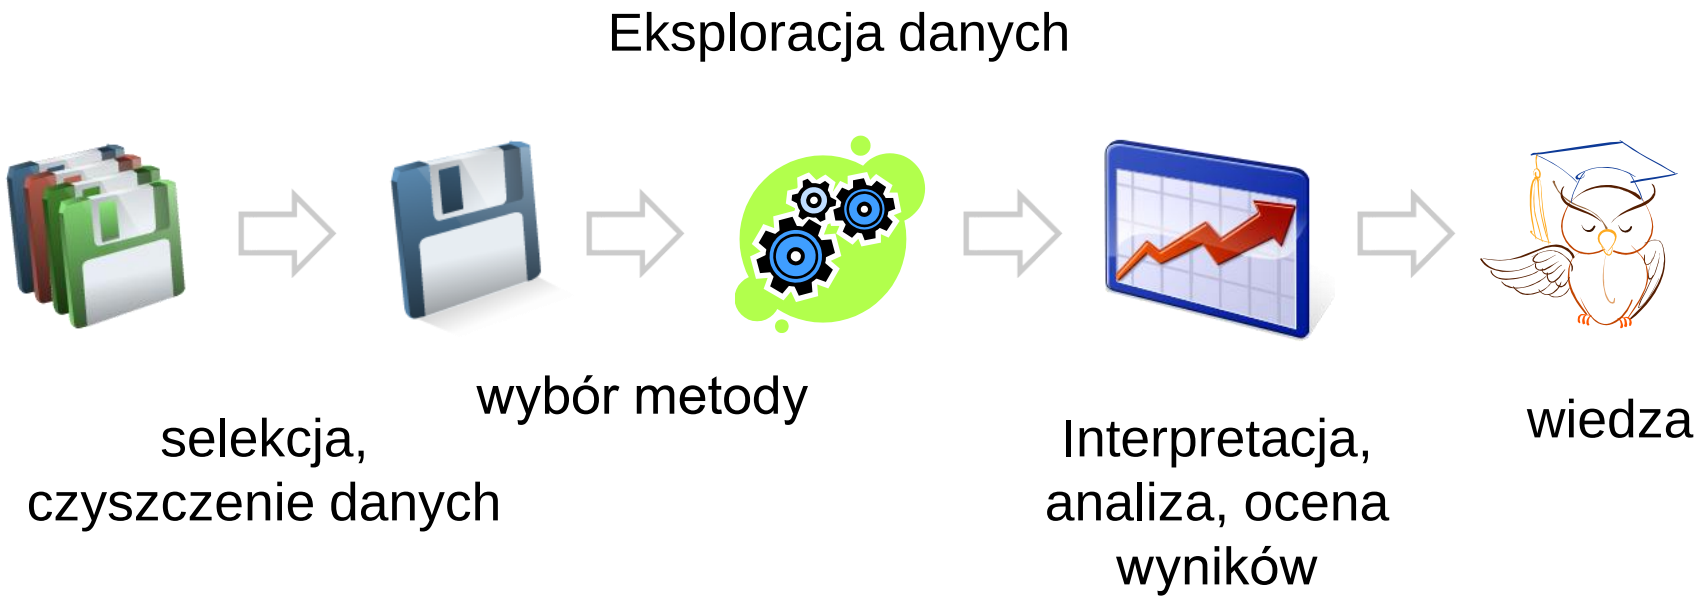


Eksploracja danych

Eksploracja danych ekstrakcja wzorców i wiedzy z dużych zbiorów danych. Szukanie wzorca nie gotowej informacji.

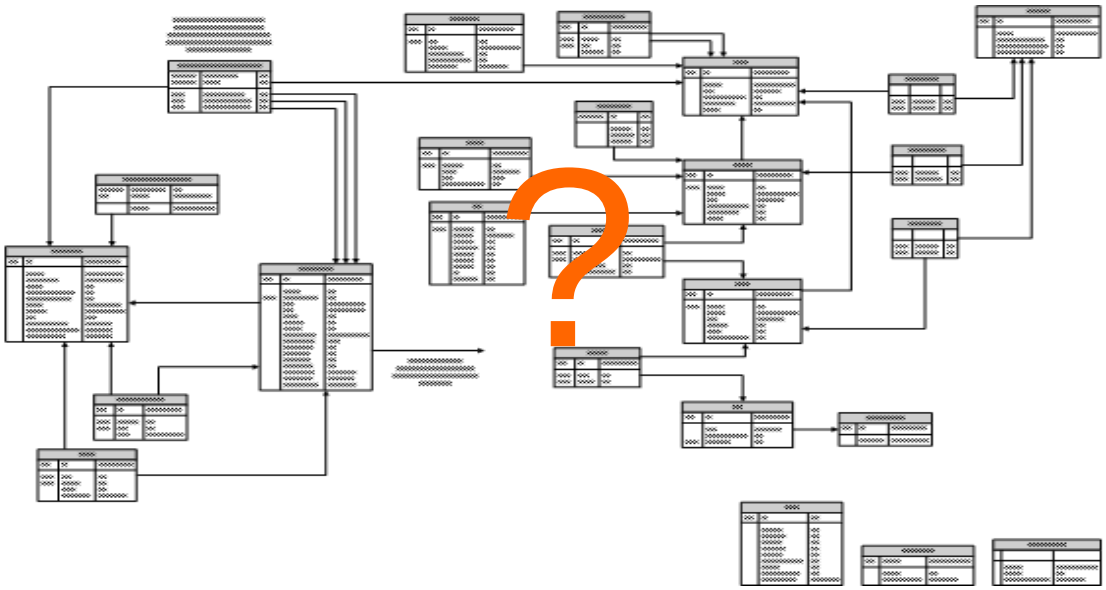


Eksploracja danych



Data mining - cel?

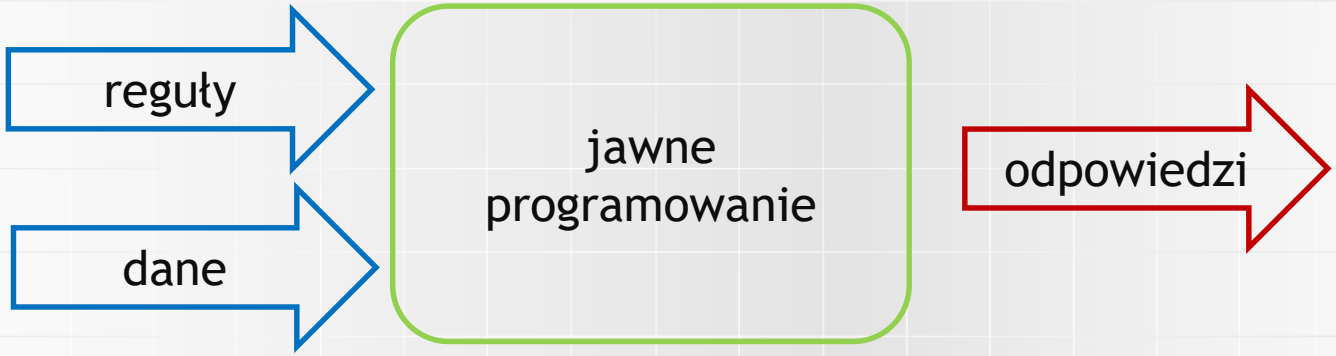
- Jest możliwe, że gromadzone dane są z sobą w jakiś sposób powiązane, ale nie wiemy jak. Chcemy poznać te relacje (*data mining*).



Data mining - cel?

- klasyfikacja/regresja
- grupowanie
- analiza przebiegów czasowych
- odkrywanie asocjacji
- wykrywanie zmian i odchyleń
- analiza połączeń

Uczenie maszyn – Machine learning

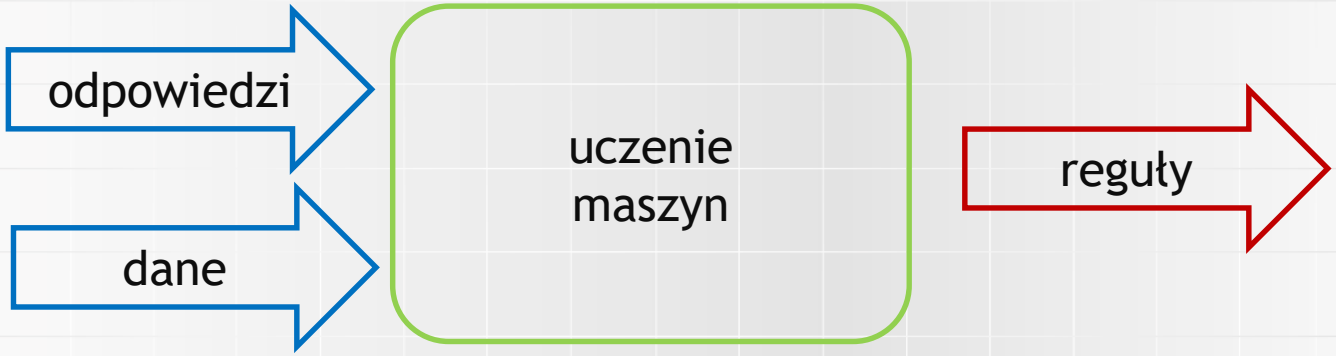


Jawne [tradycyjne] programowanie

Przykłady:

- Filtr spamu – opracowanie reguł (np. zawiera „gratulujemy”, „wygrałeś”, „kliknij aby odebrać nagrodę” , dostarczenie danych, działający filtr.
- Diagnostyka medyczna – opracowanie reguł (np. poziom cukru we krwi przekracza wartość …), dostarczenie danych, diagnoza.

Uczenie maszyn – Machine learning

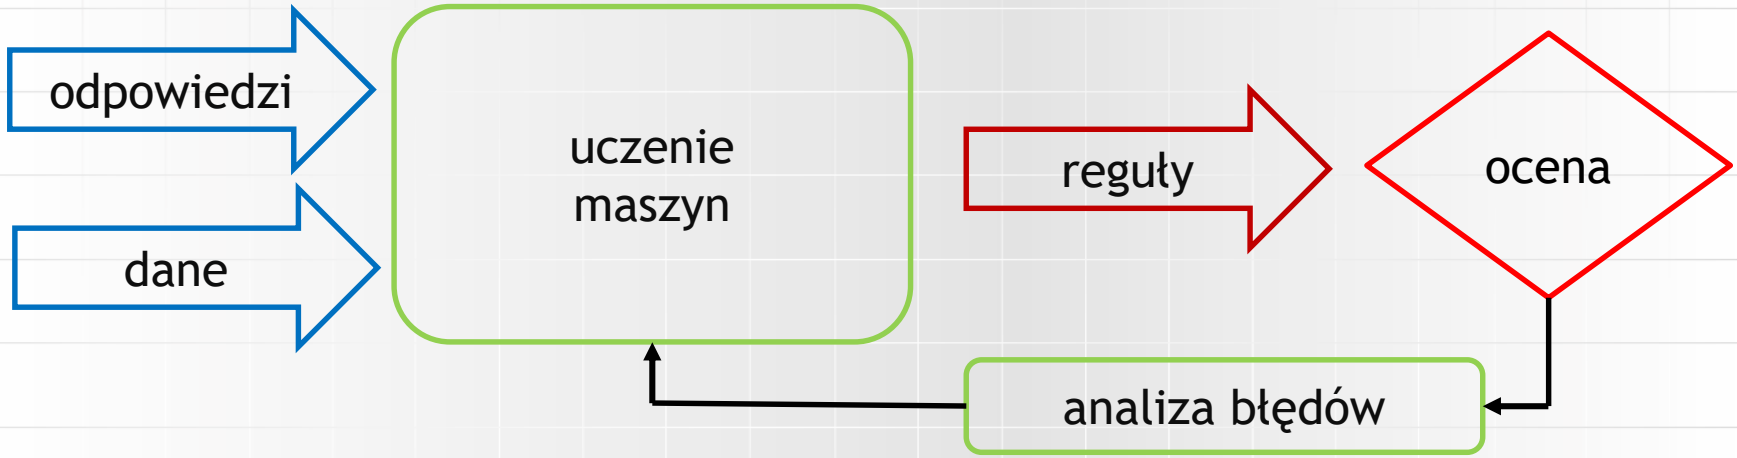


Uczenie maszyn

Uczenie maszyn [maszynowe] to dziedzina nauki dająca komputerom możliwość uczenia się bez konieczności ich jawnego programowania

Arthur Samuel, *1959*

Uczenie maszyn – Machine learning



Rys. 3. Uczenie maszyn oraz analiza błędów

Program komputerowy uczy się z doświadczenia **E** (Experience) w kontekście pewnego zadania **T** (Task) i miary wydajności **P** (Performance), jeżeli jego wydajność na T, mierzona P, wzrasta wraz z doświadczeniem **E**

Tom Mitchell, 1997

Politechnika Wrocławska

Uczenie maszyn – Machine learning

Algorytm uczenia maszynowego buduje model matematyczny na podstawie przykładowych danych, zwanych zbiorem uczącym, w celu prognozowania lub podejmowania decyzji bez konieczności programowania (budowania modelu) przez człowieka

Zamiast sztywnych instrukcji, naucz na przykładach

Politechnika Wrocławska

Uczenie maszyn vs Sztuczna inteligencja

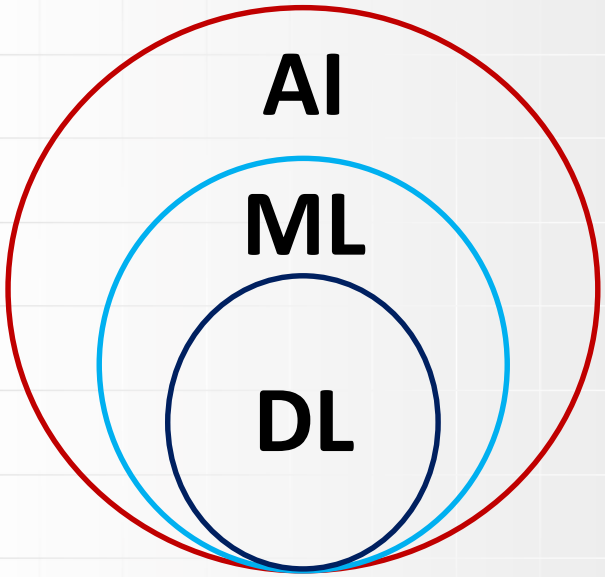
Uczenie maszyn	Sztuczna inteligencja
Dziedzina AI, która na podstawie przykładów, wyszukiwania relacji zawartych w danych uczących buduje model	Pojęcie szersze niż ML, celem jest naśladowanie przejawów ludzkiej inteligencji
Ukierunkowane na miarę(y) wydajności	Ukierunkowana na odniesienie sukcesu - symulowanie inteligencji
Budowa modelu z danych - sposób opracowania danych	Myślenie i wykonywanie zadań jak człowiek

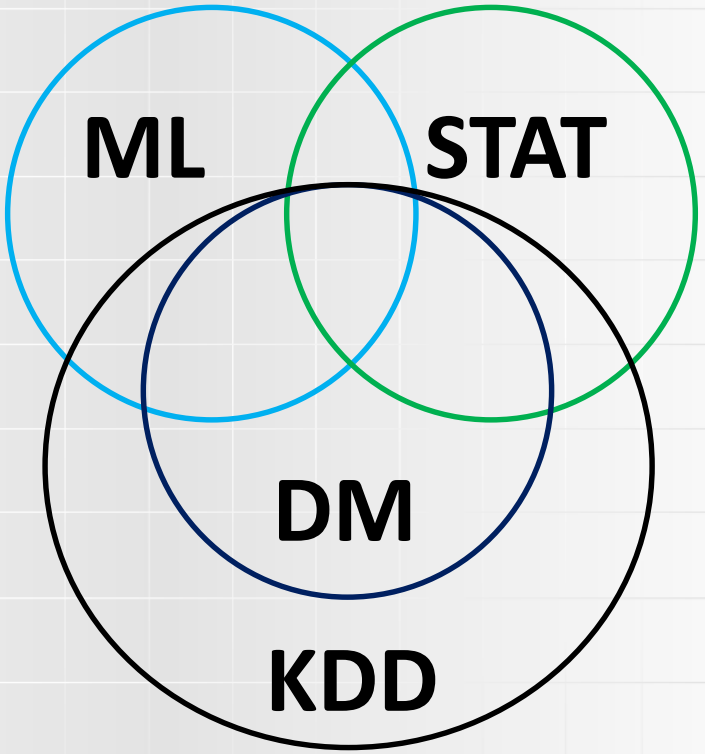
Politechnika Wrocławska

Uczenie maszyn vs Eksploracja danych

Uczenie maszyn	Eksploracja danych
Jest poddziedziną Sztucznej Inteligencji	Jest etapem procesu Odkrywania wiedzy w bazach danych.
Zautomatyzowanie procesu uczenia, rola człowieka jest ograniczona	Ukierunkowana na objaśnianie - odkrywanie wiedzy - nowa wiedza dla człowieka
Ukierunkowane na budowę modelu z danych	Ukierunkowana na uzyskanie informacji, którą interpretuje człowiek

Uczenie maszyn





- AI – sztuczna inteligencja
- DL – uczenie głębokie
- DM – eksploracja danych
- KDD – odkrywanie wiedzy w bazach danych
- ML – uczenie maszynowe
- STAT – statystyka

Data mining - cel?

- **klasyfikacja/regresja** – Klasyfikacja i Regresja to techniki eksploracji danych wykorzystywane do rozwiązywania podobnych problemów. Oba są używane w analizie predykcyjnej, ale regresja jest używana do przewidywania wartości numerycznej lub ciągłej, podczas gdy klasyfikacja używa etykiet by przypisać dane do odrębnych kategorii (klas)

Politechnika Wrocławska

Uczenie maszyn – podstawowe pojęcia

- **Zbiór uczący**, dane uczące [learning dataset]

Zbiór danych przeznaczony do uczenia algorytmu. Może też służyć do oceny wydajności modelu utworzonego w procesie uczenia.

- **Obiekt**, próbka, instancja [object, sample, instance, example]

Opis pojedynczego obiektu w zbiorze danych. W przypadku danych zgromadzonych w tabeli - jeden wiersz reprezentuje jeden obiekt.

- **Cecha**, atrybut [feature, attribute]

Cecha użyta do opisania obiektu. W przypadku danych zgromadzonych w tabeli, cechami są kolejne kolumny.

Politechnika Wrocławska

Uczenie maszyn – podstawowe pojęcia

- **Zbiór uczący**:
  - Etykietowany [labeled]– zawiera dane o przynależności obiektu do etykiety klasy
  - Nieetykietowany [unlabeled] – nie zawiera danych o przynależności obiektu do etykiety klasy
- **Dane:**
  - Strukturalne [structured data] – występują związki między danym – relacyjne bazy danych
  - Pół-strukturalne [semi-structured data] – najczęściej pojedyncza tabela, nie musi spełniać wymogu tabeli relacyjnej
  - Nieustrukturyzowane dane [unstructured data] – zdjęcia, dźwięk, dokumenty tekstowe, strony internetowe

Uczenie maszyn – podstawowe pojęcia

	Sepal Length (mm)	Sepal Width (mm)	Petal Length (mm)	Petal Width (mm)	cechy
1	50	20	35	10	
2	62	22	45	15	
3	60	22	40	10	
4	60	22	50	15	
5	45	23	13	3	
6	50	23	33	10	
7	63	23	44	13	
8	55	23	40	13	obiekt
9	55	24	38	11	
10	49	24	33	10	
11	55	24	37	10	
12	56	25	39	11	
13	63	25	49	15	
14	51	25	30	11	
15	55	25	40	13	
16	49	25	45	17	
17	63	25	50	19	
18	67	25	58	18	
19	57	25	50	20	
20	58	26	40	12	
21	55	26	44	12	
22	57	26	35	10	

Rys. 4. Nieetykietowany zbiór uczący– zbiór Iris

Uczenie maszyn – podstawowe pojęcia

etykieta klasy

cechy

obiekt

	Iris Species	Sepal Length (mm)	Sepal Width (mm)	Petal Length (mm)	Petal Width (mm)
1	Versicolor	50	20	35	10
2	Versicolor	62	22	45	15
3	Versicolor	60	22	40	10
4	Virginica	60	22	50	15
5	Setosa	45	23	13	3
6	Versicolor	50	23	33	10
7	Versicolor	63	23	44	13
8	Versicolor	55	23	40	13
9	Versicolor	55	24	38	11
10	Versicolor	49	24	33	10
11	Versicolor	55	24	37	10
12	Versicolor	56	25	39	11
13	Versicolor	63	25	49	15
14	Versicolor	51	25	30	11
15	Versicolor	55	25	40	13
16	Virginica	49	25	45	17
17	Virginica	63	25	50	19
18	Virginica	67	25	58	18
19	Virginica	57	25	50	20
20	Versicolor	58	26	40	12
21	Versicolor	55	26	44	12
22	Versicolor	57	26	35	10

Rys. 5. Etykietowany zbiór uczący– zbiór Iris

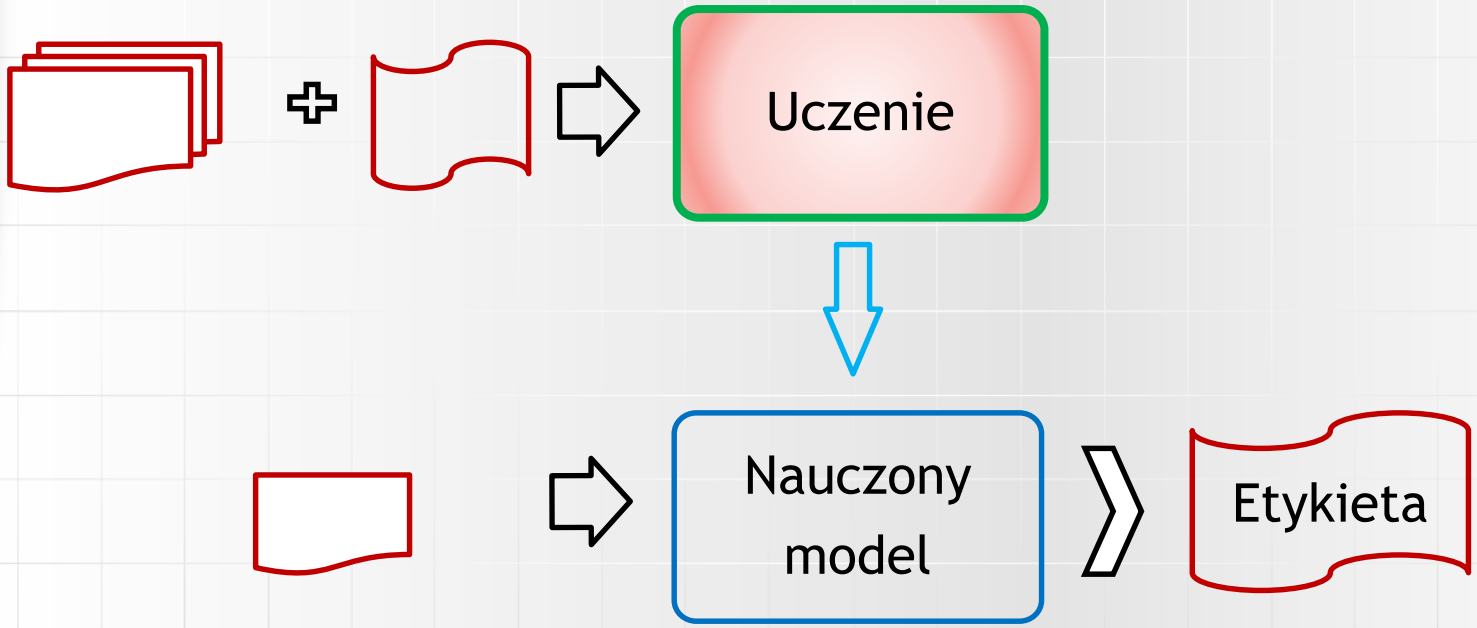
Politechnika Wrocławska

Uczenie maszyn – podstawowe pojęcia

- **Przykładowe repozytoria danych:**
  - UCI Machine Learning Respository
  - KAGGLE Machine Learning Respository
  - SNAP Datasets: Stanford Large Network Dataset Collection
  - OpenML: Open Collaborative ML Platform

Uczenie nadzorowane

Algorytm uczący korzysta z danych, w których wszystkie obiekty ze zbioru uczącego są poetykietowane (mają przypisaną etykietę klasy). Etykieta klasy jest też wyjściem algorytmu uczenia nadzorowanego.



Rys. 6. Schemat uczenia nadzorowanego

Uczenie nadzorowane

- Klasyfikacja – etykieta klasy (atrybut decyzyjny) ma wartość dyskretną (binarną, nominalną).

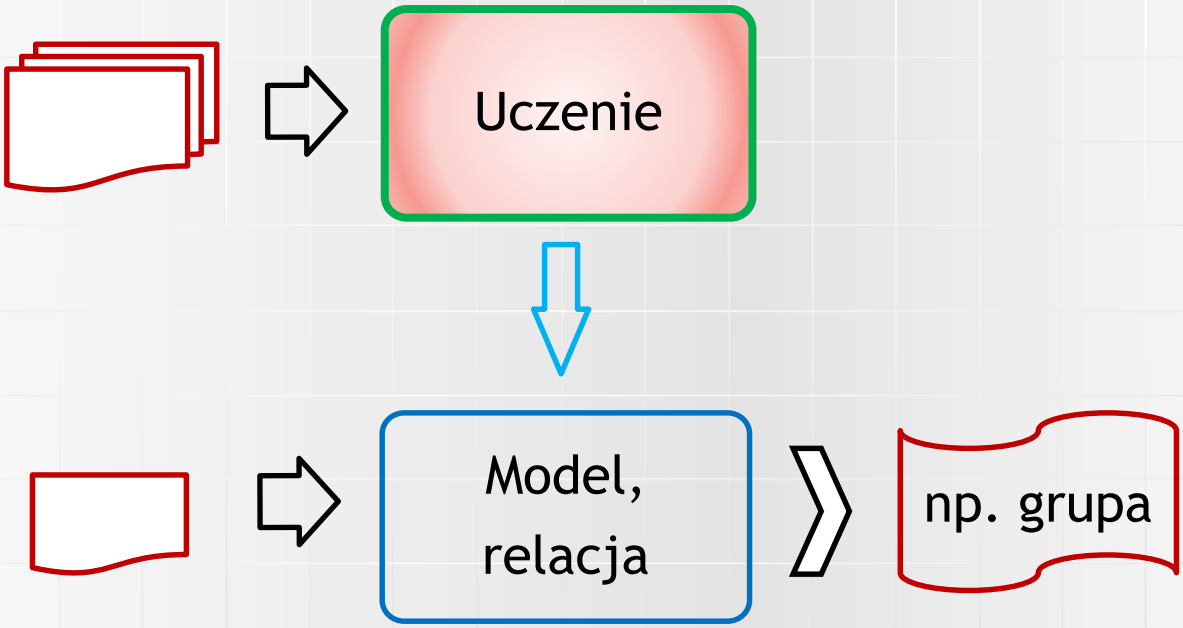
W przypadku binarnej etykiety klasy mówimy o klasyfikacji binarnej.

- Regresja, predykcja – atrybut decyzyjny jest liczbą rzeczywistą.

Celem regresji jest przewidywanie wartości numerycznej, a cechy nazywane są **czynnikami prognostycznymi, predykatorami.** Niektóre algorytmy mogą być używane do zadań regresji oraz klasyfikacji np. regresja logistyczna (przewiduje prawdopodobieństwo), sieci neuronowe.

Uczenie nienadzorowane

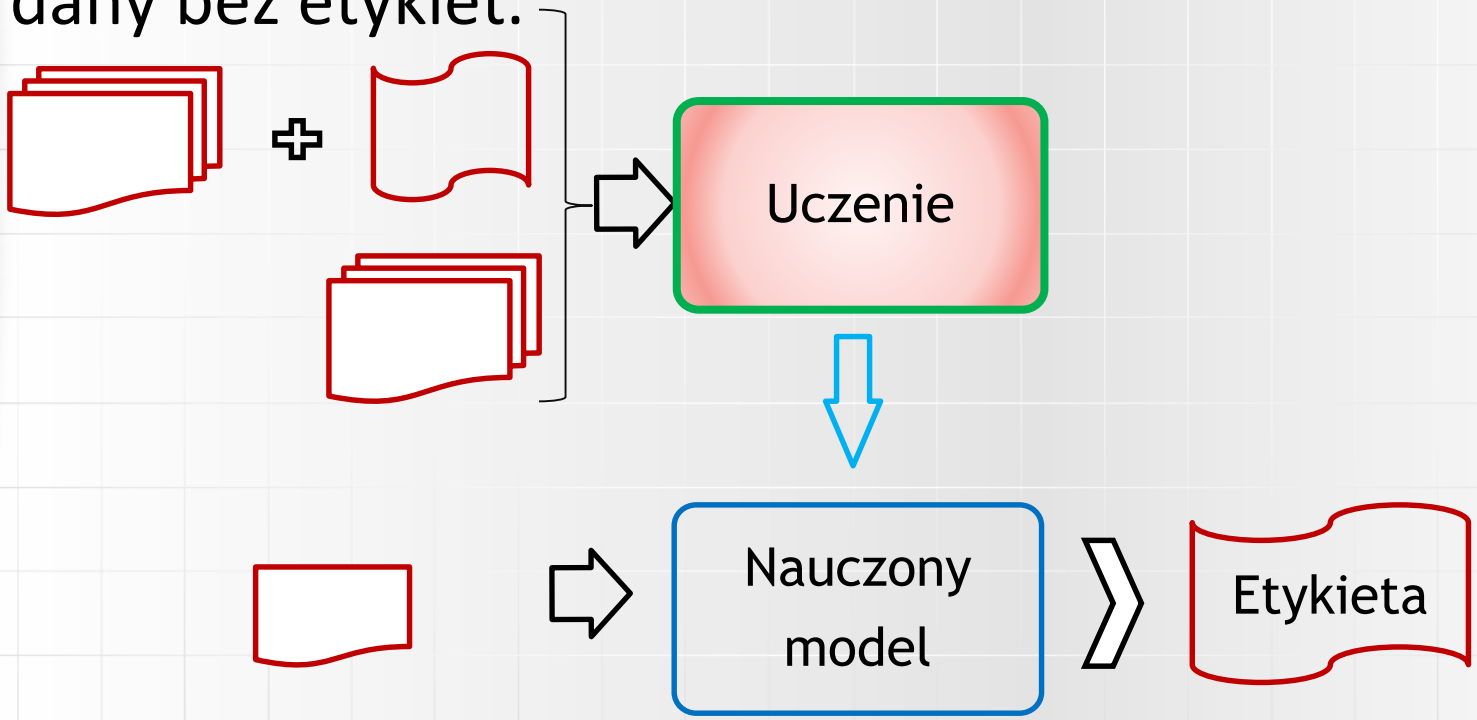
Algorytm uczący korzysta z danych, w których nie występują poetykietowane obiekty. Wzorzec, relacja, struktura, model są wynikiem działania procesu uczenia.



Rys. 7. Schemat uczenia nienadzorowanego

Uczenie częściowo nadzorowane

Połączenie uczenia nadzorowanego oraz nienadzorowanego. Algorytm uczący wykorzystuję małą porcję danych z etykietami oraz znacznie większą ilość dany bez etykiet.



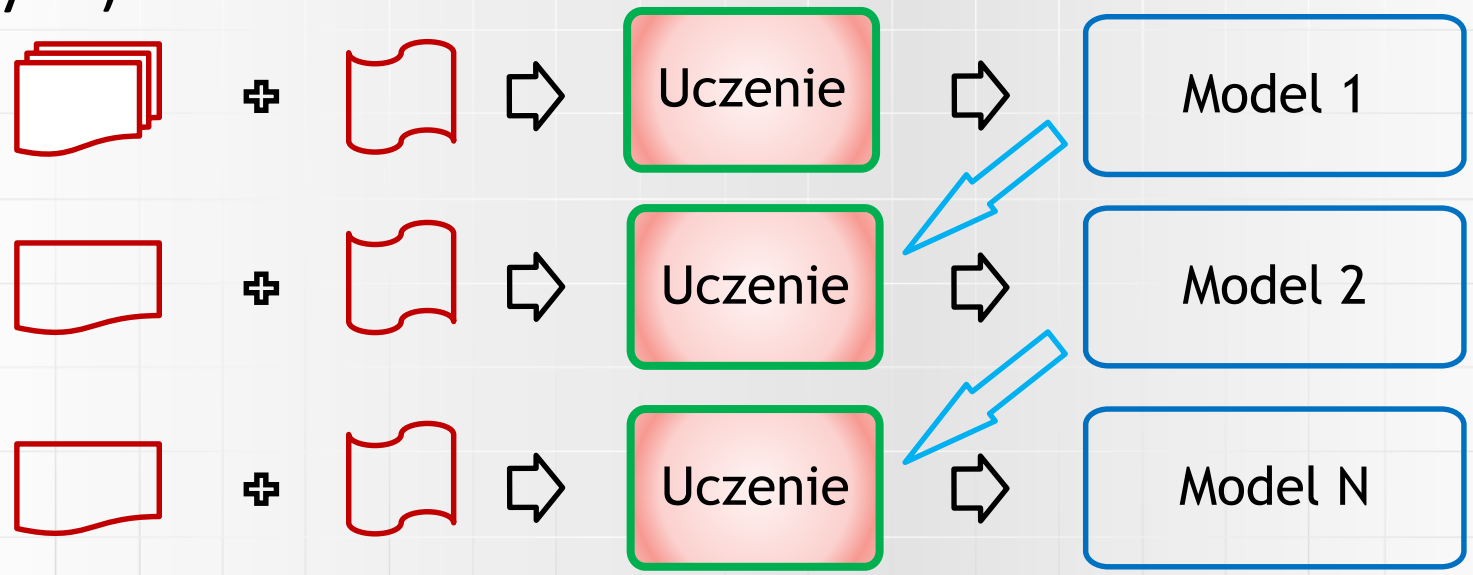
Rys. 8. Schemat uczenia częściowo nadzorowanego

Uczenie częściowo nadzorowane

- Uczenie następuje z wykorzystaniem danych poetykietowanych. Następnie, nauczony model, służy do nadania etykiet danym pierwotnie ich nie posiadającym. Kolejna faza to uczenie na całym komplecie danych.
- Głębokie sieci przekonań (ang. deep belief networks), w pierwszej kolejności bazują na ułożonych warstwowo, sekwencyjnie elementach nienadzorowanych, ograniczonych maszynach Boltzmanna (ang. restricted Boltzmann machines). Następnie cały system zostaje dostrojony przy użyciu uczenia nadzorowanego.

Uczenie przyrostowe

Model uzyskany na początku uczenia jest korygowany po otrzymaniu przez algorytm nowych danych – pojedynczych obserwacji lub pakietów (batches). Celem uczenia przyrostowego jest „szybkie” dostosowanie modelu do zmieniających się warunków (charakterystyk danych)



Rys. 8. Schemat uczenia przyrostowego

Politechnika Wrocławska

Uczenie ze wzmocnieniem

Celem uczenia ze wzmocnieniem jest uczenie się wiedzy proceduralnej, uczenie pewnych umiejętności. Algorytmowi (agentowi) uczenia nie są dostarczane dane uczące, a jedynie odpowiednia informacja trenująca, oceniające jego dotychczasową skuteczność.

Pojęcia:

- ✓ Środowisko
- ✓ Agent (uczeń)
- ✓ Stan
- ✓ Nagroda
- ✓ Akcja

Uczenie ze wzmocnieniem

Zachodzą dynamiczne interakcje ucznia (agenta) ze środowiskiem, w którym działa, realizując swoje zadanie. Interakcje te odbywają się dyskretnych (na ogół) krokach czasu i polegają na obserwowaniu przez ucznia kolejnych *stanów* środowiska oraz wykonywaniu wybranych zgodnie z jego obecną strategią decyzyjną *akcji*. Po wykonaniu akcji uczeń otrzymuje *nagrodę(y)*, które stanowią miarę oceny jakości jego działania.

Uczenie maszynowe – „czarna skrzynka”

„Użytkownicy, którzy podejmują decyzje biznesowe, wykorzystując informacje dostarczone przez systemy uczenia maszynowego, najczęściej nie chcą, by dane były prezentowane po prostu przez czarną skrzynkę. Bo im bardziej zrozumieją, co i w jaki sposób w niej działa, tym lepiej poznają, jak przebiega każdy krok w procesie przekształcenia danych w przewidywania. Wtedy wnioski prezentowane przez system będą miały większe znaczenie biznesowe”.

Computerword 20.10.2018

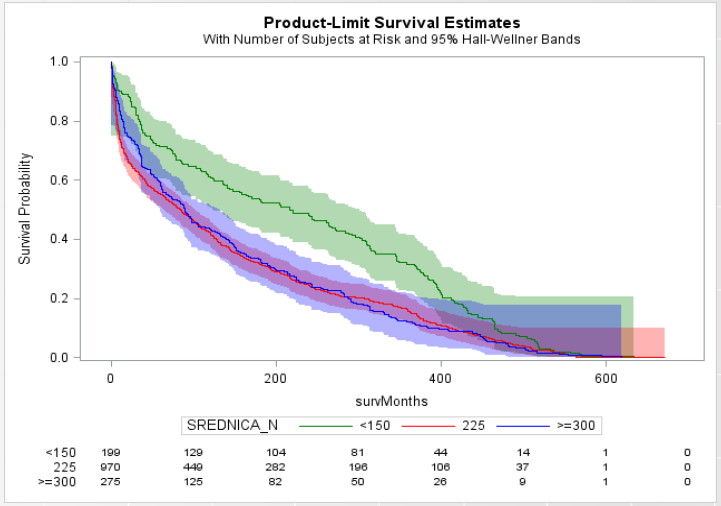
Estymator funkcji przeżycia po raz pierwszy zaproponowany został przez E. L. Kaplana i P. Meyera w 1958 roku

- W badaniach klinicznych analizujemy czas, jaki upłynie od pewnego zdarzenia np. przeprowadzenia operacji, rozpoczęcia terapii do momentu, w którym wystąpi niepowodzenie, np. zgon pacjenta.
- Długości czasu od momentu zarejestrowania się jako osoba bezrobotna do momentu znalezienia zatrudnienia – w tym przypadku krzywa przeżycia będzie przedstawiała prawdopodobieństwo pozostawania osobą bezrobotną przez obserwowanych okresów. W tym przypadku zdarzeniem nie będzie „niepowodzenia" ale „sukces" – znalezienie pracy.
- W analizie awarii może mierzyć czas do awarii urządzenia.

Estymator funkcji przeżycia po raz pierwszy zaproponowany został przez E. L. Kaplana i P. Meyera w 1958 roku

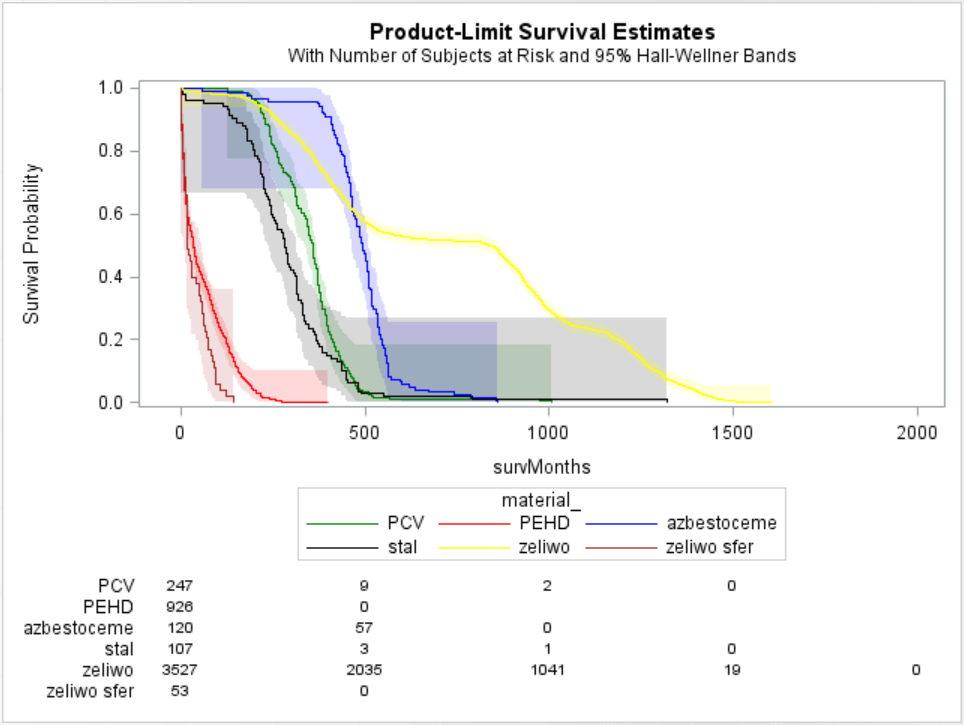
Wykonując analizę przeżycia, rozpatrujemy dwa rodzaje danych:

- Wystąpiło niepowodzenie (np. zgon pacjenta)
- W trakcie trwania obserwacji nie nastąpiło niepowodzenie – takie przypadki traktujemy jako obserwacje ucięte.

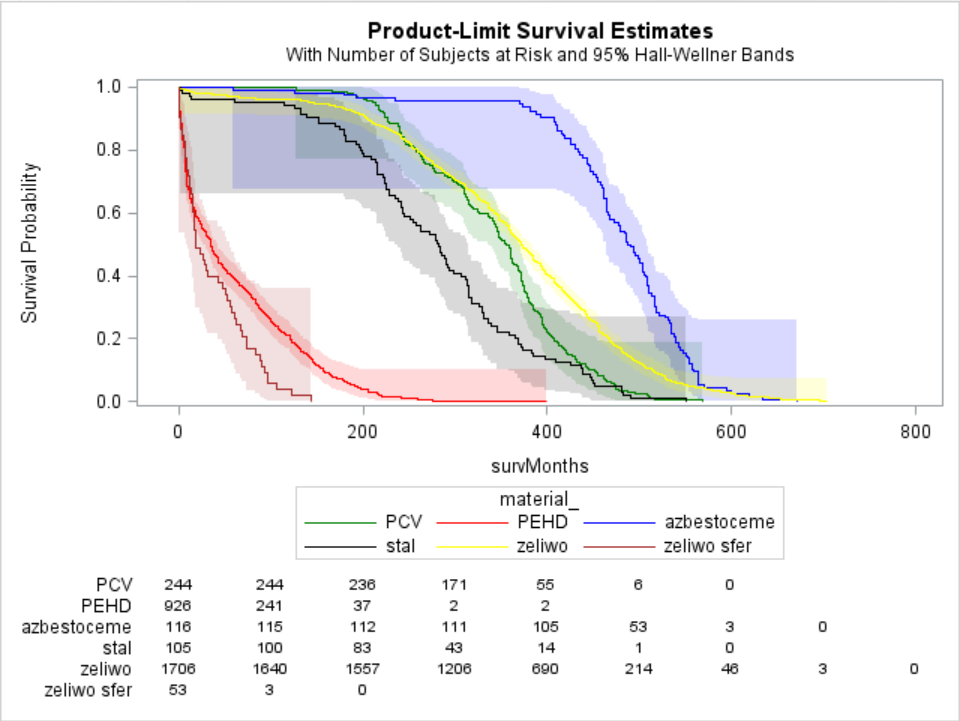


Krzywa przeżycia – kryterium podziału „średnica”

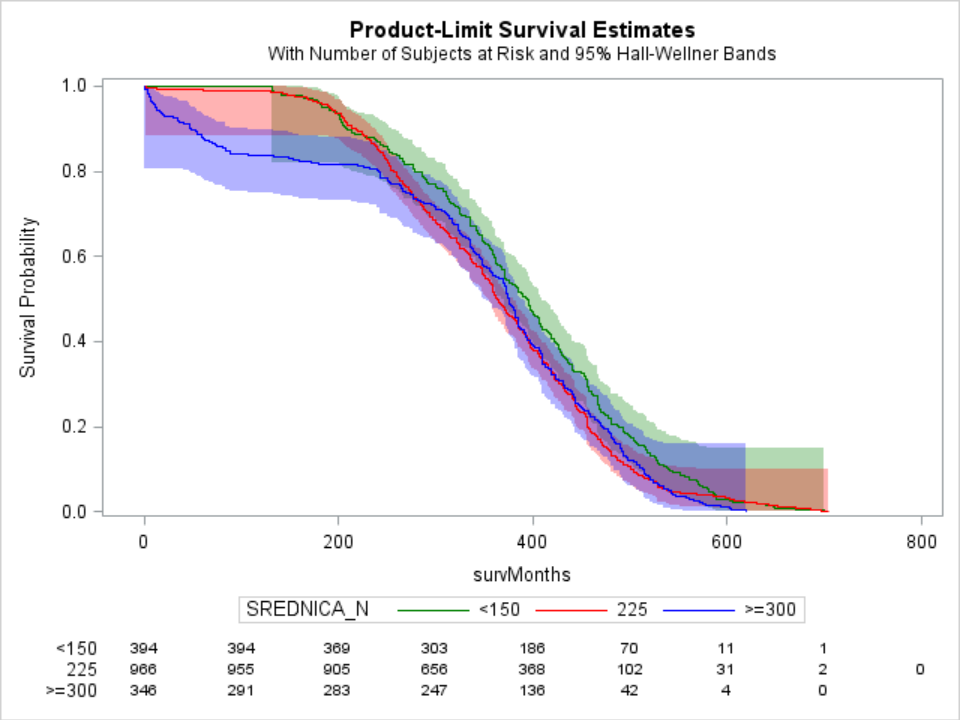
Krzywa przeżycia jest wizualną prezentacją przewidzianego przez model czasu „przeżycia” obiektu. Oś pozioma przedstawia czas do zdarzenia. Oś pionowa przedstawia prawdopodobieństwo przeżycia. W ten sposób dowolny punkt na krzywej przeżycia pokazuje prawdopodobieństwo, że „przeciętny” obiekt „przeżyje” do tego czasu.



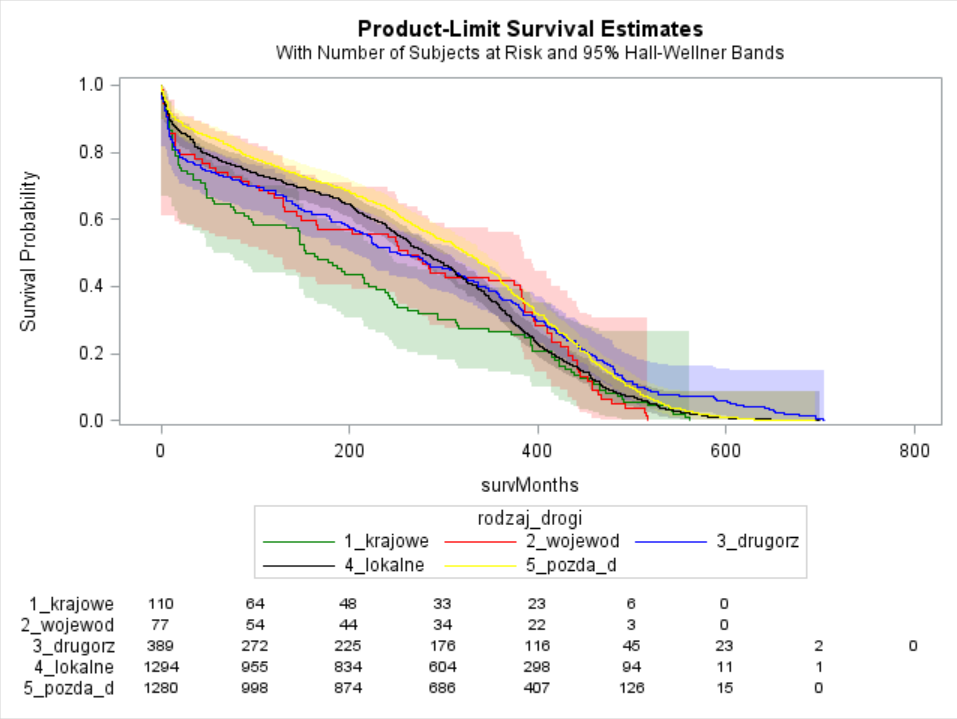
Krzywa przeżycia – kryterium podziału „materiał” (do 1913r.)



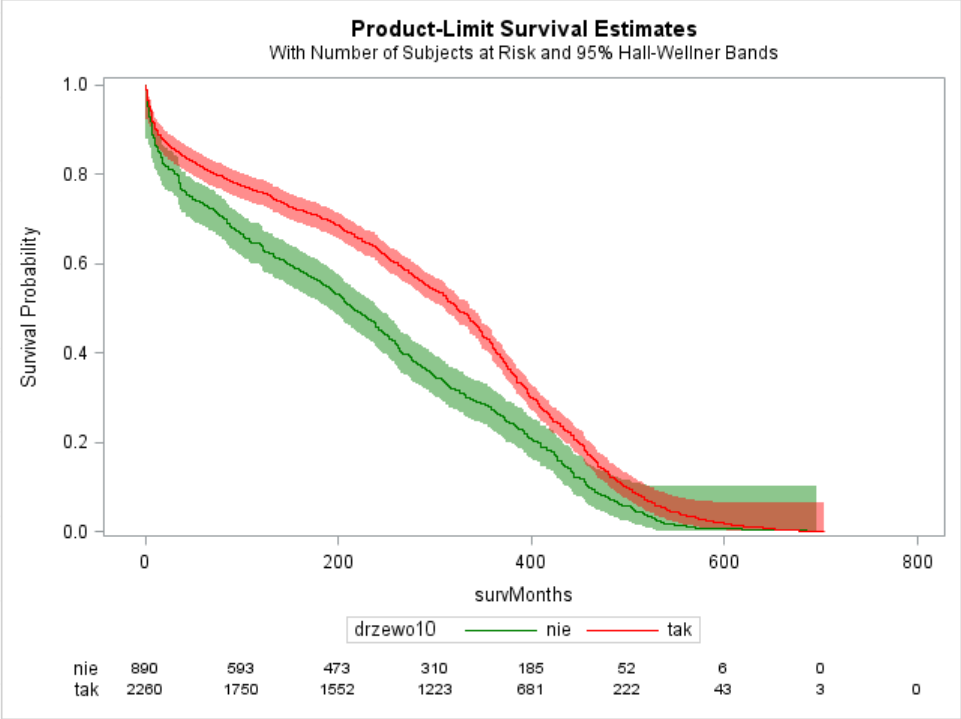
Krzywa przeżycia – kryterium podziału „materiał” (po 1950r.)



Krzywa przeżycia dla „żeliwa” kryterium podziału „średnica” (po 1950r.)



Krzywa przeżycia - kryterium podziału „droga” (po 1950r.)



Krzywa przeżycia - kryterium podziału „drzewo” (po 1950r.)

Politechnika Wrocławska

Ewaluacja modelu

Ewaluacja modelu (model evaluation) - proces sprawdzający i oceniający uzyskany model. Celem jest określenie, jak dobrze (trafnie) utworzony model spełnia swoją rolę. Rola zależna jest od typu uczenia np. dla uczenia nadzorowanego jest to etykieta klasy nowego obiektu. Ocena modelu powinna odbywać się z wykorzystaniem danych, które nie brały udziału w uczeniu.

- Miara(y), metryka, wskaźnik oceny
- Metoda(y) oceny

Ocena jakości klasyfikacji

Tab. 1. Macierz pomyłek – klasyfikacja binarna

		Klasa przewidywana		
		pozytywna (positive)	negatywna (negative)	
Klasa rzeczywista	pozytywna (positive)	**TP** (chory -> chory)	**FN** (chory -> zdrowy)	P
	negatywna (negative)	**FP** (zdrowy->chory)	**TN** (zdrowy-> zdrowy)	N
		$\hat{P}$	$\hat{N}$	

Politechnika Wrocławska

Ocena jakości klasyfikacji

Wybrane miary jakości klasyfikacji

$$Precision, PRC = \frac{TP}{\widehat{P}} \qquad Negative \quad predictive = \frac{TN}{\widehat{N}}$$

$$Specificity, SEL = \frac{TN}{N} \qquad Sensitivity, recall = \frac{TP}{P}$$

$$Accuracy\ (ACC) = \frac{TP + TN}{M}$$

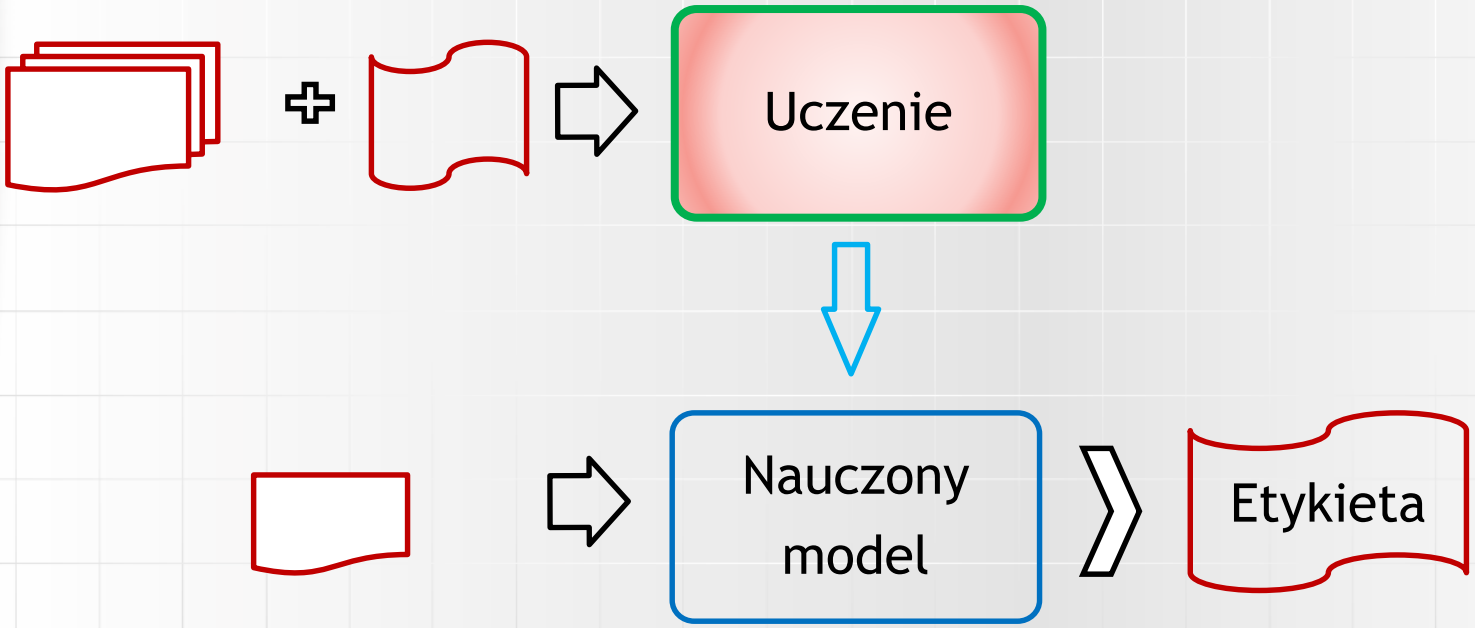
$$Balanced\ accuracy\ (BACC) = \frac{1}{2}(REC + SEL)$$

$$F_1 - score = 2\frac{PRC * REC}{PRC + REC}$$

$$G - mean = \sqrt{REC * SEL}$$

Uczenie nadzorowane

Algorytm uczący korzysta z danych, w których wszystkie obiekty ze zbioru uczącego są poetykietowane (mają przypisaną etykietę klasy). Etykieta klasy jest też wyjściem algorytmu uczenia nadzorowanego.



Rys. 6. Schemat uczenia nadzorowanego

Uczenie nadzorowane

- Klasyfikacja – etykieta klasy (atrybut decyzyjny) ma wartość dyskretną (binarną, nominalną).

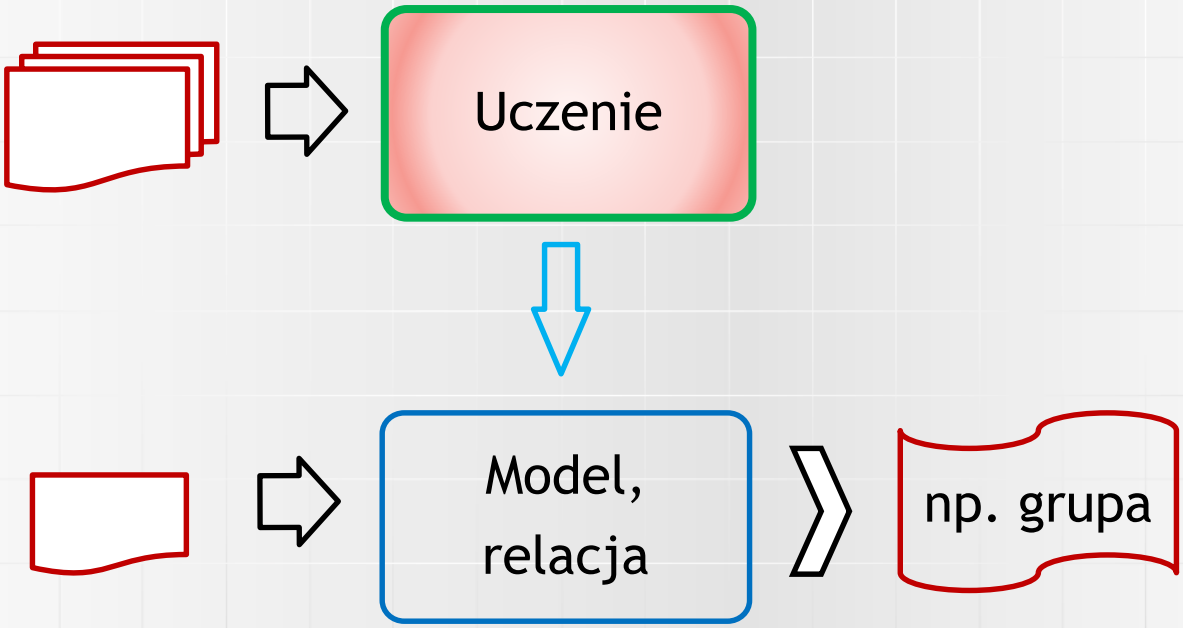
W przypadku binarnej etykiety klasy mówimy o klasyfikacji binarnej.

- Regresja, predykcja – atrybut decyzyjny jest liczbą rzeczywistą.

Celem regresji jest przewidywanie wartości numerycznej, a cechy nazywane są **czynnikami prognostycznymi, predykatorami.** Niektóre algorytmy mogą być używane do zadań regresji oraz klasyfikacji np. regresja logistyczna (przewiduje prawdopodobieństwo), sieci neuronowe.

Uczenie nienadzorowane

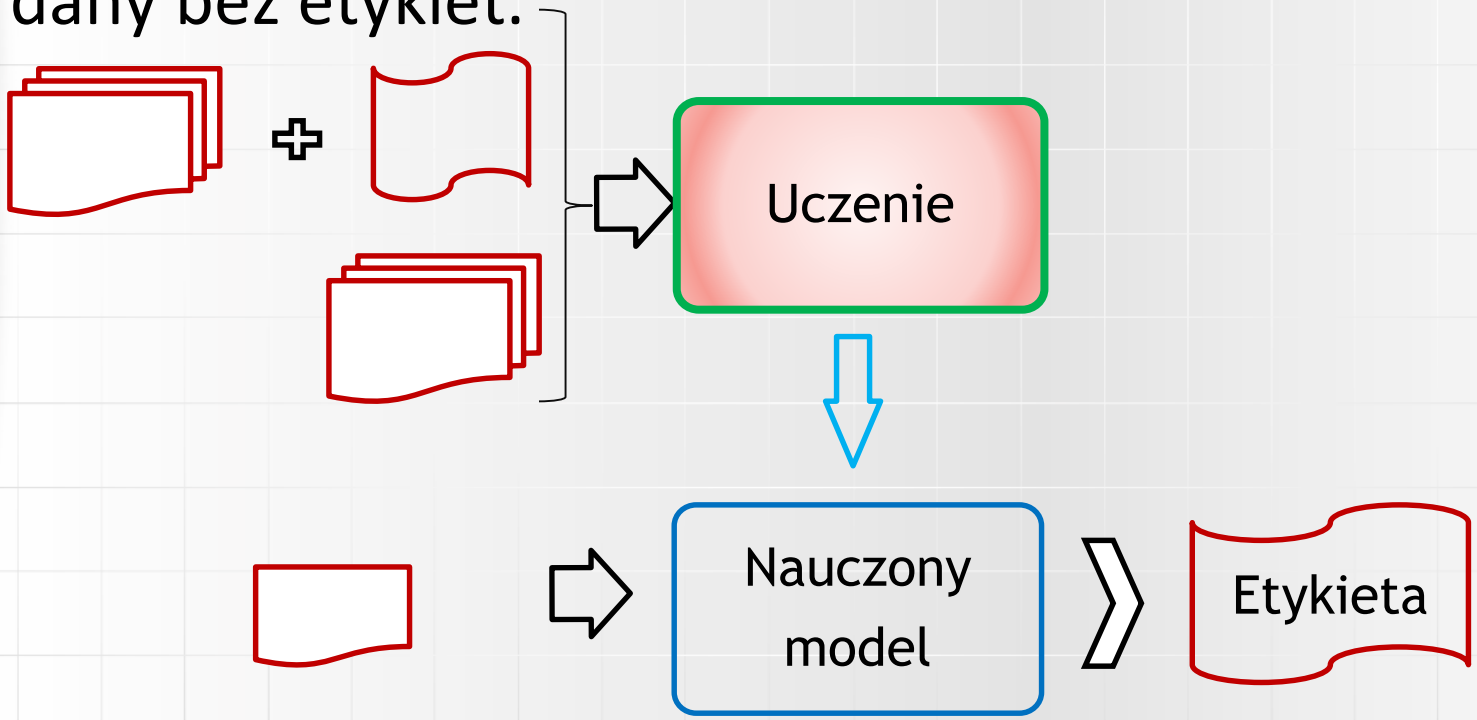
Algorytm uczący korzysta z danych, w których nie występują poetykietowane obiekty. Wzorzec, relacja, struktura, model są wynikiem działania procesu uczenia.



Rys. 7. Schemat uczenia nienadzorowanego

Uczenie częściowo nadzorowane

Połączenie uczenia nadzorowanego oraz nienadzorowanego. Algorytm uczący wykorzystuję małą porcję danych z etykietami oraz znacznie większą ilość dany bez etykiet.



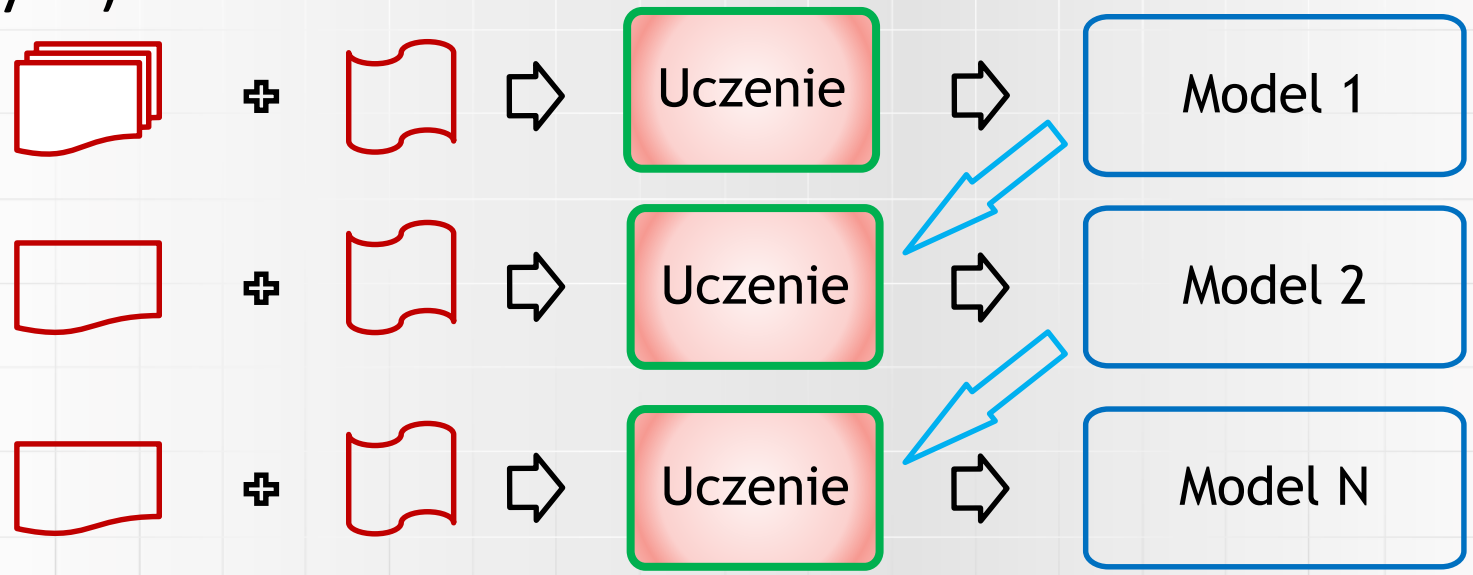
Rys. 8. Schemat uczenia częściowo nadzorowanego

Uczenie częściowo nadzorowane

- Uczenie następuje z wykorzystaniem danych poetykietowanych. Następnie, nauczony model, służy do nadania etykiet danym pierwotnie ich nie posiadającym. Kolejna faza to uczenie na całym komplecie danych.
- Głębokie sieci przekonań (ang. deep belief networks), w pierwszej kolejności bazują na ułożonych warstwowo, sekwencyjnie elementach nienadzorowanych, ograniczonych maszynach Boltzmanna (ang. restricted Boltzmann machines). Następnie cały system zostaje dostrojony przy użyciu uczenia nadzorowanego.

Uczenie przyrostowe

Model uzyskany na początku uczenia jest korygowany po otrzymaniu przez algorytm nowych danych – pojedynczych obserwacji lub pakietów (batches). Celem uczenia przyrostowego jest „szybkie” dostosowanie modelu do zmieniających się warunków (charakterystyk danych)



Rys. 8. Schemat uczenia przyrostowego

Politechnika Wrocławska

Uczenie ze wzmocnieniem

Celem uczenia ze wzmocnieniem jest uczenie się wiedzy proceduralnej, uczenie pewnych umiejętności. Algorytmowi (agentowi) uczenia nie są dostarczane dane uczące, a jedynie odpowiednia informacja trenująca, oceniające jego dotychczasową skuteczność.

Pojęcia:

- ✓ Środowisko
- ✓ Agent (uczeń)
- ✓ Stan
- ✓ Nagroda
- ✓ Akcja

Uczenie ze wzmocnieniem

Zachodzą dynamiczne interakcje ucznia (agenta) ze środowiskiem, w którym działa, realizując swoje zadanie. Interakcje te odbywają się dyskretnych (na ogół) krokach czasu i polegają na obserwowaniu przez ucznia kolejnych *stanów* środowiska oraz wykonywaniu wybranych zgodnie z jego obecną strategią decyzyjną *akcji*. Po wykonaniu akcji uczeń otrzymuje *nagrodę(y)*, które stanowią miarę oceny jakości jego działania.

Uczenie maszynowe – „czarna skrzynka”

„Użytkownicy, którzy podejmują decyzje biznesowe, wykorzystując informacje dostarczone przez systemy uczenia maszynowego, najczęściej nie chcą, by dane były prezentowane po prostu przez czarną skrzynkę. Bo im bardziej zrozumieją, co i w jaki sposób w niej działa, tym lepiej poznają, jak przebiega każdy krok w procesie przekształcenia danych w przewidywania. Wtedy wnioski prezentowane przez system będą miały większe znaczenie biznesowe”.

Computerword 20.10.2018

Ewaluacja modelu

Ewaluacja modelu (model evaluation) - proces sprawdzający i oceniający uzyskany model. Celem jest określenie, jak dobrze (trafnie) utworzony model spełnia swoją rolę. Rola zależna jest od typu uczenia np. dla uczenia nadzorowanego jest to etykieta klasy nowego obiektu. Ocena modelu powinna odbywać się z wykorzystaniem danych, które nie brały udziału w uczeniu.

- Miara(y), metryka, wskaźnik oceny
- Metoda(y) oceny

Ocena jakości klasyfikacji

Tab. 1. Macierz pomyłek – klasyfikacja binarna

		Klasa przewidywana		
		pozytywna (positive)	negatywna (negative)	
Klasa rzeczywista	pozytywna (positive)	**TP** (chory -> chory)	**FN** (chory -> zdrowy)	P
	negatywna (negative)	**FP** (chory-> zdrowy)	**TN** (zdrowy-> zdrowy)	N
		$\hat{P}$	$\hat{N}$	

Politechnika Wrocławska

Ocena jakości klasyfikacji

Wybrane miary jakości klasyfikacji

$$Precision, PRC = \frac{TP}{\widehat{P}} \qquad Negative \quad predictive = \frac{TN}{\widehat{N}}$$

$$Specificity, SEL = \frac{TN}{N} \qquad Sensitivity, recall = \frac{TP}{P}$$

$$Accuracy\ (ACC) = \frac{TP + TN}{M}$$

$$Balanced\ accuracy\ (BACC) = \frac{1}{2}(REC + SEL)$$

$$F_1 - score = 2\frac{PRC * REC}{PRC + REC}$$

$$G - mean = \sqrt{REC * SEL}$$

Drzewo decyzyjne

Klasyfikacja



jednoetapowa

Pojedynczy proces decyzyjny.

sekwencyjna

Decyzja rozłożona na szereg prostszych decyzji;
w różnych etapach wykorzystywane są różne cechy i uwzględniane różne podzbiory klas. Schemat działania klasyfikatora można przedstawić jako drzewo decyzyjne

Drzewo decyzyjne

Dana jest baza danych przykładów, z których każdy należy do określonej klasy, zgodnie z wartością atrybutu decyzyjnego. Celem klasyfikacji jest znalezienie modelu dla każdej klasy

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Drzewo decyzyjne

Drzewo decyzyjne jest grafem o strukturze drzewiastej, gdzie

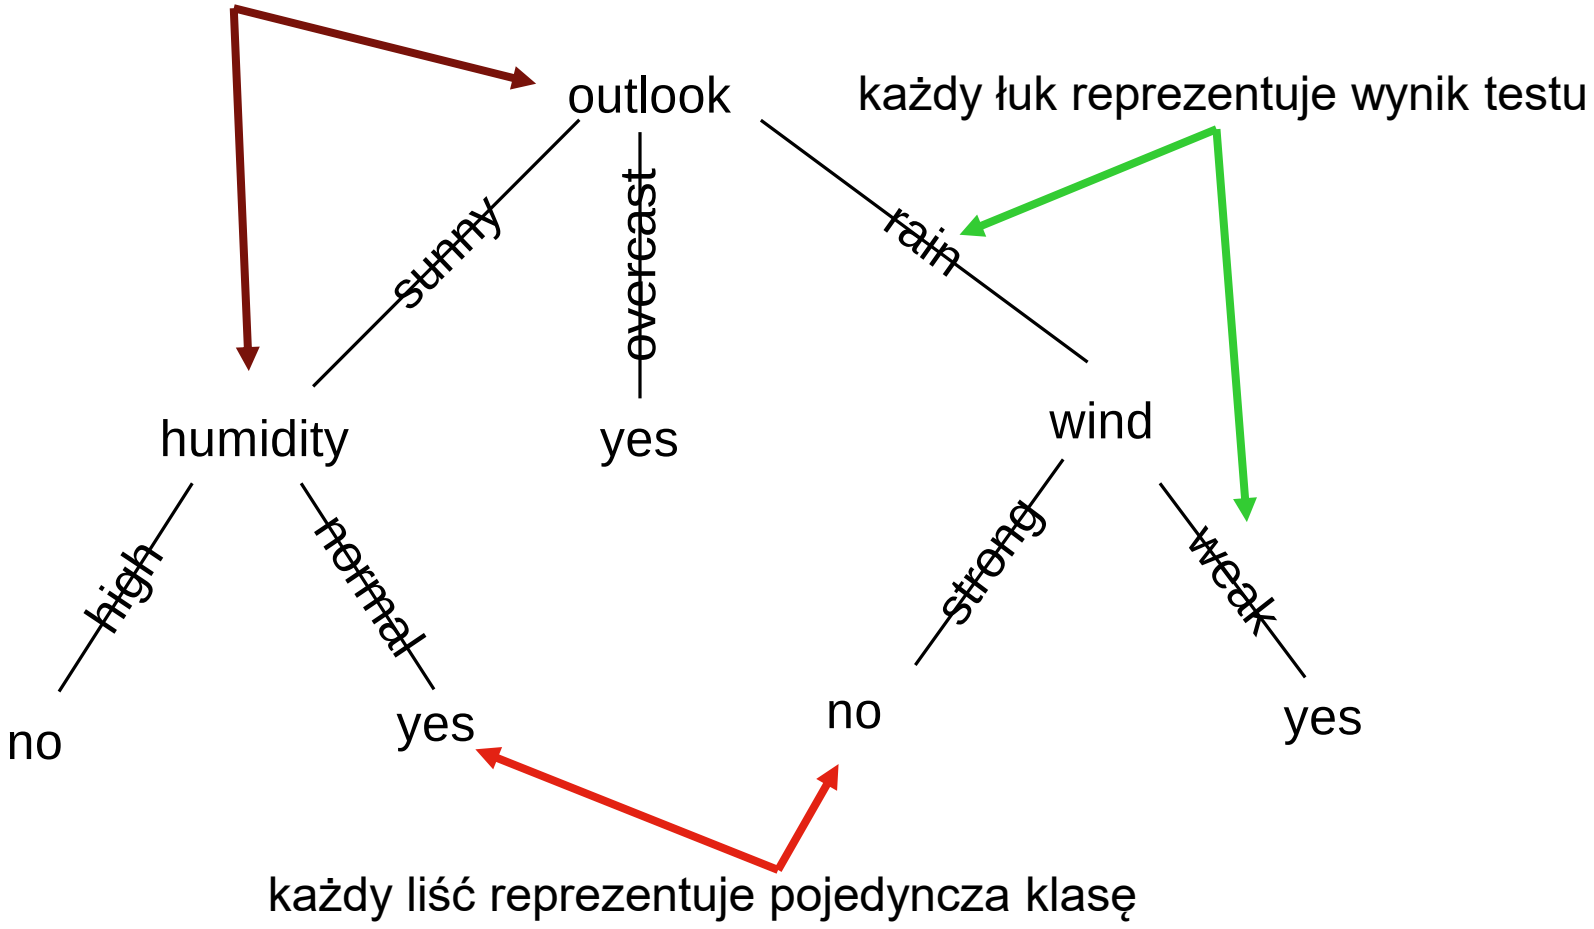
– każdy wierzchołek wewnętrzny reprezentuje test na atrybucie (atrybutach),

– każdy łuk reprezentuje wynik testu,

– każdy liść reprezentuje pojedyncza klasę lub rozkład wartości klas

Drzewo decyzyjne

każdy wierzchołek wewnętrzny reprezentuje test na atrybucie (atrybutach),



Drzewo decyzyjne

Oferują łatwe przejście do reprezentacji regułowej, np. dla przykładu „Play Tenis” można wygenerować następujące reguły:

if outlook = sunny and humidity = high then PlayTenis = yes

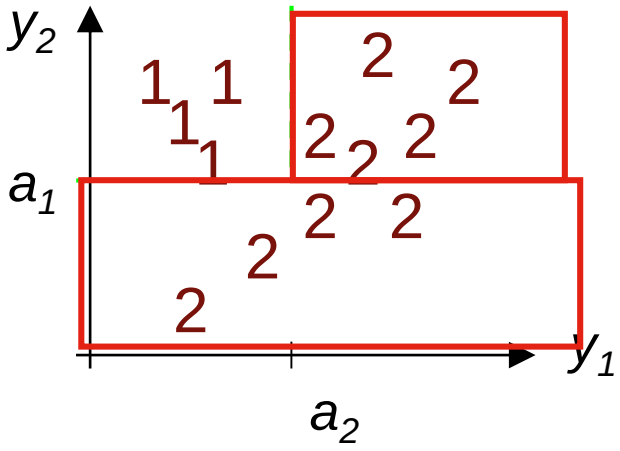
if outlook = sunny and humidity = normal then PlayTenis = no

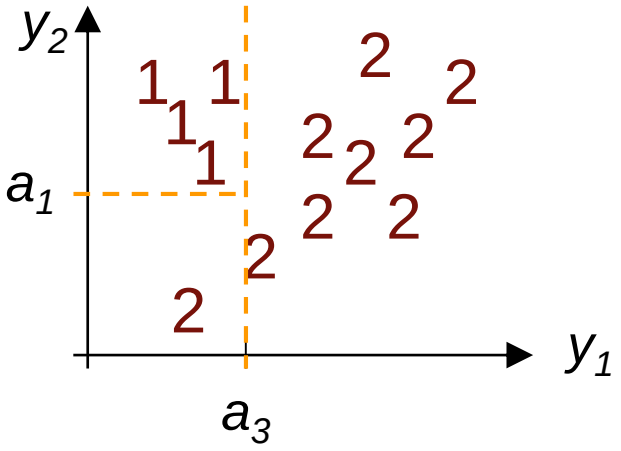
if outlook = overcast then PlayTenis = yes

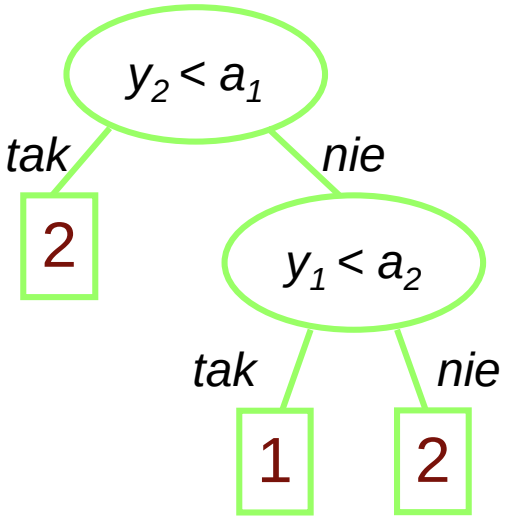
if outlook = rain and wind = strong then PlayTenis = no

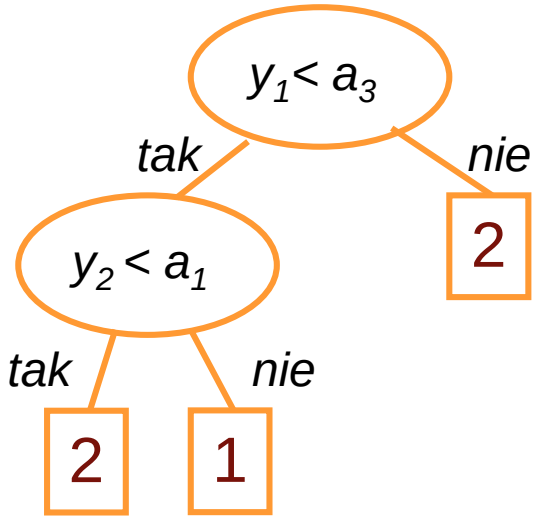
if outlook = rain and wind = weak then PlayTenis = yes

Drzewo decyzyjne









Drzewo decyzyjne

Indukcja drzew decyzyjnych to przeszukiwanie przestrzeni hipotez

Przerwanie rozbudowy drzewa, gdy spełniony jest jeden z poniższych warunków:

- liczba błędnie klasyfikowanych obrazów jest mniejsza niż ustalony próg;
- liczba obrazów w węźle jest mniejsza niż ustalony próg;
- drzewo osiągnęło maksymalny dopuszczalny rozmiar (maksymalna liczba węzłów lub maksymalna wysokość).

Data mining - cel?

- **klasyfikacja**/regresja
- grupowanie
- reguły asocjacyjne
- analiza przebiegów czasowych
- wykrywanie zmian i odchyleń
- analiza połączeń (eksploracja Web'u)

Reguły asocjacyjne

Analiza koszykowa (market basket analysis) ma swoje początki w analizie „koszyków" zakupów.

Umożliwia wykrycie logicznych reguł występujących między zmiennymi w zbiorze danych. Analiza polega na identyfikacji pozycji, które występują razem.



Reguły asocjacyjne

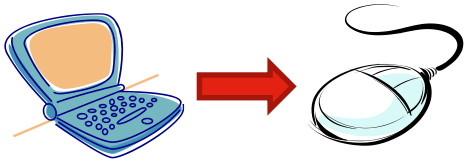
- Znalezienie mierzalnego sposobu na określenie, które produkty i jak często został zakupione wraz z innymi.
- Odkrycie, które produkty traktować jako "nierozerwalnie" połączone ze sobą.
- Które produkty nie są kupowane „razem"
- Jakie jest prawdopodobieństwo, że klienci którzy kupili produkt A, kupią również produkt B?



Reguły asocjacyjne

- Reguła asocjacyjna to implikacja postaci :

$$X \rightarrow Y$$



gdzie X, Y są obiektami w bazie.

Jeżeli [poprzednik], to [następnik]

- Stosowane wskaźniki statystyczne:
  - wsparcie (ważność - support)
  - zaufanie (siła - confidence)
  - przyrost (lift)



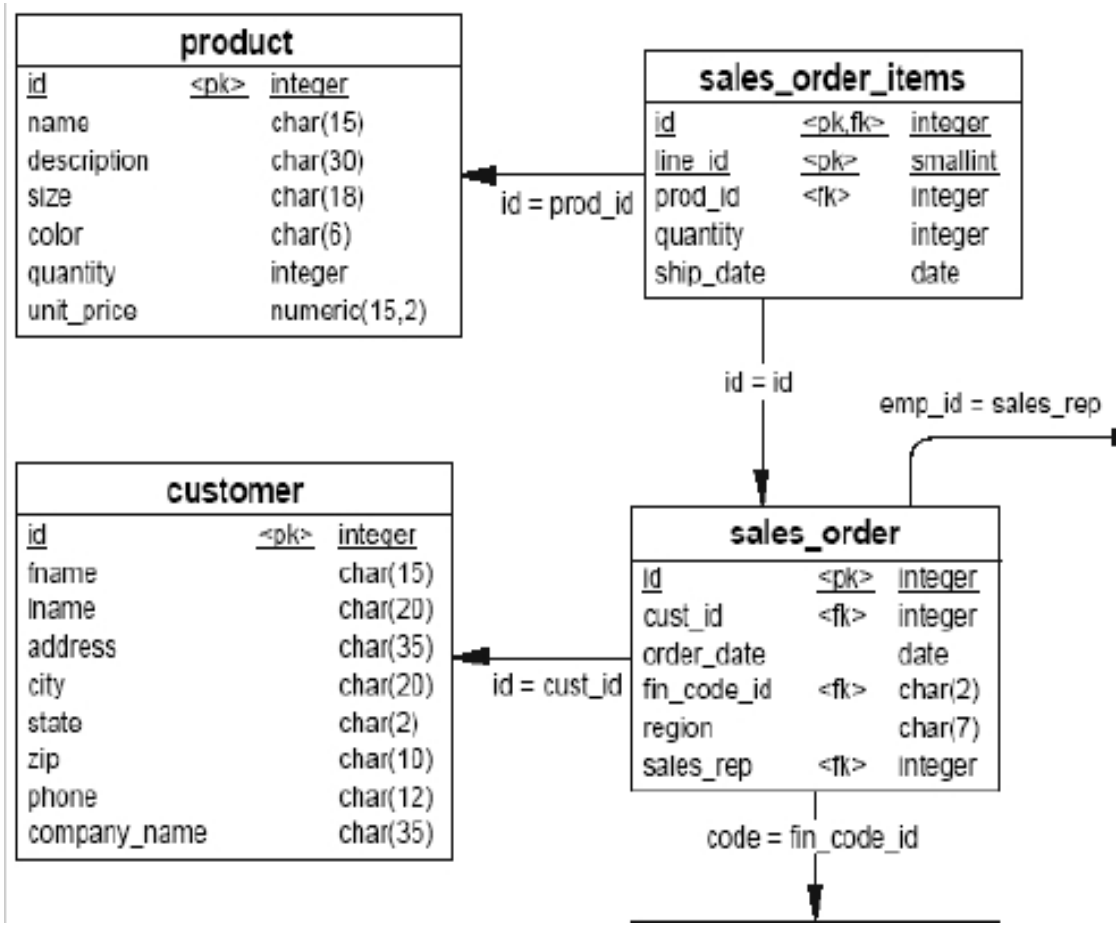
Reguły asocjacyjne

- Model danych dla reguł asocjacyjnych



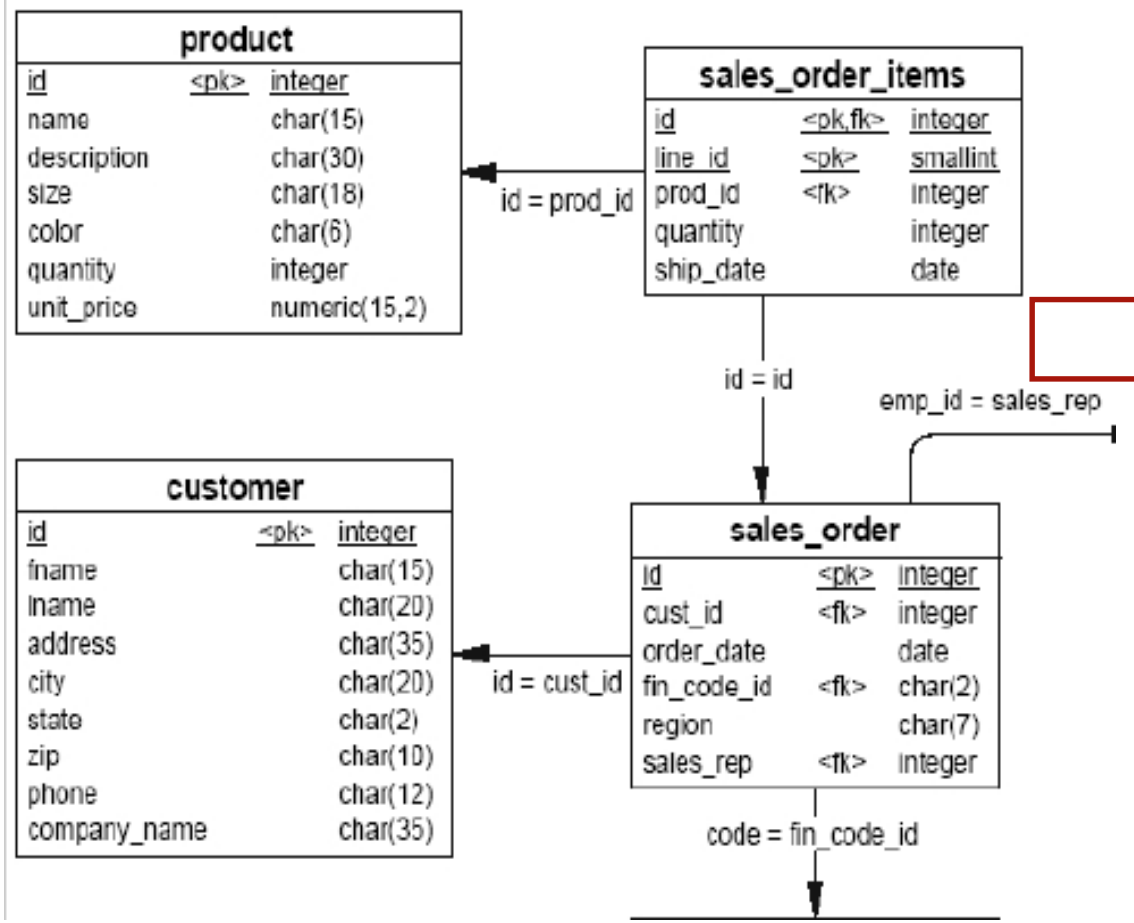
Reguły asocjacyjne

- Model BD



Reguły asocjacyjne

- Model BD



Model reguł asocjacyjnych

Nr tr.	produkt
1	komputer
1	myszka
2	komputer
2	drukarka
3	komputer
3	myszka
4	drukarka
5	komputer
5	myszka
5	Pen drive

Reguły asocjacyjne

- Model macierzowy

Nr tr.	Komp	Mysz	PEN	Druk
1	1	1	0	0
2	1	0	0	1
3	1	1	0	0
4	0	0	0	1
5	1	1	1	0



Model reguł asocjacyjnych

Nr tr.	produkt
1	komputer
1	myszka
2	komputer
2	drukarka
3	komputer
3	myszka
4	drukarka
5	komputer
5	myszka
5	Pen drive

Reguły asocjacyjne

- Wsparcie (support) określa globalny udział reguły we wszystkich transakcjach.
- Wyraża, jak często w rozważanym zbiorze przykładów występuje sytuacja opisana przez regułę.
- Częstość występowania jednocześnie poprzednika i następnika.

$$w(X \rightarrow Y) = \frac{n(X \cup Y)}{N}$$

Reguły asocjacyjne

- Zaufanie (confidence) określa występowanie danej reguły do wszystkich tych, gdzie występował zbiór początkowy.
- Jak często wystąpienie wartości warunkujących (poprzednik reguły) faktycznie pociąga za sobą wystąpienie wartości warunkowanych (następnik reguły).

$$z(X \rightarrow Y) = \frac{n(X \cup Y)}{n(X)}$$

Reguły asocjacyjne

Przyrost (lift) określa czy fakt wystąpienia jednego obiektu wpływa na zwiększenie prawdopodobieństwa wystąpienia drugiego obiektu

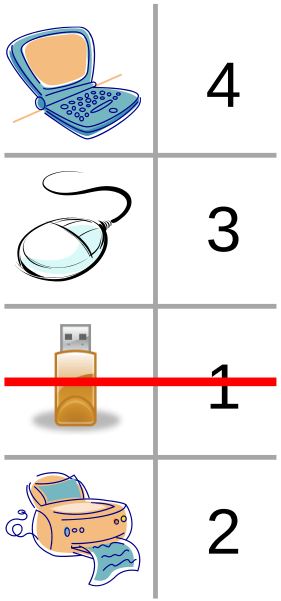
$$l1(X \rightarrow Y) = \frac{n(X \cup Y)}{n(X) * n(Y)}$$

$$l2(X \rightarrow Y) = \frac{z(X \rightarrow Y)}{n(Y)}$$

Reguły asocjacyjne

- ✓ zbiory 1-elementowe, wraz z liczbą występowania
- ✓ odrzucenie zbiorów nieczęstych





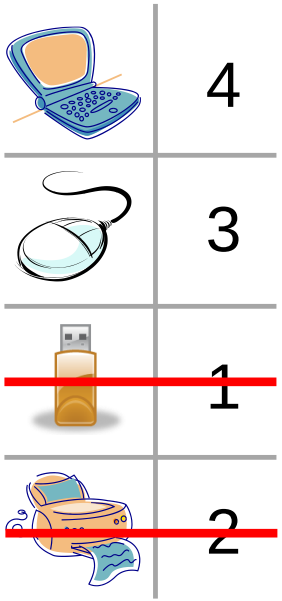
Zbiór A jest częsty, gdy występuje w transakcjach przynajmniej pewną ustaloną minimalną liczbę razy

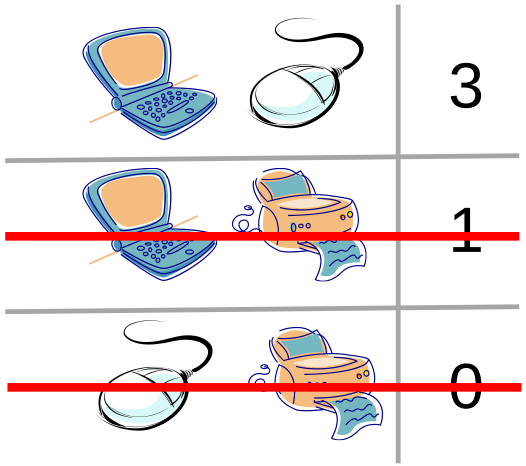
- Znajdź wszystkie zbiory częste .
- Na podstawie częstych zdarzeń utwórz reguły asocjacyjne, które spełniają warunek minimalnego wsparcia i poziomu ufności.

Reguły asocjacyjne

- ✓ zbiory 1-elementowe, wraz z liczbą występowania
- ✓ odrzucenie zbiorów nieczęstych
- ✓ zbiory 2-elementowe, wraz z liczbą występowania
- ✓ odrzucenie zbiorów nieczęstych







Reguły asocjacyjne





wsparcie = 3/5 (60%)

zaufanie = 3/4 (75%)

przyrost = 0,6 / (0,6*0,8) – 1,25



wsparcie = 3/5 (60%)

zaufanie = 3/3 (100%)

przyrost = 0,6 / (0,6*0,8) – 1,25

Reguły asocjacyjne

- Przykładowa reguła:

  <cola>⇒ <paluszki, chipsy>

o wsparciu 10% oraz zaufaniu 80% oznacza, że:

  - 80% ludzi, którzy kupili cole, kupili również paluszki i chipsy,
  - sytuacja ta zachodzi w 10% wszystkich transakcji w sklepie.

Odkrywanie wzorców sekwencji

Analiza sekwencji – w odróżnieniu od ogrywania asocjacji, ważny jest odstęp czasowy między następnikiem i poprzednikiem. Uwzględnia zatem zachowania się w „czasie".

Dla zastosowań analizy koszykowej, oznacza, że ważna jest kolejność występowania pozycji w poszczególnych koszykach.

Odkrywanie wzorców sekwencji

Np. analiza sekwencji w poruszaniu się po stronach www.
Analiza tego typu ułatwia zrozumienie zachowań odwiedzających serwis, daje wskazówki do doskonalenia struktury witryny (np. skracanie ścieżek docierania do określonych stron, eliminacja niewykorzystywanych linków), ułatwia dobór dynamicznie generowanej zawartości strony w oparciu o charakterystyczne zachowania odwiedzających, umożliwia zrozumienie sekwencji zakupów w e-sklepie itp.

Odkrywanie wzorców sekwencji

ID_P	ID_R	Data	ID_leku
105	112	26.01	30
105	114	28.01	90
106	115	10.02	30
106	113	26.01	20
106	116	8.03	70
106	116	8.03	60
106	116	8.03	40
200	117	8.03	30
200	117	9.03	50
200	117	9.03	70
220	118	9.03	30
300	119	10.03	90
220	120	15.03	40
220	120	15.03	70
220	121	15.03	90

Ile jest wszystkich sekwencji ?

Wsparcie 0,4 dla sekwencji:

30 -> 40

30-> 90

30 -> 40 i 70

Jakie wsparcie dla sekwencji

30 -> 70

Odkrywanie wzorców sekwencji

ID_P	ID_R	Data	ID_leku
105	112	26.01	30
105	114	28.01	90
106	115	10.02	30
106	113	26.01	20
106	116	8.03	70
106	116	8.03	60
106	116	8.03	40
200	117	8.03	30
200	117	9.03	50
200	117	9.03	70
220	118	9.03	30
300	119	10.03	90
220	120	15.03	40
220	120	15.03	70
220	121	15.03	90

Ile jest wszystkich sekwencji ?

Wsparcie 0,4 dla sekwencji:

30 -> 40

30-> 90

30 -> 40 i 70

Jakie wsparcie dla sekwencji

30 -> 70

Odkrywanie wzorców sekwencji

ID_P	ID_R	Data	ID_leku
105	112	26.01	30
105	114	28.01	90
106	115	10.02	30
106	113	26.01	20
106	116	8.03	70
106	116	8.03	60
106	116	8.03	40
200	117	8.03	30
200	117	9.03	50
200	117	9.03	70
220	118	9.03	30
300	119	10.03	90
220	120	15.03	40
220	120	15.03	70
220	121	15.03	90

Ile jest wszystkich sekwencji ?

Wsparcie 0,4 dla sekwencji:

30 -> 40

30-> 90

30 -> 40 i 70

Jakie wsparcie dla sekwencji

30 -> 70

Test t-Studenta (dane zależne)

- test weryfikujący hipotezę o równości średnich pomiaru (wartości średnich danej metryki)
- test parowy
- poziom istotności p (p-value) – jest to prawdopodobieństwo błędu związanego z odrzuceniem hipotezy H0 jeśli ta hipoteza byłaby prawdziwa

Test t-Studenta (dane zależne)

Hipoteza ***H0***: średnie wartości metryki nie różnią się statystycznie

Hipoteza ***H1:*** średnie wartości metryki różnią się statystycznie

Jeśli przyjmujemy H1 to do wskazania modelu można posłużyć się wartością średnią metryki

Test t-Studenta (dane zależne)

Nr	K1	K2
1	0,209	0,2
2	0,191	0,174
3	0,035	0,035
4	0,052	0,043
5	0,174	0,183
6	0,13	0,122
7	0,191	0,183
8	0,191	0,2
9	0,148	0,139
10	0,174	0,165
Średnia	0,1495	0,1444

p > 0,1 – nie znaczące
p <= 0,1 – mało znaczący
p <= 0,05 – znaczący
p<= 0,01 – silnie znaczący

W przykładzie **p=0,088**

Przykładowe dane oraz interpretacja wyniku test t-Studenta

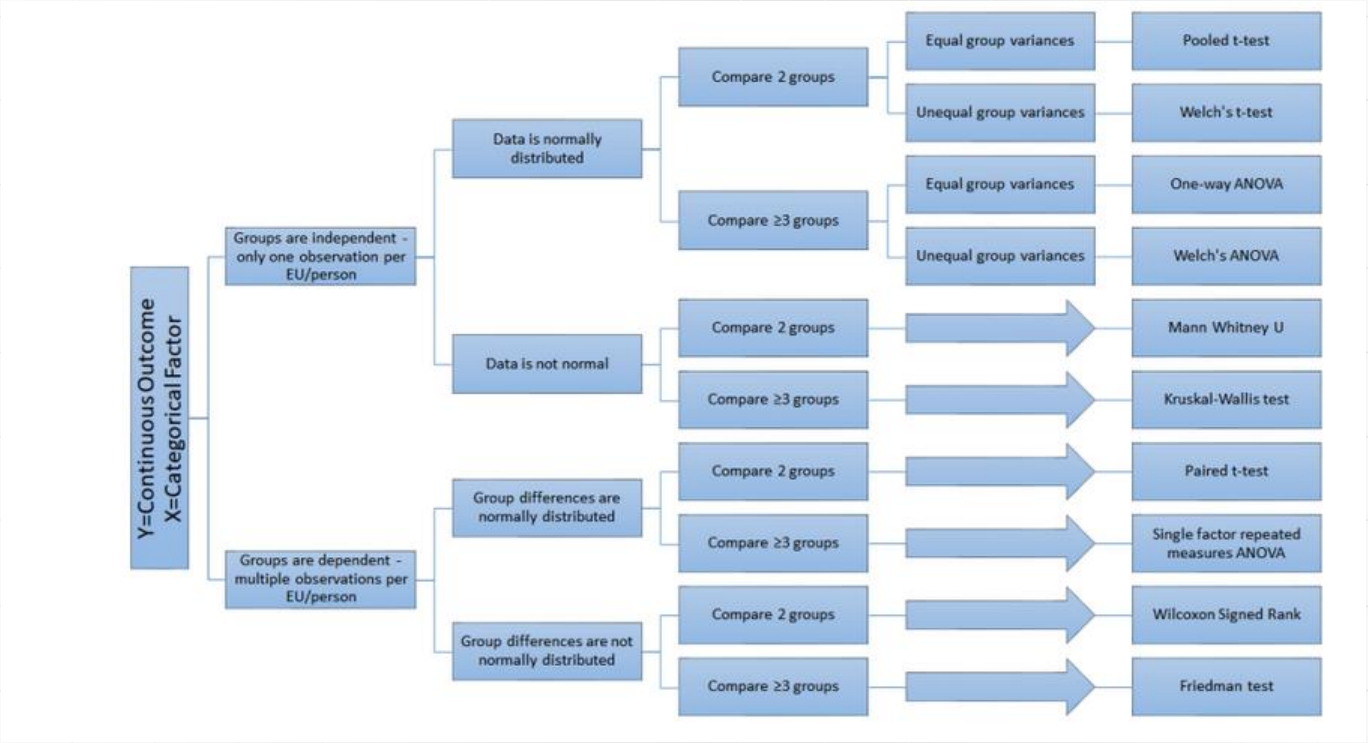
Test Wicoxona – rank znakowanych

- Zastosowanie – porównanie dwóch klasyfikatorów na wielu zbiorach danych
- nieparametryczny odpowiednik testu t-Studenta dla prób zależnych
- rangi znakowane – zliczane są rangi dla poszczególnych znaków, czyli różnic ujemnych i dodatnich dwóch odpowiadających sobie obserwacji
- w przypadku liczby obserwacji większej niż 25 i spełnionym założeniu normalności rozkładów zaleca się stosowanie testu t-Studenta

Test Wicoxona – rank znakowanych

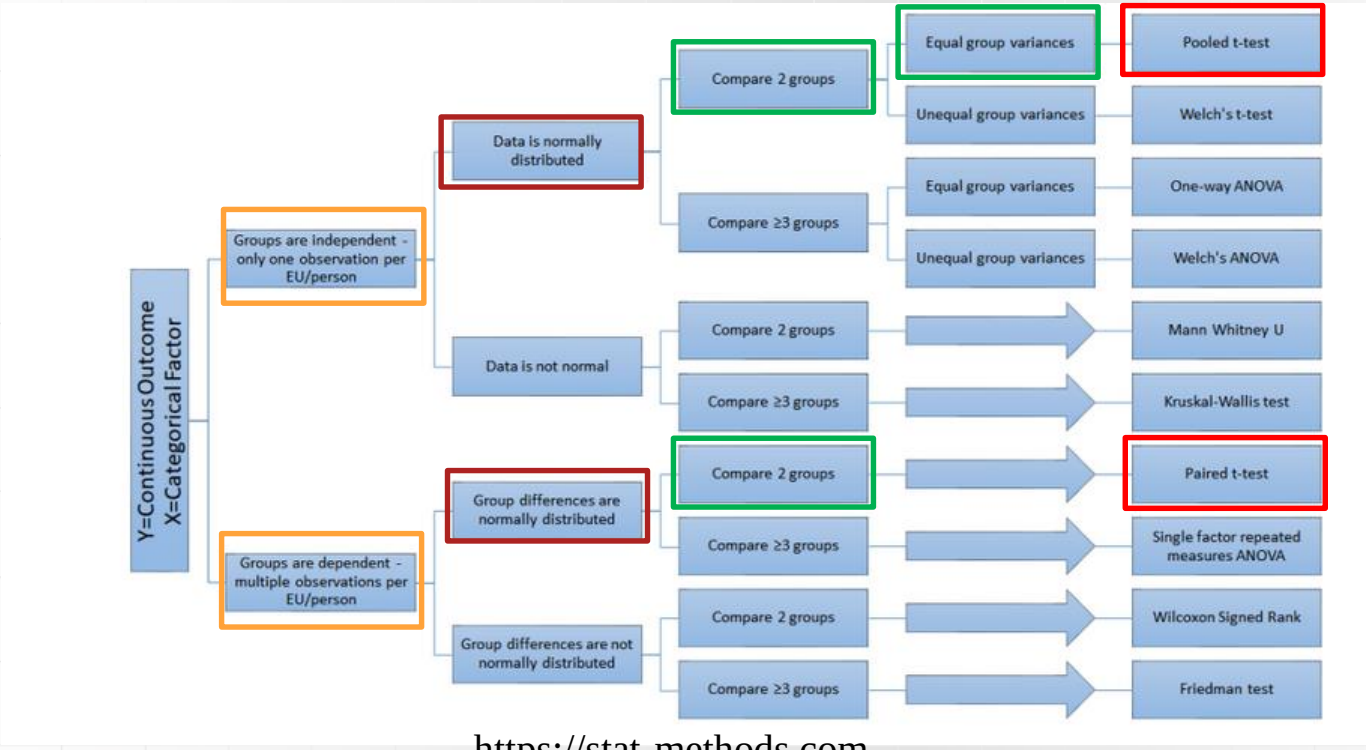
- wyznaczenie różnić między pierwszym a drugim pomiarem – różnic wartości metryk
- wyznaczenie rang dodatnich (różnica dodatnia) oraz rang ujemnych (różnica ujemna)
- niezależne sumowanie rang dodatnich oraz ujemnych
- wyznaczenie minimum z dwóch sum – statystyka testowa
- odczytanie z tablic testu Wilcoxona wartości krytycznej, porównanie z otrzymaną statystyką testową (lub statystyka Z)

Schemat wyboru testów statystycznych



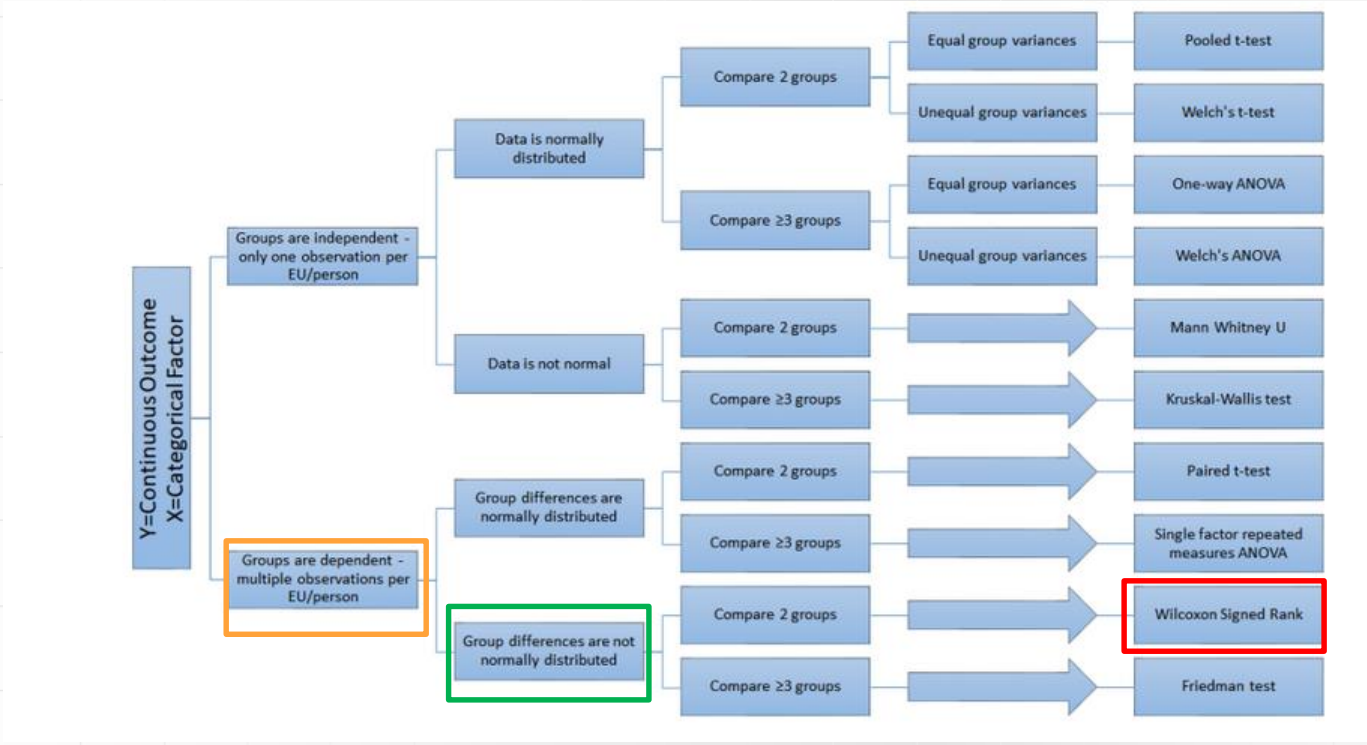
https://stat-methods.com

Schemat wyboru testów statystycznych



https://stat-methods.com

Schemat wyboru testów statystycznych



https://stat-methods.com

Test Wicoxona – rank znakowanych

N	Poziom istotności, kierunek określony		
	0,025	0,01	0,005
	Poziom istotności, kierunek nieokreślony		
	0,05	0,02	0,01
6	0	-	-
7	2	0	-
8	4	2	0
9	6	3	2
10	8	5	3
11	11	7	5
12	14	10	7
13	17	13	10
14	21	16	13
15	25	20	16

Test Wicoxona – rank znakowanych

ZD	K1	K2	Różnica	Ranga
Z1	0,863	0,868	0,005	3,5
Z2	0,599	0,591	-0,008	6
Z3	0,854	0,871	0,017	8
Z4	0,628	0,661	0,033	12
Z5	0,881	0,902	0,021	9,5
Z6	0,936	0,931	-0,005	3,5
Z7	0,763	0,769	0,006	5
Z8	0,583	0,583	0	1,5
Z9	0,775	0,838	0,063	14
Z10	1	1	0	1,5
Z11	0,95	0,972	0,022	11
Z12	0,719	0,766	0,047	13
Z13	0,872	0,881	0,009	7
Z14	0,857	0,878	0,021	9,5

R+ = 3,5+8+12+9,5+5+
1,5+14+11+13+7+9,5=
= 98,5

R – = 6+3,5+1,5 = 11

Stat. Test.: T= min{R+,R –}=11

Z tablic: 21, dla
N=14
poziomu istot. 0,05

Odrzucamy H0 – (11<21)

Przykładowe dane oraz interpretacja wyniku test Wilcoxona

Test Friedmana – porządku rang

- zastosowanie – porównanie wielu klasyfikatorów na wielu zbiorach danych
- test nieparametryczny (analiza wariancji powtarzanych pomiarów dla rang Friedmana – ANOVA Friedmana)
- H0 – średnie rang z N pomiarów nie są statystycznie różne
- H1 – nie wszystkie średnie rangi są sobie równe

Test Friedmana

ZD	K1	K2	K3	K4	Ranga K1	Ranga K2	Ranga K3	Ranga K4
Z1	0,762	0,768	0,771	0,799	4	3	2	1
Z2	0,699	0,691	0,701	0,704	2	3	4	1
Z3	0,854	0,871	0,868	0,867	4	1	2	3
Z4	0,728	0,761	0,754	0,757	4	1	3	2
Z5	0,882	0,888	0,886	0,898	4	2	3	1
Z6	0,936	0,931	0,916	0,931	1	2,5	4	2,5
Z7	0,662	0,668	0,599	0,695	3	2	4	1
Z8	0,583	0,583	0,563	0,625	2,5	2,5	4	1
Z9	0,775	0,838	0,866	0,875	4	3	2	1
Z10	0,923	0,923	0,923	0,923	2,5	2,5	2,5	2,5
Z11	0,94	0,962	0,965	0,962	4	2,5	1	2,5
Z12	0,819	0,866	0,814	0,869	3	2	4	1
Z13	0,962	0,981	0,965	0,965	4	1	2,5	2,5
Z14	0,952	0,948	0,926	0,975	2	3	4	1
				Średnia	3,21	2,28	2,85	1,64

Przykładowe dane – test Friedmana

Test Friedmana – post-hoc

- test typu post-hoc (po fakcie) to kolejny krok analizy wariancji
- *po fakcie*, czyli po sprawdzeniu H0
- jeśli przyjmujemy H0 to testu post-hoc nie wykonuje się
- cel: porównanie parami – znalezienie par, w których średnie rangi są statystycznie różne
- wiele testów: „konserwatywne” lub „liberalne”

Post-hoc – test Nemenyi

- jeśli porównujemy klasyfikatory, wśród których nie ma wyróżnionego

$$CD = q_\alpha \sqrt{\frac{K(K+1)}{6N}}$$

K	q05	q1	CDq05	CDq1
2	1,96	1,645	0,524	0,44
3	2,344	2,052	0,886	0,776
4	2,569	2,291	1,254	1,118
5	2,728	2,46	1,63	1,47
6	2,85	2,589	2,015	1,83
7	2,948	2,693	2,407	2,199
8	3,031	2,78	2,806	2,574

Wartości krytyczne – test Nemenyi

Post-hoc – test Nemenyi

K1	K2	K3	K4
3,21	2,28	2,85	1,64

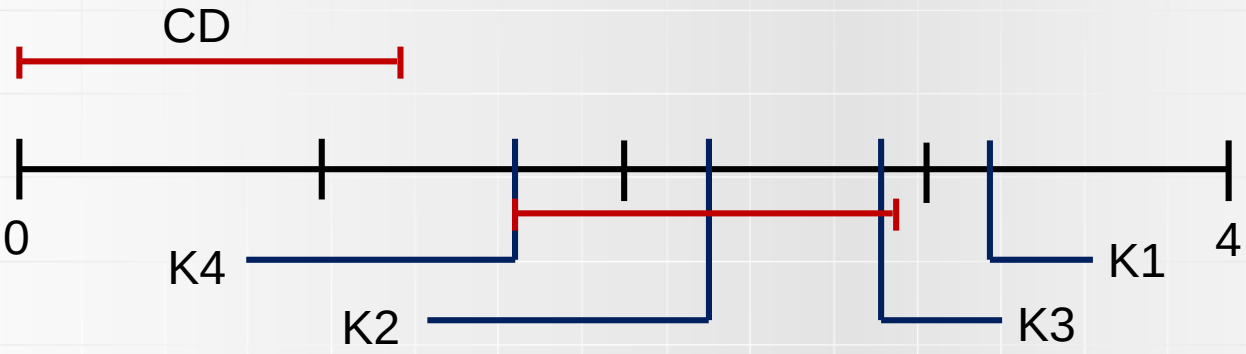
Średnie rangi – test Friedmana

		K1	K2	K3	K4
	Średnia r.	3,21	2,28	2,85	1,64
K1	3,21	0	0,93	0,36	1,57
K2	2,28	--	0	0,57	0,64
K3	2,85	--	--	0	1,21
K4	1,64	--	--	--	0

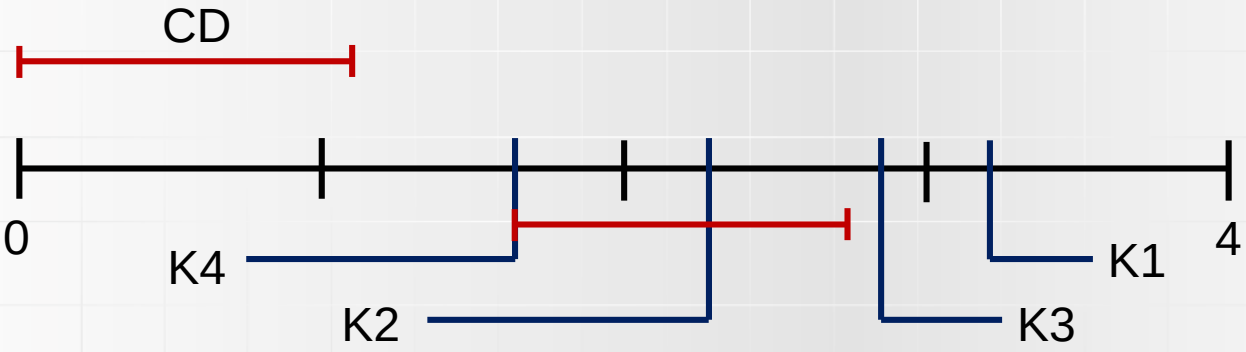
Moduł różnicy średnich rang

- poziom istotności 0,05: różnica między K1 K4
- poziom istotności 0,1: różnica miedzy K1 K4 oraz K3 K4

Post-hoc – test Nemenyi



Wizualizacja – poziom istotności 0,05



Wizualizacja – poziom istotności 0,1

Post-hoc – test Bonferroni-Dunn

- jeśli porównujemy klasyfikatory, wśród których jeden jest wyróżniony – modyfikacje, hiperparametry jednego algorytmu
- procedura taka sama jak w teście Nemenyi
- inna wartość krytyczna
  - ➢ wybór testu post-hoc jest kwestią w wielu przypadkach arbitralną, testy post-hoc różnią się czułością wykrycia rzeczywistych różnic między grupami
  - ✓ Tukeya, NIR, Duncana
  - ✓ procedury szukania par: Holm, Hochberg

Post-hoc – test Bonferroni-Dunn

		K1	K2	K3	K4
	Średnia r.	3,21	2,28	2,85	1,64
K1	3,21	0	0,93	0,36	1,57
K2	2,28	--	0	0,57	0,64
K3	2,85	--	--	0	1,21
K4	1,64	--	--	--	0

Moduł różnicy średnich rang

- poziom istotności 0,05: CD = 1,17
- poziom istotności 0,1: CD = 1,04

- poziom istotności 0,05: różnica między K1 K4 oraz K3 K4
- poziom istotności 0,1: różnica między K1 K4 oraz K3 K4

Macierz – wygrana-przegrana-remis

- porównanie metod zliczając parami wygrane, przegrane oraz remisy
- liczba zwycięstw jest zgodna z rozkładem dwumianowym

N	q05	q1
11	9	9
12	10	9
13	10	10
14	11	10
…	…	…
23	17	16
24	18	16
25	18	17

Wartości krytyczne dla metody wygrana-przegrana-remis

Macierz – wygrana-przegrana-remis

W/P/R	K1	K2	K3	K4
K1	0	3/2/9	5/1/8	1/1/12
K2	--	0	9/1/4	3/3/8
K3	--	--	0	2/2/10
K4	--	--	--	0

Tabela wygrana-przegrana-remis

N = 14, q05 = 11, q1 = 10

- poziom istotności 0,05: różnica między K1 K4
- poziom istotności 0,1: różnica między K1 K4 oraz K3 K4

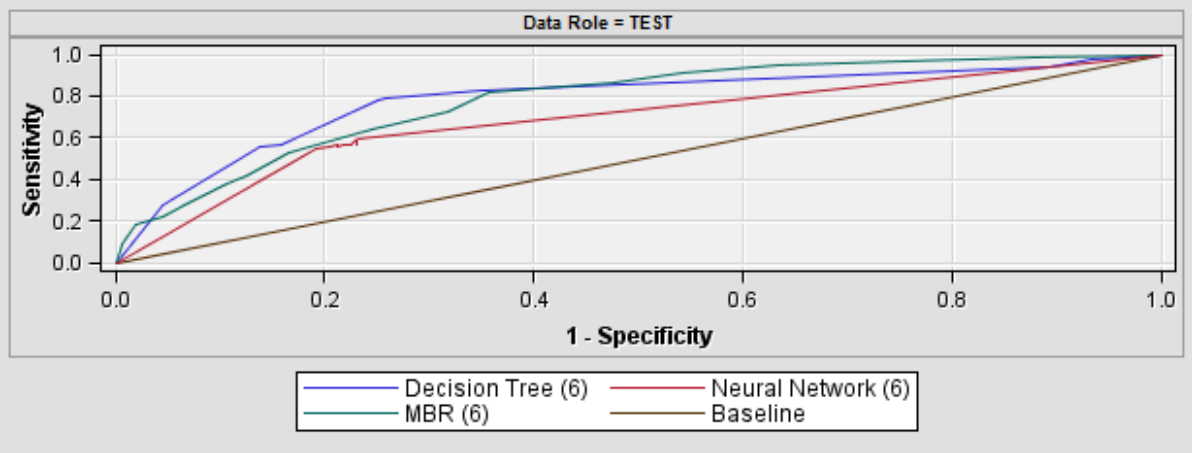
Ocena jakości klasyfikacji

Tab. 1. Macierz pomyłek – klasyfikacja binarna

		Klasa przewidywana		
		pozytywna (positive)	negatywna (negative)	
Klasa rzeczywista	pozytywna (positive)	**TP** (chory -> chory)	**FN** (chory -> zdrowy)	P
	negatywna (negative)	**FP** (zdrowy-> chory)	**TN** (zdrowy-> zdrowy)	N
		$\hat{P}$	$\hat{N}$	

Ocena jakości klasyfikacji

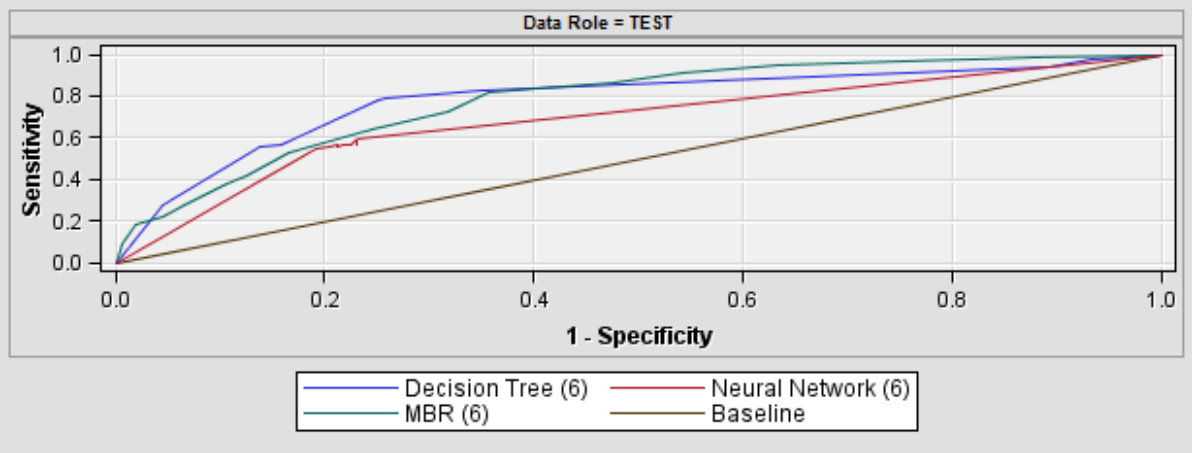
- **Krzywa ROC (**Receiver Operating Curve**):**
  - Jest funkcją, gdzie zmienną niezależną jest 1-specyficzność, zmienną zależną czułość
  - Pozwala „szybko” graficznie ocenić skuteczność klasyfikacji



Rys. 8. Przykład krzywej ROC

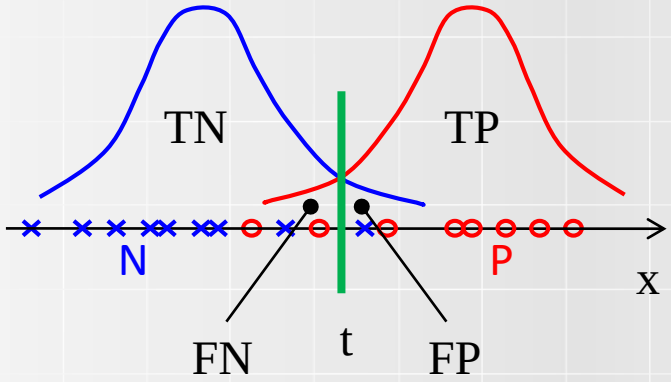
Ocena jakości klasyfikacji

- Punkt (0,1) – idealna klasyfikacja
- Punkt (0,0) – wszystkie obiekty do klasy negatywnej
- Punkt (1,0) – całkowicie błędna klasyfikacja
- Punkt (1,1) – wszystkie obiekty do klasy pozytywnej
- Pole pod krzywą (AUC) (Area Under ROC Curve)



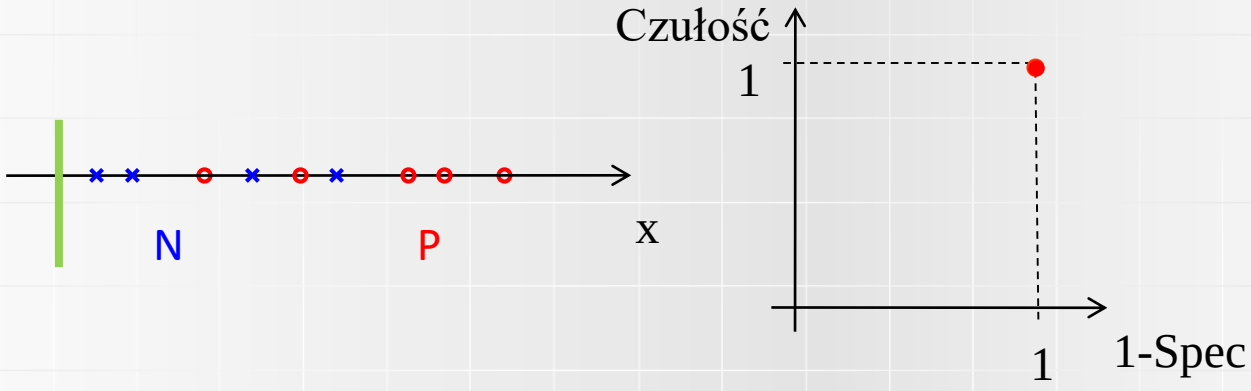
Rys. 8. Przykład krzywej ROC

ROC - przykład



		Klasa przewidywana	
		pozytywna	negatywna
Klasa rzeczywista	pozytywna	**TP**	**FN**
	negatywna	**FP**	**TN**

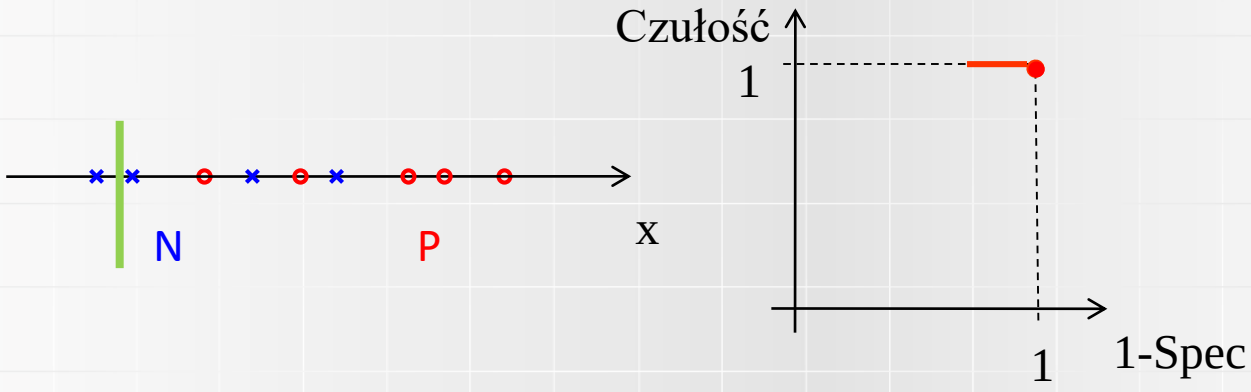
ROC - przykład



Czułość: 5/5 1
Specyficzność 0/4 0
1-Spec 1

		Klasa przewidywana	
		pozytywna	negatywna
Klasa rzeczywista	pozytywna	**5**	**0**
	negatywna	**4**	**0**

ROC - przykład



Czułość: 5/5 1

Specyficzność 1/4

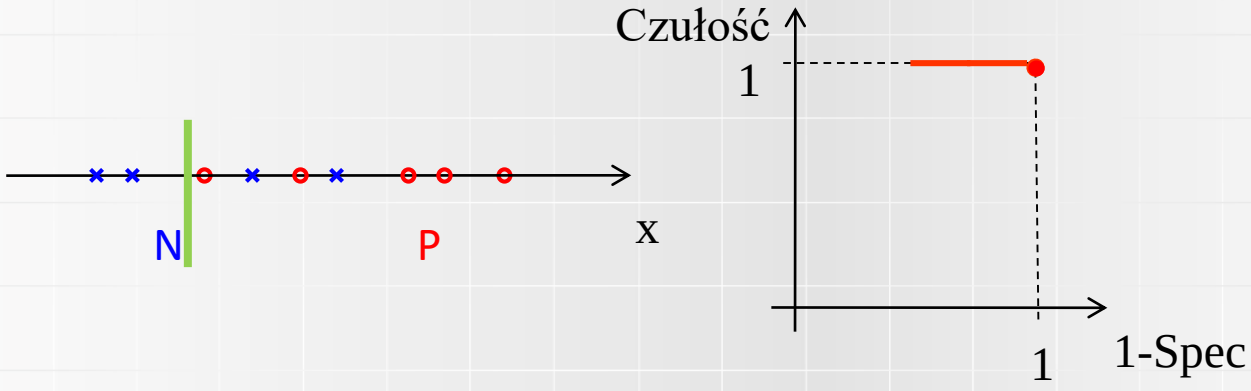
0,25

1-Spec

0,75

		Klasa przewidywana	
		pozytywna	negatywna
Klasa rzeczywista	pozytywna	**5**	**0**
	negatywna	**3**	**1**

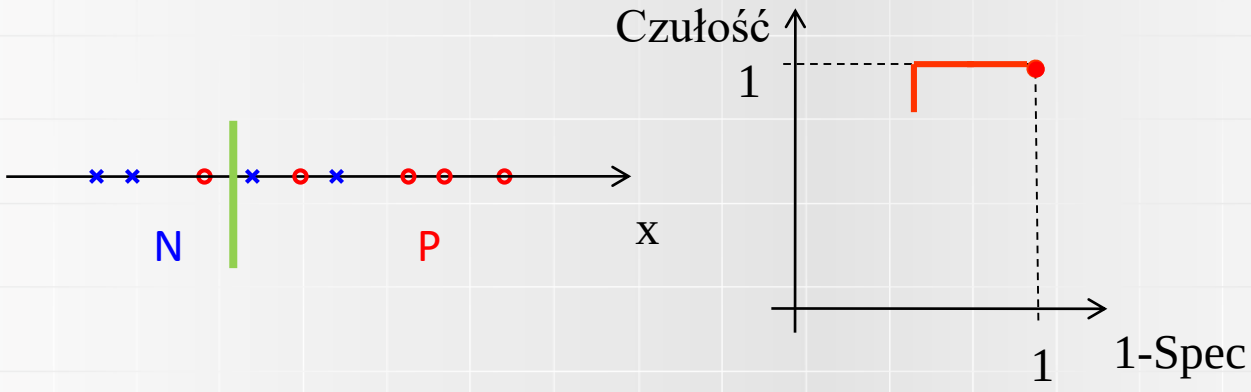
ROC - przykład



Czułość: 5/5 1
Specyficzność 2/4 0,5
1-Spec 0,5

		Klasa przewidywana	
		pozytywna	negatywna
Klasa rzeczywista	pozytywna	**5**	**0**
	negatywna	**2**	**2**

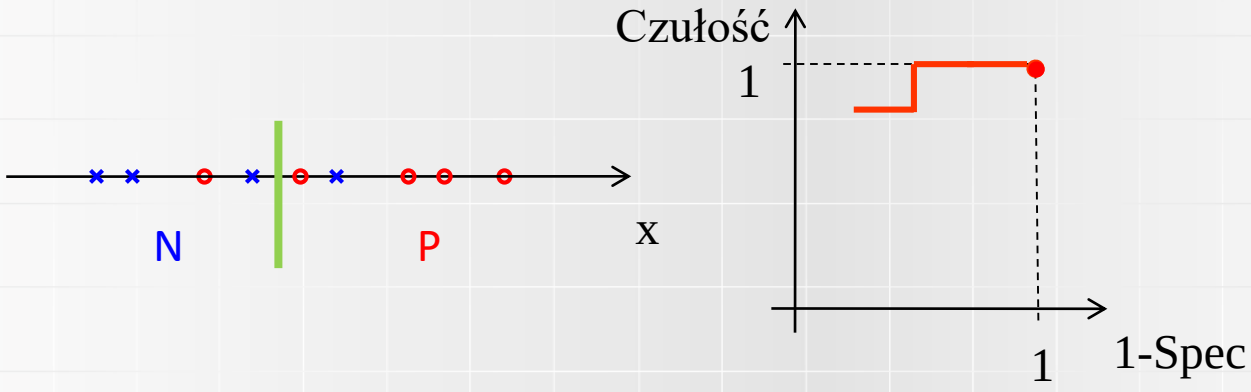
ROC - przykład



Czułość: 4/5 0,8
Specyficzność 2/4 0,5
1-Spec 0,5

		Klasa przewidywana	
		pozytywna	negatywna
Klasa rzeczywista	pozytywna	**4**	**1**
	negatywna	**2**	**2**

ROC - przykład



Czułość: 4/5 0,8

Specyficzność 3/4

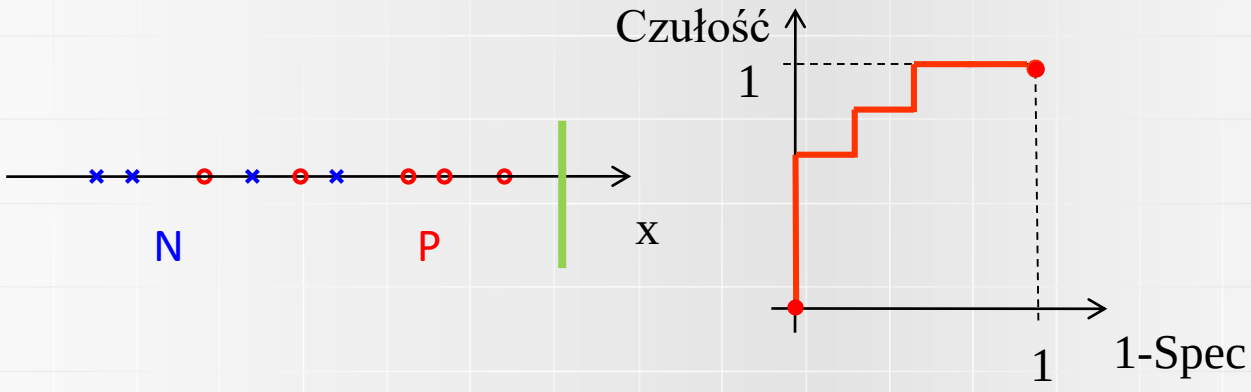
0,75

1-Spec

0,25

		Klasa przewidywana	
		pozytywna	negatywna
Klasa rzeczywista	pozytywna	**4**	**1**
	negatywna	**1**	**3**

ROC - przykład



Czułość: 0/5 0
Specyficzność 0/4 0
1-Spec 1

		Klasa przewidywana	
		pozytywna	negatywna
Klasa rzeczywista	pozytywna	**0**	**5**
	negatywna	**0**	**4**

Politechnika Wrocławska

Regresja liniowa

Analiza regresji liniowej pozwala przewidzieć wartość zmiennej na podstawie wartości innej zmiennej. Zmienna, której wartość ma zostać oszacowana, jest nazywana zmienną zależną (wyjaśniana). Zmienna, która służy do obliczenia wartości innej zmiennej, jest nazywana zmienną niezależną (wyjaśniającą).

Z założenia istnieje liniowy związek między zmienną zależną a zmienną (zmiennymi) niezależną.

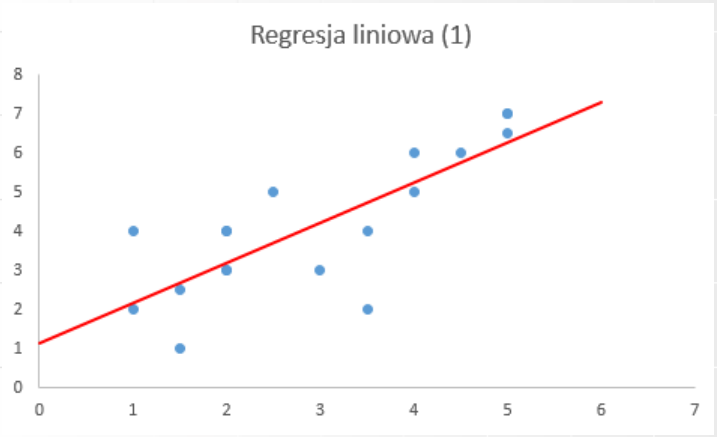
Politechnika Wrocławska

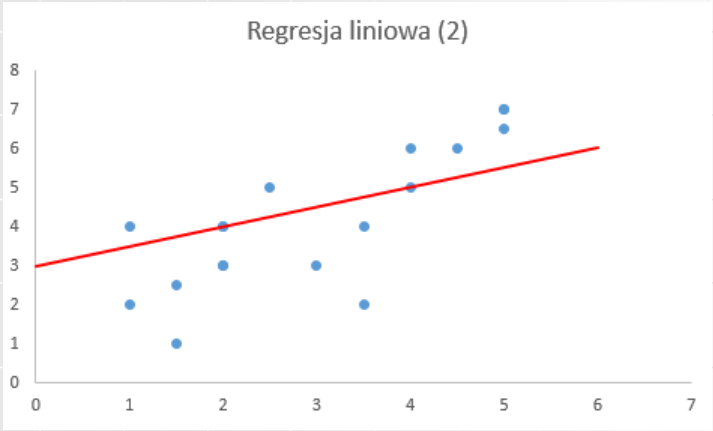
Regresja liniowa

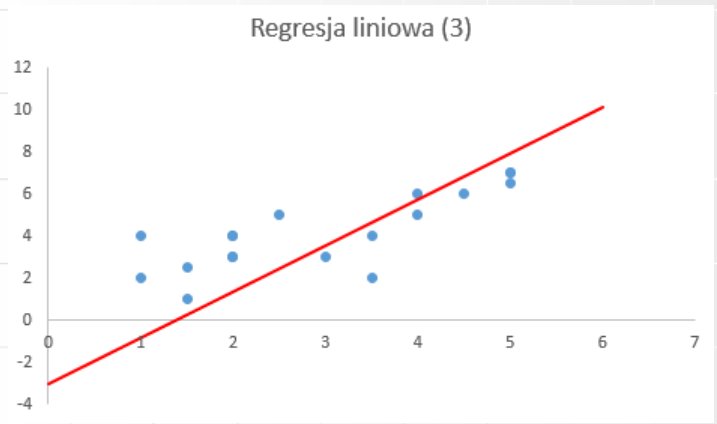
- Prostota,
- Interpretowalność – łatwo wyjaśnić, jak dana cecha wpływa na wynik modelu,
- Szybkość – nawet przy dużej liczbie danych wynik może być akceptowalny.

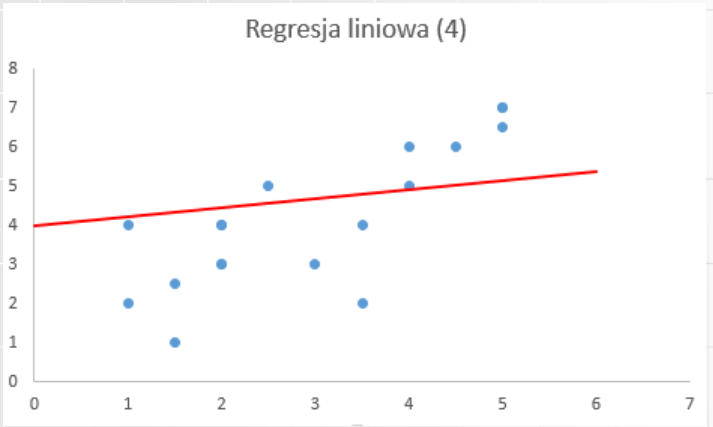
❖ **Wartości odstające** bardzo zaburzają wyniki. Dlatego, zanim przystąpimy do pracy, warto się ich pozbyć.

Regresja liniowa







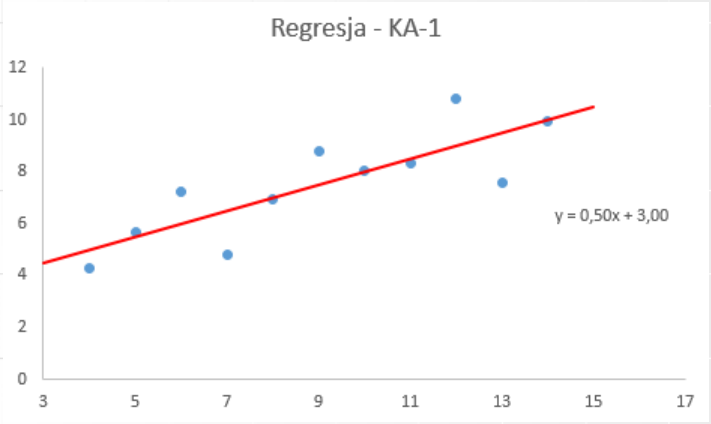


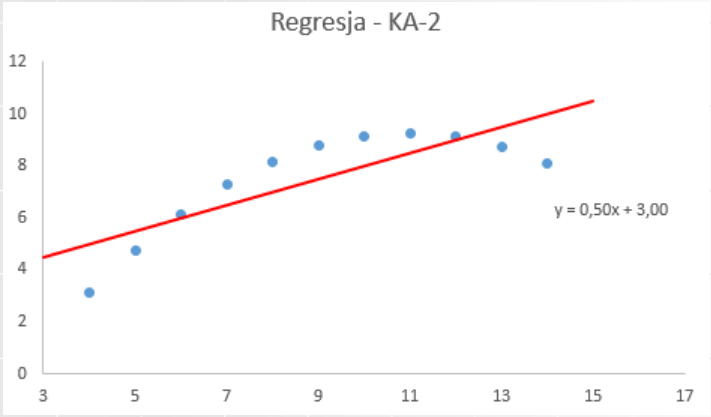
Regresja liniowa

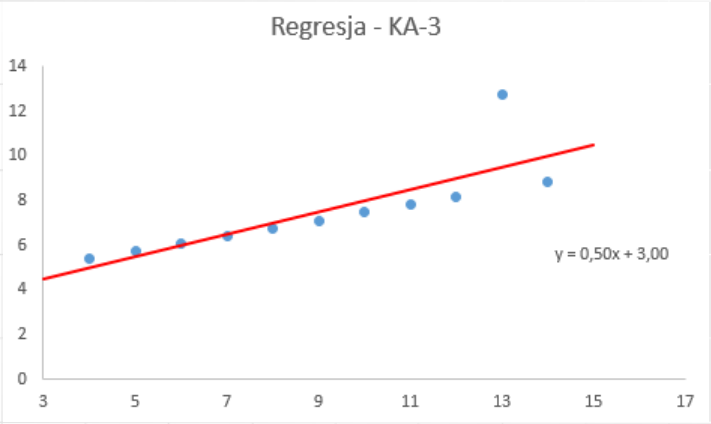
I		II		III		IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89

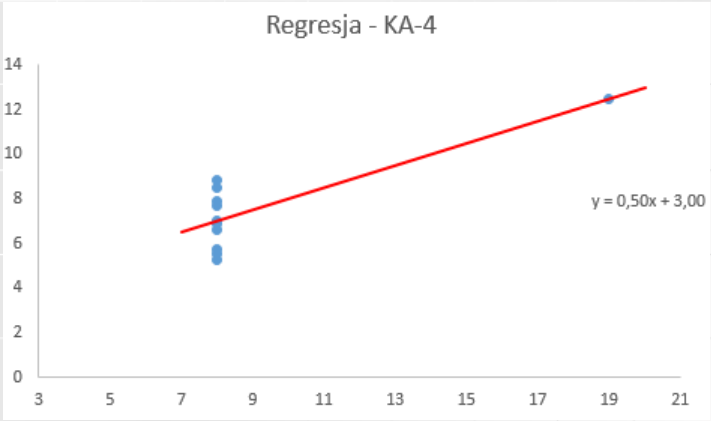
Kwartet Anscombe'a – cztery przykłady danych o identycznych cechach statystycznych, takich jak średnia arytmetyczna, wariancja, współczynnik korelacji czy równanie regresji liniowej

Regresja liniowa



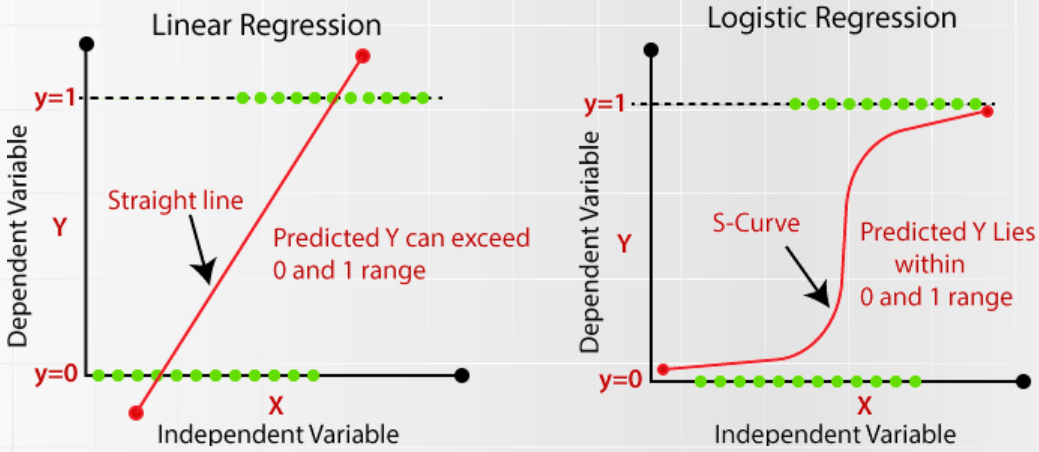






Regresja logistyczna

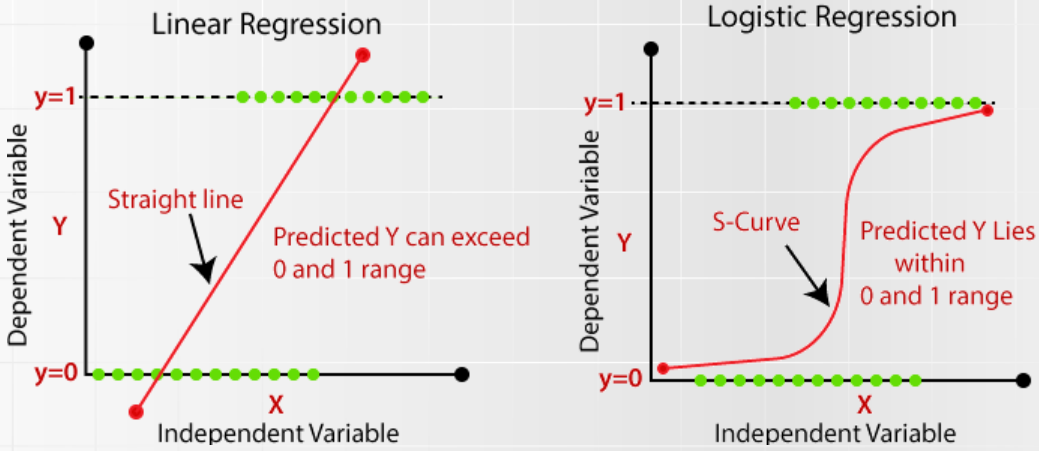
– **Regresja logistyczna – jedna z metod regresji używanych w statystyce w przypadku, gdy zmienna zależna jest na skali dychotomicznej (przyjmuje tylko dwie wartości).**



https://www.javatpoint.com/linear-regression-vs-logistic-regression-in-machine-learning

Regresja logistyczna

- Krzywa w kształcie litery “S” pozwala określić, jakie jest prawdopodobieństwo zdarzenia y=1
- Jeśli wartość zmiennej X rośnie, to prawdopodobieństwo tego, że wystąpi zdarzenie y=1 również rośnie



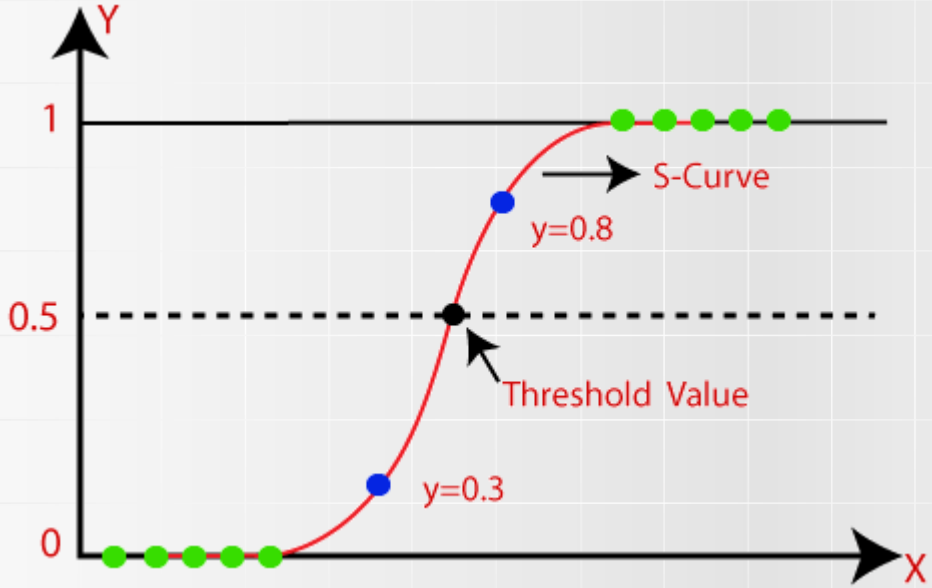
https://www.javatpoint.com/linear-regression-vs-logistic-regression-in-machine-learning

Politechnika Wrocławska

Regresja logistyczna

- Próg odcięcia (ang. *threshold*) wartość, powyżej której przypisujemy obserwację do jednej klasy, a poniżej której do drugiej klasy. Jest to punkt graniczny, który pozwala na dokonanie decyzji o przynależności danego obiektu do jednej z klas na podstawie wartości przewidywanego prawdopodobieństwa.
- Domyślnie próg odcięcia wynosi 0,5 (czyli 50%). Oznacza to, że wszystkie obserwacje, dla których przewidywane prawdopodobieństwo przynależności do jednej z klas jest większe niż 0,5, zostaną przypisane do tej klasy, a pozostałe do drugiej.
- Warto pamiętać, że wybór wartości progu odcięcia zależy od konkretnego zastosowania i powinien być ustalany z uwzględnieniem stosowanej metryk, wybór progu odcięcia wpływa na jakość niektórych metryk (np. recall, accurancy, precision)

Regresja logistyczna



https://medium.com/@novus_afk/understanding-logistic-regression-a-beginners-guide-73f148866910

Ekstrakcja cech – analiza głównych składowych (principal component analysis)

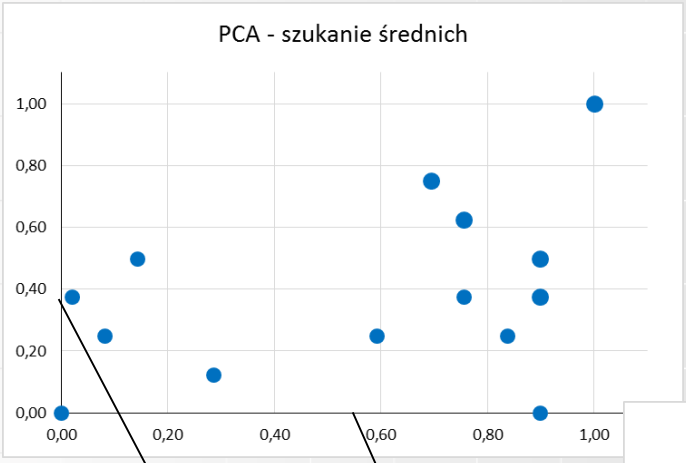
- przekształcenie, w nową przestrzeń obserwacji.
- obrót układu współrzędnych, tak aby pierwsza współrzędna miała maksymalną wariancję
- najwięcej zmienności (wariancję) wyjaśniają kolejne składowe główne
- składowa główna – kombinacja liniowa cech
- odrzucane są składowe główne, które najmniej wyjaśniają dane

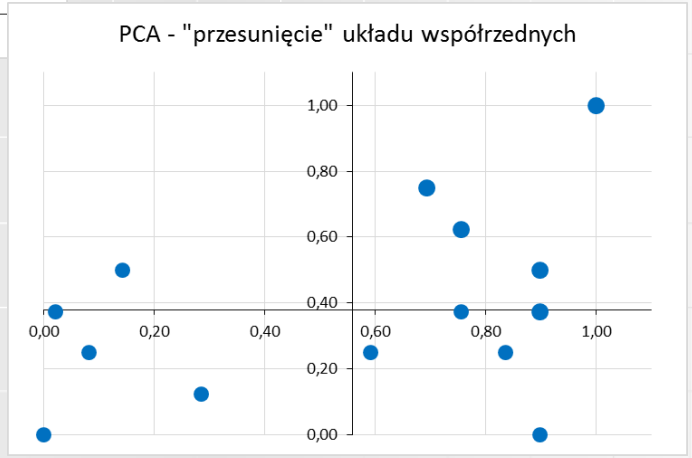
Politechnika Wrocławska

PCA

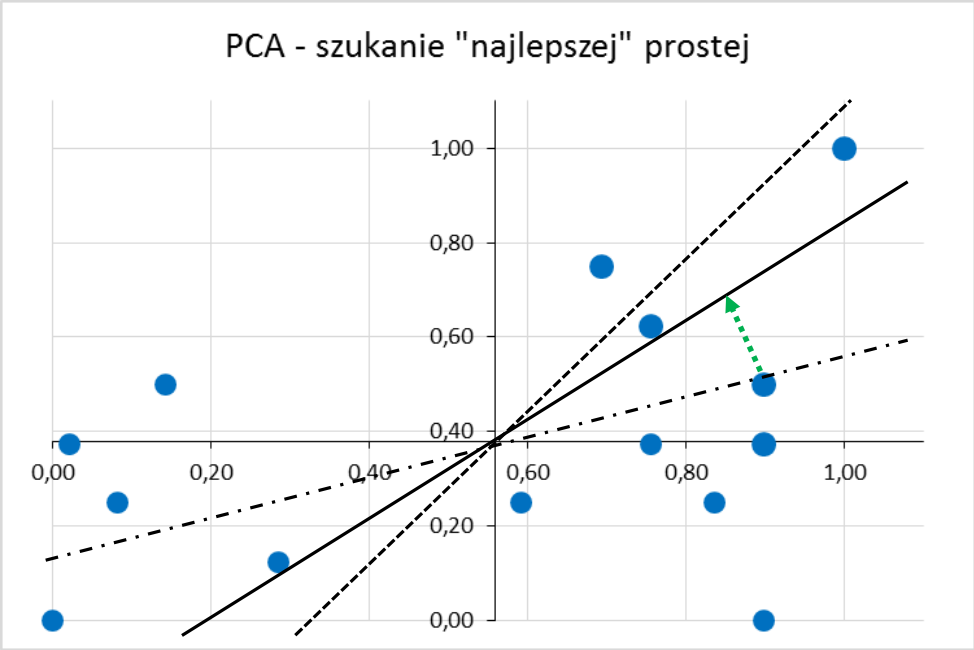
- w zależności od implementacji algorytm może wykorzystywać macierzy korelacji, albo macierzy kowariancji utworzonej ze zbioru wejściowego
- wykorzystanie macierzy korelacji odpowiada wstępnej normalizacji (standaryzacji do RN) zbioru wejściowego
- wykorzystanie macierzy kowariancji wymaga wcześniejszej standaryzacji do RN

PCA


PCA - szukanie średnich
1,00
0,80
0,60
0,40
0,20
0,00
0,00
0,20
0,40
0,60
0,80
1,00
0,38
0,56

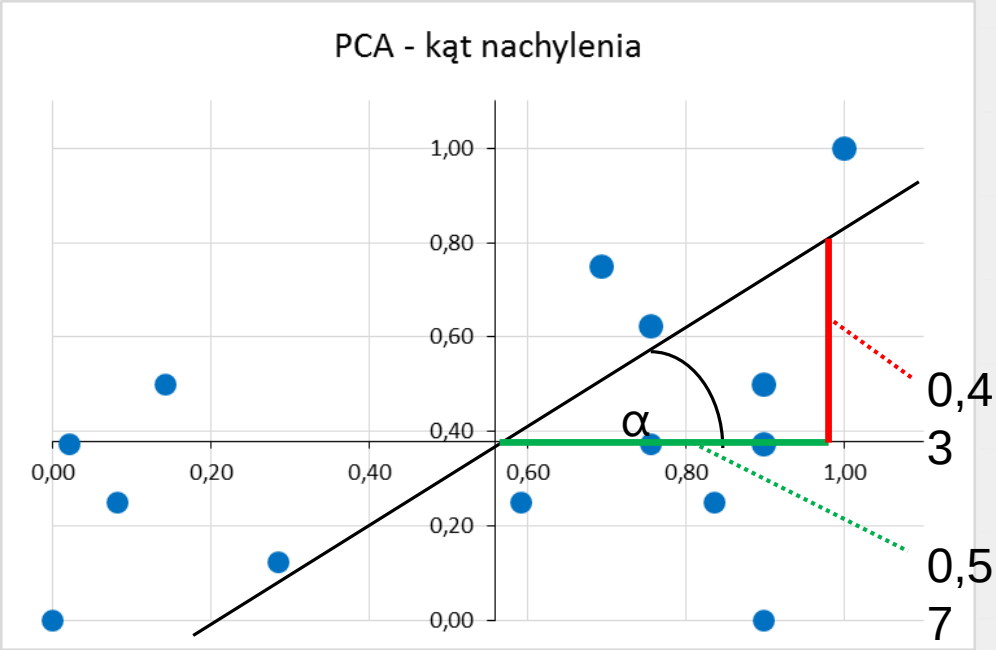

PCA - "przesunięcie" układu współrzednych
1,00
0,80
0,60
0,40
0,20
0,00
0,00
0,20
0,40
0,60
0,80
1,00

PCA



Szukana prosta: minimalizuje sumę odległości punktów od prostej

PCA



Kąt α definiuje stosunek poszczególnych zmiennych, których kombinacja linowa z wagami równymi stosunkowi wyznacza składową główną

PCA – zbiór danych „Cars”

Simple Statistics							
	Cylinders	Horsepower	MPG_City	MPG_Highway	Weight	Wheelbase	Length
Mean	5.807511737	215.8779343	20.07042254	26.85446009	3580.474178	108.1643192	186.4201878
StD	1.558442633	71.9910395	5.24861602	5.75233488	759.870073	8.3300304	14.3666105

Simple Statistics							
	Cylinders	Horsepower	MPG_City	MPG_Highway	Weight	Wheelbase	Length
Mean	0.000000000	-0.000105515	0.001846978	0.001916350	0.003321427	0.001216779	0.004042227
StD	1.000000000	1.002157802	1.001985100	1.001939343	1.001168482	1.002191748	1.000600310

Zbiór cech zbioru danych Cars – oryginalne oraz po standaryzacji do RN

PCA – zbiór danych „Cars”

Eigenvectors								
		Prin1	Prin2	Prin3	Prin4	Prin5	Prin6	Prin7
Cylinders		0.387956	-.191108	0.497514	0.189402	-.710574	-.156823	0.008177
Horsepower		0.351176	-.402303	0.531116	-.270672	0.595442	0.015496	-.068472
MPG_City	MPG (City)	-.394158	0.277986	0.446223	0.383381	0.124175	-.031020	-.636306
MPG_Highway	MPG (Highway)	-.394686	0.270281	0.504482	-.026084	0.029535	0.165761	0.698312
Weight	Weight (LBS)	0.415958	0.089567	-.092538	0.729037	0.238655	0.434868	0.181197
Wheelbase	Wheelbase (IN)	0.353570	0.560871	0.008769	0.044636	0.216751	-.702125	0.135584
Length	Length (IN)	0.342046	0.573327	0.090215	-.457946	-.142492	0.514430	-.226947

Pierwsza składowa główna (Prin1) to następująca kombinacja liniowa cech:

SG1=0,39*Cylinders+0,35*Horsepower-0,4*MPG_City-0,4*MPG_Highway+

+0,42*Weight+0,35*Wheelbasee+0,34*Lenght

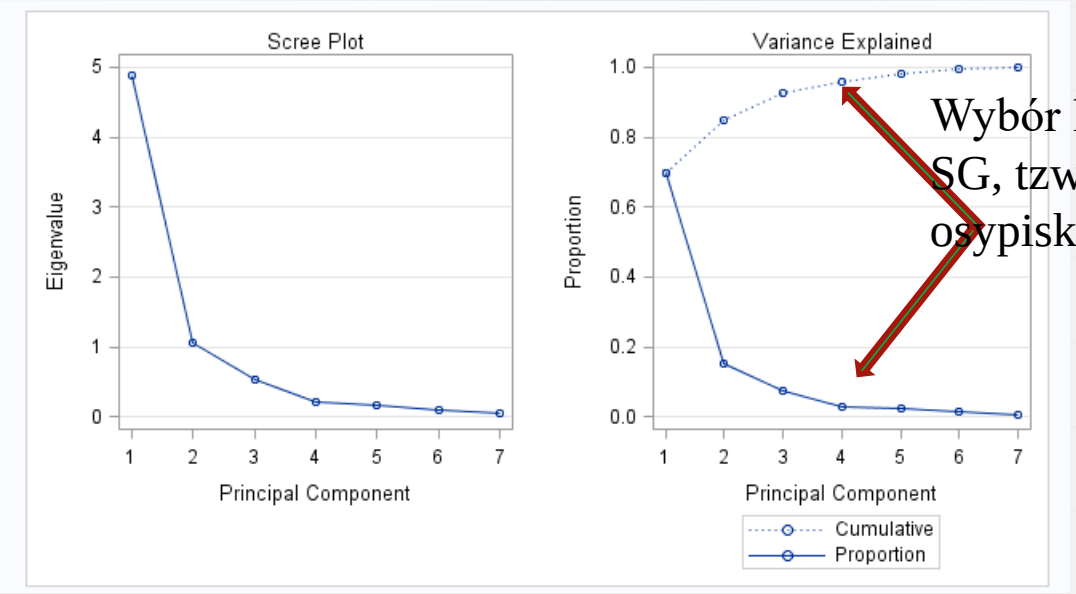
Wektory własne

PCA – zbiór danych „Cars”

Eigenvalues of the Correlation Matrix				
	Eigenvalue	Difference	Proportion	Cumulative
1	4.89369971	3.83188774	0.6991	0.6991
2	1.06181197	0.52523907	0.1517	0.8508
3	0.53657290	0.32559513	0.0767	0.9274
4	0.21097778	0.04852350	0.0301	0.9576
5	0.16245427	0.07049219	0.0232	0.9808
6	0.09196208	0.04944078	0.0131	0.9939
7	0.04252130		0.0061	1.0000

Wartości własne, proporcja objaśniania (wariancji) zbioru oraz wartość skumulowana objaśnienia zbioru

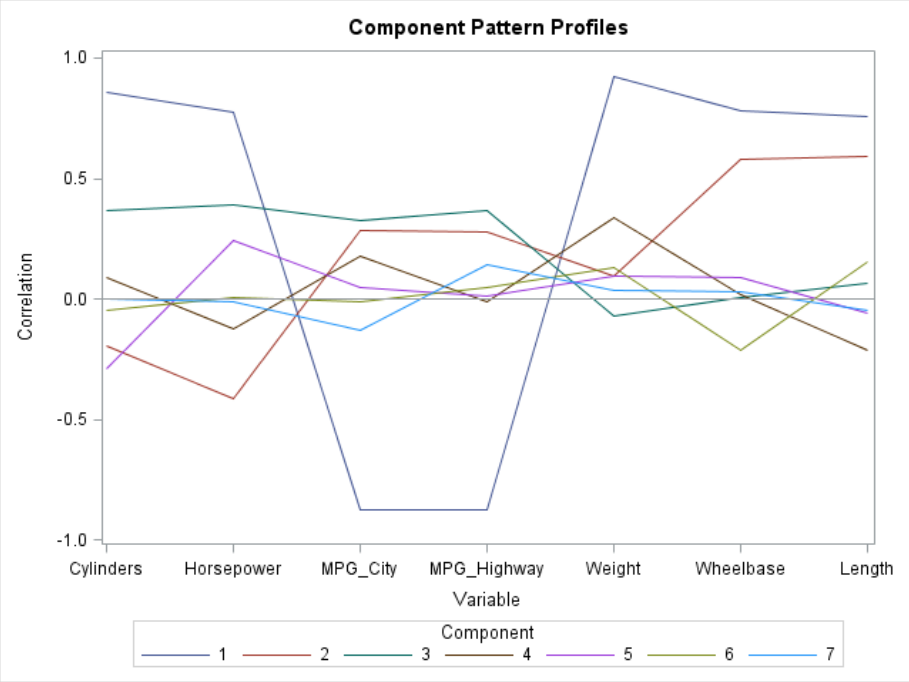
PCA – zbiór danych „Cars”



Wybór liczby SG, tzw. koniec osypiska

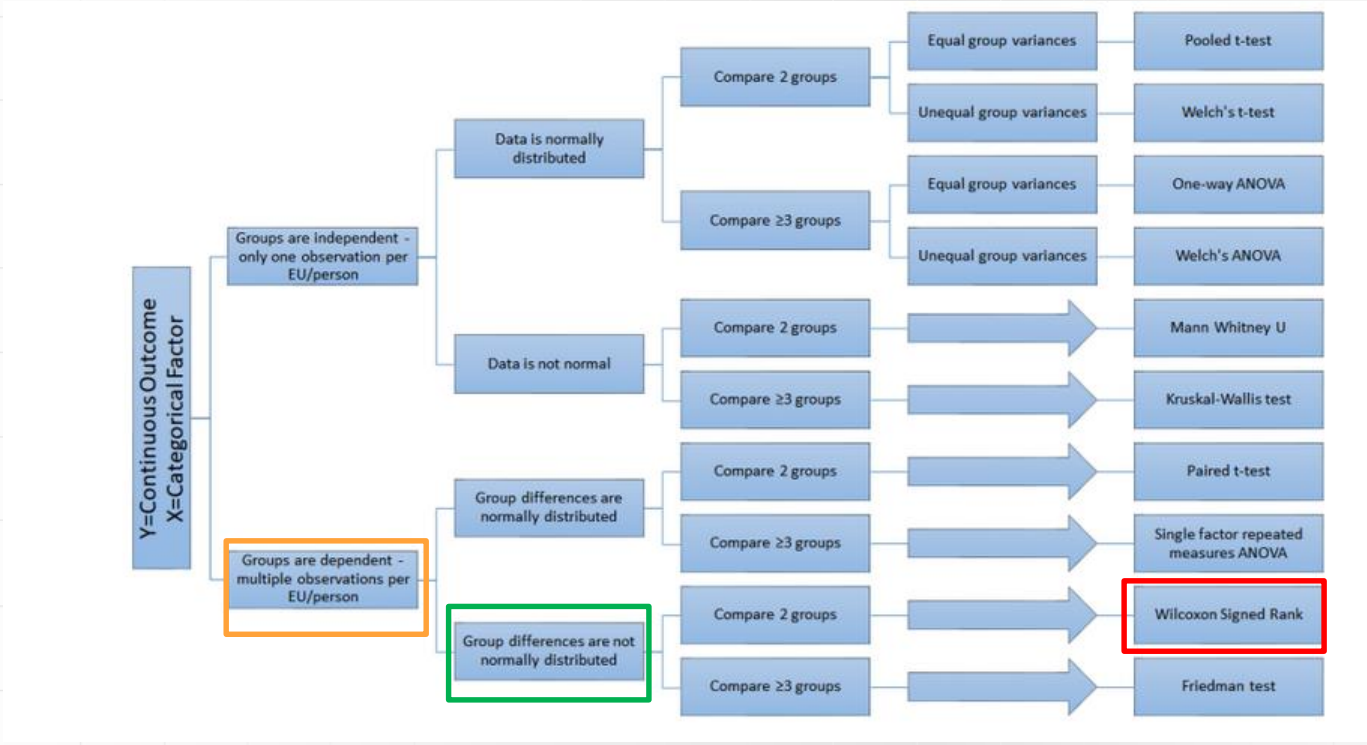
Interpretacja graficzna: wartości własne, proporcja objaśniania zbioru (wariancji) oraz wartość skumulowana objaśnienia zbioru

PCA – zbiór danych „Cars”



Pierwsza składowa główna (linia niebieska) jest silnie dodatnio skorelowana ze zmiennymi: Cylinders, Horsepower, Weight, Wheelbasee oraz Lenght

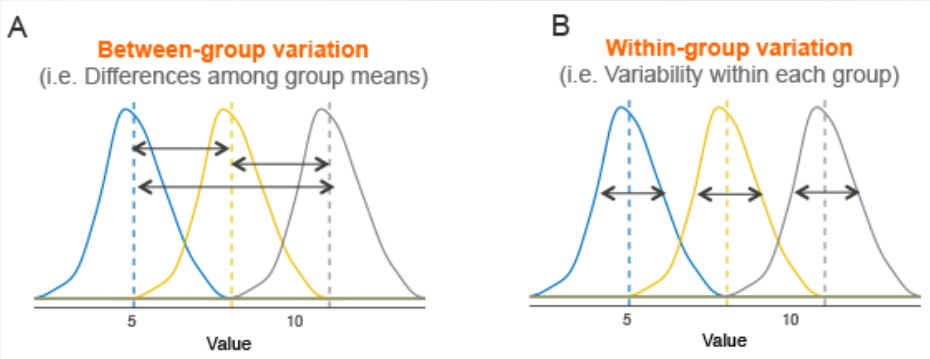
Schemat wyboru testów statystycznych



https://stat-methods.com

ANOVA

- ANOVA <-> **AN**alysis **O**f **Va**riance
- Czy średnie w grupach różnią się istotnie?
- Porównanie zmienności pomiędzy grupami reprezentowanymi przez średnie ze zmiennością indywidualnych obserwacji wewnątrz grup



https://www.datanovia.com/en/lessons/anova-in-r/

Politechnika Wrocławska

ANOVA

- ANOVA <-> **AN**alysis **O**f **Va**riance
- Czy średnie w grupach różnią się istotnie?
- Porównanie zmienności pomiędzy grupami reprezentowanymi przez średnie ze zmiennością indywidualnych obserwacji wewnątrz grup
- Rozrzut średnich oceniany jest za pomocą wariancji
- Jednoczynnikowa analiza wariancji - "rozszerzenie" testów t-Studenta
- W przypadku wielu grup – testy post-hoc

Politechnika Wrocławska

ANOVA

- w medycynie analiza wariancji pozwoli określić, która z testowanych metod leczenia jest najbardziej skuteczna
- ogólnie: ma zastosowanie w przypadku analizy wpływu jednego czynnika na badaną zmienną zależną
- np. w celu weryfikacji, czy wyniki studentów z egzaminu różniły się w zależności od czasu przygotowania do egzaminu (studentów przypisujemy do trzech niezależnych grup np. o krótkim, średnim i długim czasie przygotowania do egzaminu
- obserwacje zależne: single-factor repeated ANOVA
- obserwacje niezależne: on-way ANOWA

ANOVA

- **Zmienna zależna mierzona na skali ilościowej**
  - **Skala ilościowa** – typ skali pomiarowej używanej w statystyce i badaniach naukowych, która umożliwia nie tylko klasyfikację (jak w skali nominalnej) i porządkowanie obserwacji (jak w skali porządkowej), ale również wykonywanie operacji matematycznych takich jak dodawanie, odejmowanie, mnożenie i dzielenie
- Pomiar na tej skali pozwala na dokładne określenie danej wartości na skali oraz na określenie różnic w jednostkach pomiarowych, pomiędzy danym pomiarem a innym. Może przyjmować postać ciągłą (od 0 do bezwzględnej nieskończoności) lub o określonych wartościach (z wyznaczonym maksimum).

Politechnika Wrocławska

ANOVA

- **Niezależność obserwacji** - próby zostały pobrane losowo, niezależnie od siebie dla każdej z analizowanych grup

- W każdej grupie są różni uczestnicy badania i żaden uczestnik nie należy do więcej niż jednej grupy

ANOVA

- Rozkład wyników zmiennej zależnej w każdej z analizowanych grup jest zbliżony do **rozkładu normalnego.**
  - ✓ W przypadku zmiennych mierzonych na skali porządkowej czy nominalnej nie możliwe jest obliczenie tych wartości, a co za tym idzie test t-Studenta nie powinien być stosowany. W takim przypadku najczęściej stosuje się nieparametryczny odpowiednik dla testu t-Studenta - test U Manna-Whitneya.
- Wariancje w porównywanych grupach są do siebie podobne - homogeniczność wariancji.
  - ✓ W przypadku złamanego założenia o homogeniczności wariancji stosowane są odmienne testy post-hoc w porównaniu do sytuacji, gdy założenie to zostało spełnione

Politechnika Wrocławska

ANOVA

- **Równoliczność obserwacji w grupach.** Poszczególne kategorie zmiennej niezależnej powinny być statystycznie równoliczne. Nie jest konieczne spełnienie warunku o idealnej równoliczność poszczególnych grup.
- Niewielkie różnice między grupami są do przyjęcia (weryfikacja za pomocą test zgodności Chi-kwadrat).

ANOVA

Wierszy razem: 15 Kolumn razem: 2

	words	method
1	700	A
2	850	A
3	820	A
4	640	A
5	920	A
6	480	B
7	460	B
8	500	B
9	570	B
10	580	B
11	500	C
12	550	C
13	480	C
14	600	C
15	610	C

Example of one-way ANOVA

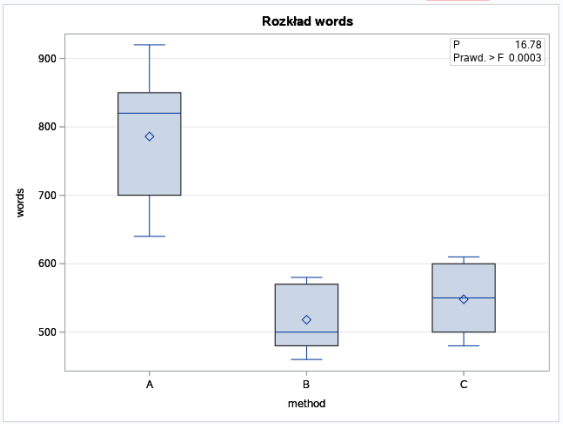
Procedura ANOVA

Zmienna zależna: words

Źródło	DF	Suma kwadratów	Średni kwadrat	Wartość F	Pr. > F
Model	2	215613.3333	107806.6667	16.78	0.0003
Błąd	12	77080.0000	6423.3333		
Razem skorygowane	14	292693.3333			

R-kwadrat	Wsp. zmienności	Pierw. z MSE	Średnia words
0.736653	12.98256	80.14570	617.3333

Źródło	DF	Suma kwadratów typu ANOVA	Średni kwadrat	Wartość F	Pr. > F
method	2	215613.3333	107806.6667	16.78	0.0003



ANOVA

Testy normalności				
Testowanie	Statystyka		Wartość p	
Shapiro-Wilka	W	0.951822	Pr. < W	0.7502
Kołmogorowa-Smirnowa	D	0.217312	Pr. > D	>0.1500
Cramera-von Misesa	W-kwadr.	0.036584	Pr. > W-kwadr.	>0.2500
Andersona-Darlinga	A-kwadr.	0.221372	Pr. > A-kwadr.	>0.2500

Testy normalności				
Testowanie	Statystyka		Wartość p	
Shapiro-Wilka	W	0.881679	Pr. < W	0.3170
Kołmogorowa-Smirnowa	D	0.232051	Pr. > D	>0.1500
Cramera-von Misesa	W-kwadr.	0.056997	Pr. > W-kwadr.	>0.2500
Andersona-Darlinga	A-kwadr.	0.346821	Pr. > A-kwadr.	>0.2500

Testy normalności				
Testowanie	Statystyka		Wartość p	
Shapiro-Wilka	W	0.906446	Pr. < W	0.4465
Kołmogorowa-Smirnowa	D	0.214808	Pr. > D	>0.1500
Cramera-von Misesa	W-kwadr.	0.041479	Pr. > W-kwadr.	>0.2500
Andersona-Darlinga	A-kwadr.	0.279615	Pr. > A-kwadr.	>0.2500

Example of one-way ANOVA

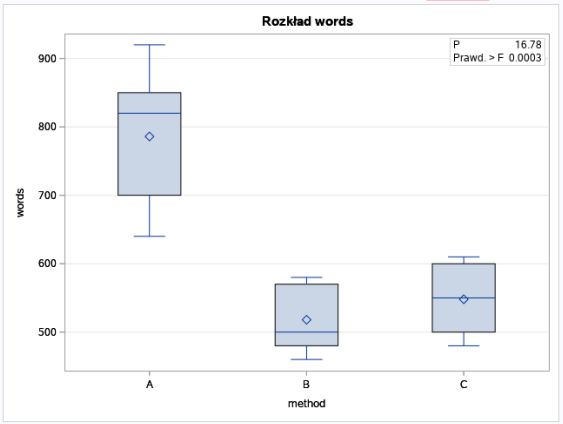
Procedura ANOVA

Zmienna zależna: words

Źródło	DF	Suma kwadratów	Średni kwadrat	Wartość F	Pr. > F
Model	2	215613.3333	107806.6667	16.78	0.0003
Błąd	12	77080.0000	6423.3333		
Razem skorygowane	14	292693.3333			

R-kwadrat	Wsp. zmienności	Pierw. z MSE	Średnia words
0.736653	12.98256	80.14570	617.3333

Źródło	DF	Suma kwadratów typu ANOVA	Średni kwadrat	Wartość F	Pr. > F
method	2	215613.3333	107806.6667	16.78	0.0003



Rozkład wyników zmiennej zależnej w każdej z analizowanych grup jest zbliżony do **rozkładu normalnego?**

ANOVA

Wierszy razem: 15 Kolumn razem: 2

	words	method
1	700	A
2	850	A
3	820	A
4	640	A
5	920	A
6	480	B
7	460	B
8	500	B
9	570	B
10	580	B
11	500	C
12	550	C
13	480	C
14	600	C
15	610	C

Example of one-way ANOVA

Procedura ANOVA

Test Levene'a homogeniczności wariancji words
ANOVA kwadratów odchylenia od średniej grupy

Źródło	DF	Suma kwadratów	Średni kwadrat	Wartość F	Pr. > F
method	2	2.0668E8	1.0334E8	3.74	0.0545
Błąd	12	3.3121E8	27601053		

ANOVA Welcha dla words

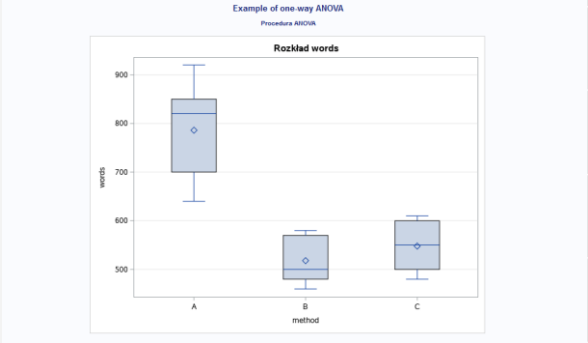
Źródło	DF	Wartość F	Pr. > F
method	2.0000	10.52	0.0065
Błąd	7.5552		

Wariancje w porównywanych grupach są do siebie podobne - homogeniczność wariancji**?**

ANOVA

Wierszy razem: 15 Kolumn razem: 2

	words	method
1	700	A
2	850	A
3	820	A
4	640	A
5	920	A
6	480	B
7	460	B
8	500	B
9	570	B
10	580	B
11	500	C
12	550	C
13	480	C
14	600	C
15	610	C



Example of one-way ANOVA

Procedura ANOVA

Test Studenta-Newmana-Keulsa dla words

Uwaga: This test controls the Type I experimentwise error rate under the complete null hypothesis but not under partial null hypotheses.

Alfa	0.05
Stopnie swobody błędu	12
Błąd średniokwadratowy	6423.333

Liczba średnich	2	3
Zakres krytyczny	110.43659	135.22869

words SNK Grouping for Means of method (alfa = 0.05)

Means leżące pod tym samym paskiem nie są znacząco różne.

method	Ocena
A	786.00
C	548.00
B	518.00

Planowanie eksperymentu

„Uczenie maszynowe to technologia, która wymaga specjalistycznej wiedzy, jak przygotować dane do trenowania i testowania, jakie algorytmy zastosować i jak wdrożyć system produkcyjny, a później jak jego działanie monitorować i dopasowywać do zmieniających się warunków. Dlatego wiedza i doświadczenie osób wdrażających, a później zajmujących się utrzymaniem systemu uczenia maszynowego mają krytyczne znaczenie dla powodzenia tego typu projektów”.

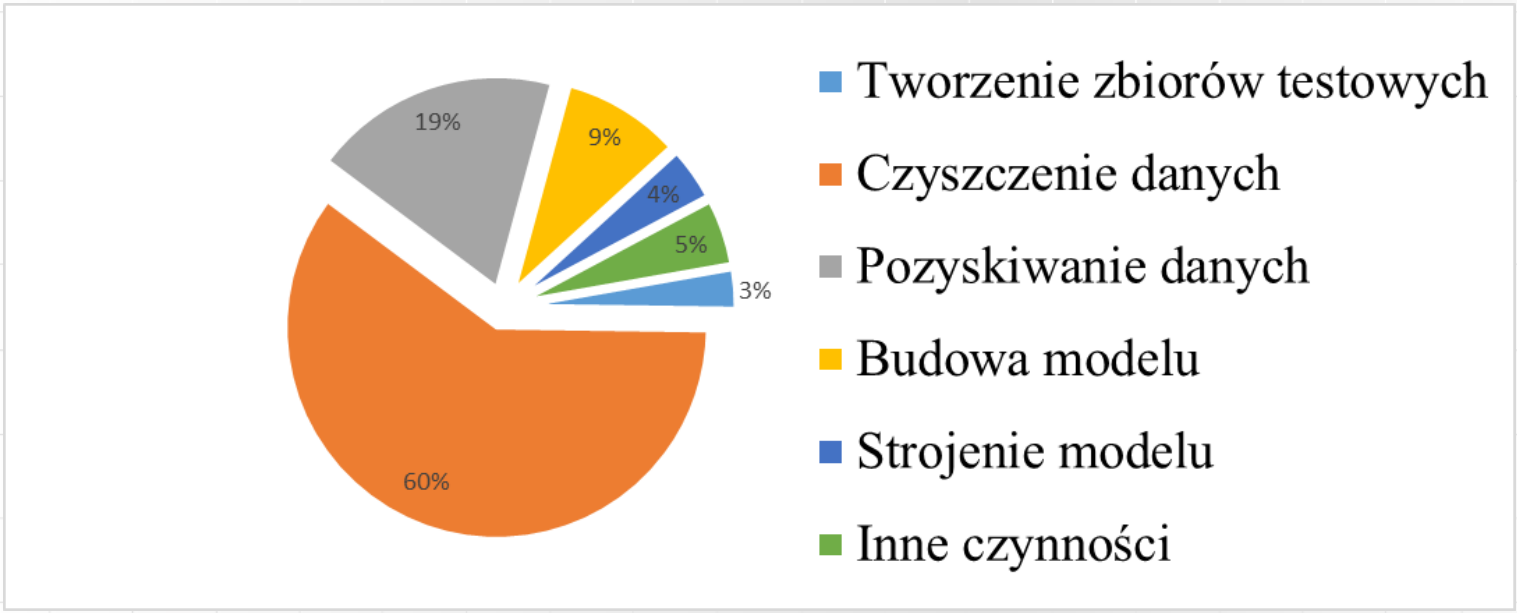
Computerword 20.10.2018

Planowanie eksperymentu

- Definicja problemu
  - z jakim problemem mamy do czynienia:
    regresja, klasyfikacja nienazdorowana, uczenie ze wzmocnieniem?
  - czy posiadamy właściwe dane:
    uczenie nadzorowane vs. uczenie nienadzorowane
  - wybór właściwych metryk:
    błąd całkowity nie jest właściwą metryką dla danych silnie niezbalansowanych
  - metryki liczbowe a możliwość wizualizacji oraz objaśniania modelu

Planowanie eksperymentu

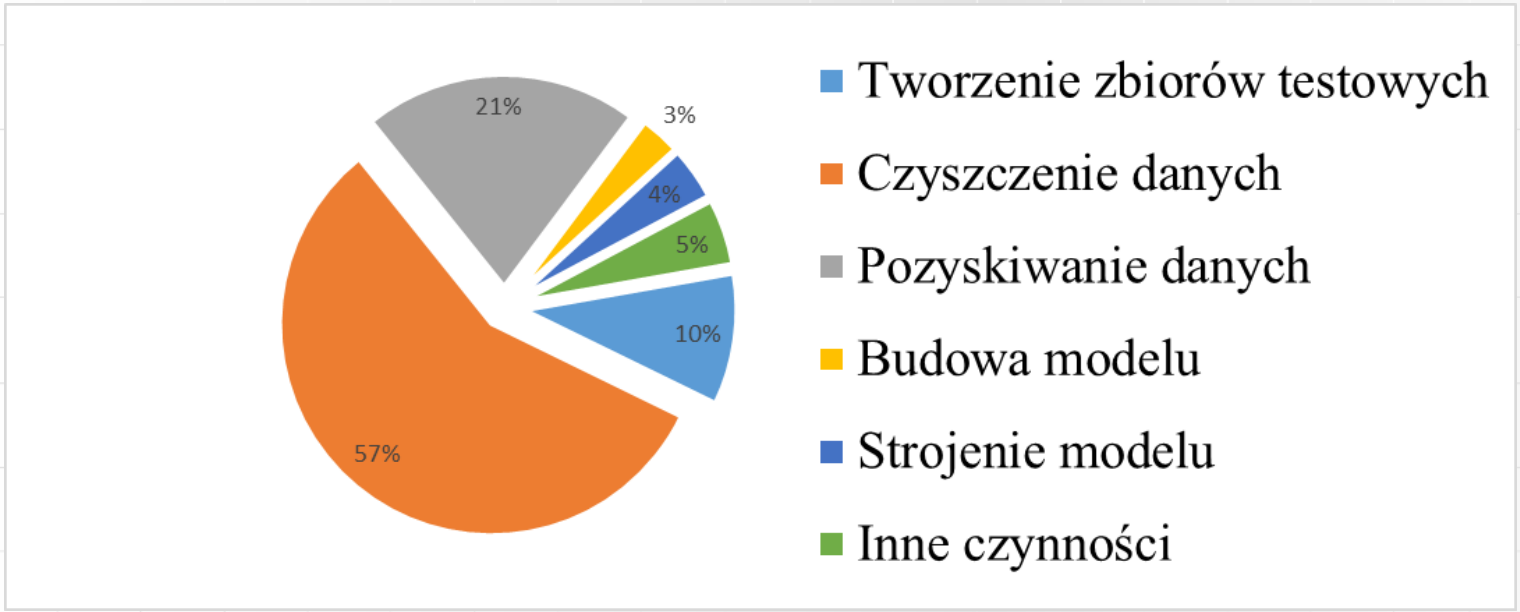
- Jakość, czystość danych
  - *śmieci na wejściu – śmieci na wyjściu*
    Garbage In, Garbage Out – GIGO



Inżynieria danych – podział czasu na czynności (www.forbes.com)

Planowanie eksperymentu

- Jakość, czystość danych
  - *„Czyszczenie danych jest nudne”*



Inżynieria danych – najmniej satysfakcjonujące czynności (www.forbes.com)

Planowanie eksperymentu

- Jaki model?
  - Twierdzenie „no free lunch” (NFL) – David Wolpert

Nie istnieje algorytm uczenia maszynowego, który ma charakter uniwersalny dla wszystkich problemów

- ekonomia – „there ain’t no such thing as a free lunch” „nie ma darmowych obiadów” Leonard Ayres Porter, Roberta A. Heinleina, Milton Friedman

Planowanie eksperymentu

- Jaki model?
  - Twierdzenie „no free lunch”
  - ✓ wzorzec, model a kontrprzykład, czyli paradoks „czarnego łabędzia”
  - ✓ uczenie maszynowe – rozumowanie indukcyjne – wnioski o problemie z wykorzystaniem obserwacji z przeszłości
  - ✓ wyuczony model może dobrze działać dla jednego problemu, ale nie daje to powodu by sądzić, że równie dobrze nadaje się do dowolnie innego problemu

Politechnika Wrocławska

Planowanie eksperymentu

- Jaki model?
  - analiza danych, zrozumienie problemu
  - zacząć od prostych modeli
  - modele proste (np. regresja logistyczna) – zazwyczaj duże obciążenie i mniejsze dopasowanie
  - modele złożone (np. sieci neuronowe) – zazwyczaj większa wariancja i nadmierne dopasowanie
  - kompromis między prostymi a złożonymi modelami
  - porównanie wielu modeli
  - dobór parametrów i hiperparametrów

Planowanie eksperymentu

- Parametry i hiperparametry
  - parametr – wartość zostaje ustalona podczas procesu uczenia, dostrajanie parametru wykonywane jest przez algorytm podczas procesu uczenia
    - wagi w sieci neuronowej
  - hiperparametr – parametr „wyższego rzędu”, model nie dostraja hiperparametru, ustalony jest przed uczeniem
    - głębokość drzewa decyzyjnego
    - liczba warstw sieci neuronowej
    - Liczba drzew w lesie losowym

Planowanie eksperymentu

- Hiperparametry
  - metody heurystyczne - pomagają rozwiązać problem w warunkach niedostatecznej informacji i zrekompensować jej brak intuicją oraz wyobraźnią
    - najlepsze założenie, wybieramy przypuszczalnie najlepszy zestaw hiperparametrów oraz małą liczbę ich wartości – duże doświadczenie w analizie danych może ułatwić trafny wybór
    - analiza zmian wartości jednego hipermaprametru przy ustalonych wartościach innych parametrów – wada to założenie, że hiperparametry nie są skorelowane

Planowanie eksperymentu

- Hiperparametry
  - metoda siatki (grid search) – wszystkie możliwe kombinacje interesujących wartości parametrów
    - np. dwa hiperparametry po 5 wartości: 5x5=25
    - zakładając, że model wyliczany jest w ciągu 1s, to w czasie jednego semestru akademickiego można wyliczyć mniej modeli niż dla siedmiu hiperparametrów o możliwych 10 wartościach ☺
    - można stosować do hiperparametrów o małej liczbie przeszukiwań

Planowanie eksperymentu

- Hiperparametry
  - metoda losowania (random search) – wybrane kombinacje interesujących wartości parametrów,
    - ➢ ogranicza przestrzeń poszukiwań
    - ➢ wynik zależy od prawidłowego wyboru przestrzeni poszukiwań
    - ➢ dla każdego problemu należy wyznaczyć niezależnie przestrzeń poszukiwań
    - ➢ można po kilku iteracjach zmienić przestrzeń poszukiwań
    - ➢ można stosować do hiperparametrów o dużej liczbie przeszukiwań

Planowanie eksperymentu

- Hiperparametry
  - metoda optymalizacji baysowskiej (Baysian optimalization) – probabilistyczne przeszukiwanie przestrzeni hiperparametrów, oszacowanie jaka będzie wartość metryki w wybranym punkcie przeszukiwań (siatce) jeśli znane są wartości metryki w innych punktach siatki przez zdefiniowanie prostszej funkcji zastępczej
    - względnie mała potrzebna liczba przeszukiwań w celu znalezienia maksimum metryki
    - skuteczna w przypadku wielu maksimów lokalnych, nie wpada w lokalne optimum

Planowanie eksperymentu

- Definicja ukończenia
  - pojęcie zaczerpnięte z metodyk zwinnych zarządzania projektem – „definition of done”
  - należy ustalić pewne założenia (wartości metryki/metryk), które pozwalają określić, że model jest wystarczająco dobry, może być weryfikowany w praktyce
  - jakie różnice w wartościach metryki są znaczące: praktyka akademicka, praktyka wdrożeń przemysłowych, konkursy uczenia maszynowego