Propozycja projektu – Hurtownie i eksploracja danych

Iuliia Kapustinskaia, Amelia Sroczyńska, Grzegorz Szczepanek · 30.10.2026

Część 1: Hurtownia danych

Temat: Hurtownia danych i panel monitorowania pacjentów z cukrzycą i nadciśnieniem na tle regionalnych wskaźników zdrowotnych.

Pytania analityczne

Każde pytanie łączy dane pacjentów z Synthei z danymi CDC dla tego samego hrabstwa:

1. **Czy wśród naszych pacjentów cukrzyca i nadciśnienie występują tak samo często jak w całym hrabstwie?**
   Synthea: rozpoznania dorosłych pacjentów · CDC: % dorosłych z cukrzycą i nadciśnieniem
2. **Czy tam, gdzie nadciśnienie jest częstsze, nasi pacjenci gorzej je kontrolują?**
   Synthea: ostatni pomiar ciśnienia < 140/90 mmHg · CDC: % dorosłych z nadciśnieniem
3. **Czy nasi pacjenci z cukrzycą częściej mają otyłość niż mieszkańcy ich hrabstwa?**
   Synthea: BMI ≥ 30 · CDC: % dorosłych z otyłością
4. **Czy nasi pacjenci z nadciśnieniem częściej mają wysoki cholesterol niż mieszkańcy hrabstwa?**
   Synthea: badania cholesterolu i rozpoznanie hiperlipidemii · CDC: % dorosłych z wysokim cholesterolem
5. **Czy tam, gdzie więcej ludzi nie ma czym dojechać do lekarza, nasi pacjenci rzadziej przychodzą na wizyty?**
   Synthea: liczba wizyt w roku · CDC: % dorosłych bez dostępu do transportu

Proponowane bazy danych

Baza	Co zawiera	Klucz łączenia
Synthea (HL7 FHIR R4 + CSV)	sztuczni pacjenci z adresem, wizyty, rozpoznania, wyniki HbA1c i cholesterolu, ciśnienie, BMI	kod FIPS hrabstwa z adresu pacjenta
CDC PLACES – dane hrabstw (2025 release, dane z 2023 r.)	prawdziwe szacunki dla hrabstw: % dorosłych z cukrzycą, nadciśnieniem, otyłością, wysokim cholesterolem, bez dostępu do transportu (łącznie 40 wskaźników)	kod FIPS hrabstwa
Słowniki LOINC i ICD-10	nazwy badań, grupy chorób	kody badań i rozpoznań

Synthea + CDC PLACES + słowniki → ETL (Python) → hurtownia (PostgreSQL) → wizualizacja (Excel, tabele przestawne)

Część 2: Eksploracja danych

Temat: Przewidywanie ponownej hospitalizacji pacjentów z cukrzycą w ciągu 30 dni od wypisu.

Zbiór danych

UCI Machine Learning Repository: **„Diabetes 130-US Hospitals for Years 1999–2008”**. Prawdziwe, zanonimizowane dane ze 130 szpitali w USA: 101 766 hospitalizacji pacjentów z cukrzycą, 47 cech (m.in. wiek, liczba leków i procedur, wynik HbA1c, rozpoznania). Licencja CC BY 4.0.

Zadanie eksploracji

Klasyfikacja nadzorowana. Zmienna celu `readmitted` mówi, czy pacjent wrócił do szpitala w ciągu 30 dni. Traktujemy ją jako problem dwuklasowy: ponowne przyjęcie < 30 dni / brak.

Pytania do przemyślenia

Dodatkowe propozycje – do wyboru lub zamiany z pytaniami ze strony 1

#	Pytanie	Synthea	CDC	Uwagi
6	Czy nasi pacjenci z nadciśnieniem biorą leki równie często jak mieszkańcy hrabstwa?	leki przepisane z powodu nadciśnienia	% chorych biorących leki na ciśnienie	wynik przewidywalny: w Synthei leki ma 100% chorych
7	Czy tam, gdzie ludzie rzadziej chodzą na coroczną kontrolę, nasi pacjenci też rzadziej przychodzą?	liczba wizyt w 2023 r.	% dorosłych po kontroli w ostatnim roku	słaby sygnał: hrabstwa różnią się o kilka punktów %
8	Czy w hrabstwach, gdzie otyłość jest częstsza, nasi chorzy mają wyższy HbA1c?	ostatni wynik HbA1c	% dorosłych z otyłością	hrabstwa mało się różnią
9	Czy nasi pacjenci palą tyle samo co mieszkańcy hrabstwa?	status palenia	% palących	w Synthei prawie nikt nie pali
10	Czy cholesterol bada się u naszych pacjentów równie często jak u mieszkańców hrabstwa?	badania cholesterolu w ostatnich 5 latach	% dorosłych po badaniu cholesterolu w ostatnich 5 latach	dobre – ta sama definicja w obu źródłach
11	Czy w hrabstwach, gdzie cukrzyca jest częstsza, częściej badamy HbA1c?	liczba badań HbA1c na chorego w roku	% dorosłych z cukrzycą	ok
12	Czy tam, gdzie więcej ludzi nie ma ubezpieczenia, więcej naszych pacjentów też go nie ma?	ubezpieczyciel pacjenta („NO_INSURANCE”)	% dorosłych bez ubezpieczenia	sprawdzić, ilu takich pacjentów będzie
13	Czy w hrabstwach, gdzie więcej osób ma problem z kupnem jedzenia, nasi chorzy mają gorsze wyniki?	ostatni HbA1c i ciśnienie	% z niepewnością żywnościową	ok
14	Czy nasi pacjenci z cukrzycą mają choroby serca częściej niż mieszkańcy hrabstwa?	rozpoznania chorób serca	% dorosłych z chorobą wieńcową	mało przypadków w Synthei
15	Ilu pacjentów bez wizyty od ponad 12 miesięcy mieszka w hrabstwach o najwyższej częstości cukrzycy?	data ostatniej wizyty	% dorosłych z cukrzycą	w próbce przewlekle chorzy mają regularne wizyty – wynik może być zerowy

Ograniczenia, które wpływają na wybór

- CDC podaje dane tylko dla całych hrabstw, bez podziału na wiek i płeć.
- Hrabstwa Massachusetts są do siebie podobne (np. cukrzyca 8–12%), więc porównania hrabstw między sobą dadzą małe różnice. Pomoże wygenerowanie pacjentów w 2–3 stanach.
- Pytania typu „nasi pacjenci vs CDC” (1, 3, 4, 10) działają nawet przy małych różnicach między hrabstwami.

Model wielowymiarowy (wstępny szkic)

Pojęcie	Co to znaczy	U nas
Fakt	zdarzenie, które liczymy	**Pomiar** (HbA1c, ciśnienie, BMI, cholesterol), **Wizyta**, **Wskaźnik CDC** (jedna wartość dla hrabstwa i roku)
Miara	liczba w fakcie, którą sumujemy lub uśredniamy	wartość pomiaru, „w normie” 0/1 (z tego % pod kontrolą), liczba wizyt, liczba pacjentów, wartość % z CDC
Wymiar	przekrój, według którego grupujemy	Czas, Pacjent, Lokalizacja (hrabstwo), Rozpoznanie, Typ pomiaru, Wskaźnik CDC
Atrybut	cecha opisująca wymiar	Pacjent: płeć, grupa wiekowa, cukrzyca tak/nie, nadciśnienie tak/nie · Lokalizacja: nazwa hrabstwa, kod FIPS, stan, liczba mieszkańców · Typ pomiaru: kod LOINC, nazwa, jednostka, próg normy
Hierarchia	poziomy w wymiarze, od szczegółu do ogółu	Czas: dzień → miesiąc → kwartał → rok · Lokalizacja: hrabstwo → stan · Pacjent: wiek → grupa wiekowa · Rozpoznanie: kod ICD-10 → grupa → rozdział

Wymiary Placówka i Lekarz nie są potrzebne do pytań 1–5, więc na razie ich nie uwzględniamy. Najniższy wspólny poziom lokalizacji to hrabstwo, bo CDC nie podaje danych dla miast ani kodów ZIP.