Propozycja projektu – Hurtownie i eksploracja danych (wersja 2)

Iuliia Kapustinskaia, Amelia Sroczyńska, Grzegorz Szczepanek · 05.11.2026

Zmiany względem wersji z 30.10.2026: zamiast generatora (Synthea) i zagregowanych wskaźników (CDC PLACES) źródłami są dwa istniejące systemy szpitalne (MIMIC-IV i eICU-CRD). Część ED używa klasyfikacji trójklasowej. Uzasadnienie na końcu.

Część 1: Hurtownia danych

Temat: Hurtownia danych o pacjentach szpitalnych z cukrzycą i nadciśnieniem, zintegrowana z dwóch niezależnych systemów szpitalnych USA.

Systemy źródłowe

	MIMIC-IV (demo 2.2)	eICU-CRD (demo 2.0.1)
Co to jest	baza elektronicznej dokumentacji medycznej szpitala Beth Israel Deaconess Medical Center	wielośrodkowa baza oddziałów intensywnej terapii (telemedycyna eICU)
Model	relacyjny, 26 tabel (moduły `hosp` i `icu`)	relacyjny, tabele zdarzeń (`patient`, `diagnosis`, `lab`, `hospital`, …)
Skala demo	100 pacjentów, 275 przyjęć, ok. 107 tys. wyników badań	2520 pobytów OIOM, 1841 pacjentów, 186 szpitali
Identyfikatory	`subject_id`, `hadm_id`	`uniquepid`, `patientunitstayid`, `hospitalid`
Kodowanie diagnoz	ICD-9 i ICD-10 (ok. 2200 i 2300 wierszy)	ICD-9 z ICD-10 w jednym polu tekstowym + hierarchia tekstowa `diagnosisstring`
Czas	daty przesunięte; rok tylko jako przedział (`anchor_year_group`: 2011–13, 2014–16)	offsety w minutach od przyjęcia; rok wypisu 2014 lub 2015; godzina doby
Lokalizacja	jeden szpital	`region` (Midwest, South, West, Northeast), `teachingstatus`, `numbedscategory`
Licencja	otwarty dostęp (PhysioNet)	ODbL v1.0

Wszystkie wymienione liczby policzyliśmy na pobranych plikach.

Heterogeniczność źródeł (to ona uzasadnia ETL): różne identyfikatory, różne wersje ICD, różne modele czasu, różne nazwy pól dla tych samych pojęć (zgon: `hospital_expire_flag` vs `hospitaldischargestatus`), brak HbA1c w eICU. Dane z obu systemów nie dotyczą tych samych pacjentów, więc integracja polega na uzgodnieniu wymiarów, a nie na łączeniu rekordów.

Opcjonalny moduł izby przyjęć MIMIC-IV-ED (osobny pakiet) rozważymy, jeśli starczy czasu. Nie sprawdzaliśmy jego zawartości.

Pytania analityczne

Pytania 1–4 wymagają danych z obu systemów jednocześnie. Porównanie jest ograniczone do pobytów na OIOM (w MIMIC: tabela `icustays`), bo eICU zawiera tylko OIOM.

1. **Czy udział pacjentów z cukrzycą wśród pobytów na OIOM zależy od regionu USA?** MIMIC: diagnozy ICD (E10–E14, 250) w pobytach z `icustays` · eICU: diagnozy po regionie szpitala

2. **Jak często cukrzyca współwystępuje z nadciśnieniem i czy jest to podobne w obu systemach?** MIMIC: ICD-10 I10–I16, ICD-9 401–405 · eICU: te same grupy po ujednoliceniu kodów
3. **Czy śmiertelność szpitalna pacjentów z cukrzycą różni się od pozostałych, w podziale na system i region?** MIMIC: `hospital_expire_flag` · eICU: `hospitaldischargestatus`
4. **Czy pobyt na OIOM jest dłuższy dla pacjentów z cukrzycą i nadciśnieniem niż dla pozostałych?** MIMIC: długość pobytu w `icustays` · eICU: `unitdischargeoffset`
5. **(tylko MIMIC, ograniczone liczebnościowo)** Jaki odsetek pacjentów z cukrzycą ma HbA1c poniżej 7%? MIMIC: tabela `labevents` (`itemid` 50852 – „% Hemoglobin A1c"). W demo jest 20 pacjentów z cukrzycą i wynikiem HbA1c, więc traktujemy to jako przykład działania miary, nie jako wniosek statystyczny.

Model wielowymiarowy

Dla każdego źródła powstaje osobny schemat gwiazdy. Gwiazdy dzielą wymiary uzgodnione (conformed), co daje konstelację faktów.

- **Gwiazda 1: Przyjęcie MIMIC** (ziarno: jedno przyjęcie do szpitala, `hadm_id`)
- **Gwiazda 2: Pobyt OIOM eICU** (ziarno: jeden pobyt na oddziale, `patientunitstayid`)
- **Gwiazda 3: Pomiar HbA1c MIMIC** (ziarno: jeden wynik badania)

Pojęcie	Gwiazda 1	Gwiazda 2	Gwiazda 3
Fakt	Przyjęcie	Pobyt OIOM	Pomiar HbA1c
Miary	liczba przyjęć, czas pobytu (dni), zgon (0/1), liczba rozpoznań	liczba pobytów, czas pobytu na OIOM (dni), zgon (0/1)	wartość HbA1c (%), „w normie" (0/1, < 7%), liczba pomiarów
Wymiary	Czas, Pacjent, Diagnoza, Placówka	Czas, Pacjent, Diagnoza, Placówka	Czas, Pacjent, Placówka

Wymiary uzgodnione i ich atrybuty

Wymiar	Atrybuty	Hierarchia
Czas	grupa lat / rok wypisu, dzień pobytu (względny), godzina doby, pora doby	okres (2011–13, 2014–16, 2014, 2015) → rok → dzień pobytu → godzina
Pacjent	płeć, wiek, grupa wiekowa, rasa/pochodzenie (jeśli dostępne w obu)	pacjent → grupa wiekowa
Diagnoza	kod, wersja klasyfikacji (ICD-9/ICD-10), nazwa, grupa (cukrzyca / nadciśnienie / inne)	kod → grupa → rozdział ICD
Placówka	system źródłowy, region, status szpitala uczącego, kategoria wielkości (liczba łóżek), szpital	system → region → szpital

Uwagi do modelu:

- **Czas jest względny**, bo źródła nie podają prawdziwych dat kalendarzowych. Hierarchia dzień → miesiąc → rok nie jest możliwa. Opisujemy to jako cechę źródeł, nie błąd modelu.
- **Diagnoza** jest w relacji wiele do wielu z faktem (jedno przyjęcie ma wiele rozpoznań). Rozwiązujemy to tabelą mostkową lub flagami cukrzyca/nadciśnienie w wymiarze Pobyt.
- **Placówka** w eICU ma 18 szpitali bez regionu i część bez liczby łóżek. Przypisujemy im wartość „nieznany".
- Poziom „szpital" jest zachowany w modelu, ale **nie służy do porównań**: w eICU demo przypada 10–40 pobytów na szpital (maks. 16 z cukrzycą), więc porównujemy regiony.

Architektura (zgodnie z wykładem)

MIMIC-IV + eICU-CRD (warstwa źródłowa OLTP) → ETL w Pythonie z obszarem przejściowym (ekstrakcja, ujednolicenie ICD-9/ICD-10, mapowanie nazw, wyliczenie miar) → hurtownia relacyjna w PostgreSQL (ROLAP, schemat gwiazdy, konstelacja) → wizualizacja w Excelu (tabele przestawne).

Część 2: Eksploracja danych

Temat: Przewidywanie ponownej hospitalizacji pacjentów z cukrzycą.

Zbiór danych: UCI Machine Learning Repository, „Diabetes 130-US Hospitals for Years 1999–2008”: 101 766 hospitalizacji, 47 cech, licencja CC BY 4.0.

Zadanie: klasyfikacja nadzorowana **trójklasowa**. Zmienna celu `readmitted` ma trzy wartości:

- `<30` – powrót do szpitala w ciągu 30 dni,
- `>30` – powrót po więcej niż 30 dniach,
- `NO` – brak powrotu.

Wariant dwuklasowy (`<30` vs reszta) traktujemy jako dodatkowe porównanie, nie jako zadanie podstawowe.

Plan eksperymentu

Element	Decyzja	Uzasadnienie
Metryki	macro-F1, F1 dla klasy `<30`, macierz pomyłek, porównanie z klasyfikatorem większościowym	accuracy jest mylące dla danych niezbalansowanych (`NO` 53,9%, `>30` 34,9%, `<30` 11,2%; klasyfikator większościowy ma accuracy ok. 54%)
Walidacja	walidacja krzyżowa grupowana po `patient_nbr`	ten sam pacjent ma w zbiorze wiele pobytów, zwykła walidacja powodowałaby wyciek
Czyszczenie	usunięcie pobytów zakończonych zgonem lub przekazaniem do hospicjum	takie przypadki nie mogą się zakończyć ponowną hospitalizacją (kody `discharge_disposition_id` 11, 13, 14, 19, 20, 21; usuwa to 2423 z 101 766 rekordów)
Modele	regresja logistyczna (punkt odniesienia), drzewo decyzyjne, las losowy, gradient boosting	od prostych do złożonych, zgodnie z wykładem
Hiperparametry	random search w uzasadnionych przedziałach (np. głębokość drzewa, liczba drzew, współczynnik uczenia)	duża liczba kombinacji, grid search byłby zbyt kosztowny
Niezbalansowanie	wagi klas; porównanie z oversamplingiem tylko na zbiorze uczącym	oversampling na całości zbioru powoduje wyciek
„Definition of done”	ustalamy z góry minimalną poprawę macro-F1 względem punktu odniesienia, którą uznajemy za istotną	zgodnie z wykładem o planowaniu eksperymentu
Wnioski	opcjonalnie test statystyczny różnic między modelami	

Uzasadnienie decyzji

Decyzja	Dlaczego
Rezygnacja z Synthea	to generator, a nie istniejący system informatyczny
Rezygnacja z CDC PLACES	dane są silnie zagregowane (jedna wartość na hrabstwo), bez danych transakcyjnych. Hurtownia ma stać na danych niezagregowanych. Dodatkowo żadne źródło szpitalne nie podaje hrabstwa pacjenta (dane są zanonimizowane), więc nie ma klucza łączenia
MIMIC-IV + eICU-CRD	rzeczywiste, niezależne systemy szpitalne z własnymi schematami, różnymi identyfikatorami i kodowaniem, co uzasadnia ETL i integrację

Decyzja	Dlaczego
Zostajemy przy cukrzycy i nadciśnieniu	zachowujemy temat zgłoszony 30.10. Zmienia się tło porównawcze: zamiast wskaźników hrabstw jest porównanie systemów i regionów
Klasyfikacja trójklasowa	`>30` i `NO` to różne zdarzenia kliniczne, scalenie ich ukrywałoby informację

Ograniczenia i punkty do potwierdzenia

1. **Czy zrzut bazy badawczej (MIMIC-IV, eICU) jest akceptowany jako „istniejący system”?** To są bazy zbudowane z systemów szpitalnych, a nie same systemy. Chcemy to potwierdzić z prowadzącym.
2. **Liczebność:** MIMIC demo ma 35 pacjentów z cukrzycą (20 z wynikiem HbA1c). eICU ma 346 pobytów z cukrzycą, ale brak wyników HbA1c. Porównania regionów obejmują Northeast tylko 14 pobytów z cukrzycą.
3. **Ciśnienie krwi:** w MIMIC jest w tabeli `omr` (zapisy ambulatoryjne), a w eICU w `vitalAperiodic` (pomiar nieinwazyjny na OIOM, 2328 z 2520 pobytów) i w `vitalPeriodic` (inwazyjny, 430 pobytów). Kontekst pomiaru jest inny, a dane zawierają wartości 0 do usunięcia, więc nadciśnienie definiujemy rozpoznaniem, a pomiar traktujemy jako opcjonalną miarę.
4. **Brak kalendarza:** wymiar Czas jest względny, więc analizy trendów w czasie nie są możliwe.
5. Dane z MIMIC-IV i eICU opisują pacjentów OIOM i szpitalnych, więc wnioski nie przenoszą się na populację ogólną.