Rejestr decyzji projektowych – HD i ED

Iuliia Kapustinskaia, Amelia Sroczyńska, Grzegorz Szczepanek · 05.11.2026

Do każdej decyzji: **co wybraliśmy**, **jakie alternatywy odrzuciliśmy i dlaczego**, **jaka jest słabość** (czego prowadzący może się czepić). Liczby pochodzą z pobranych plików demo MIMIC-IV 2.2 i eICU-CRD 2.0.1. Rzeczy, których nie sprawdziliśmy, są oznaczone jako **niezweryfikowane**.

Zasada prowadzącego: *jeśli robimy A, a nie B, musimy umieć udowodnić dlaczego.* Poniżej jest to „dlaczego".

Część HD: źródła danych

#	Decyzja	Rozważone i odrzucone	Dlaczego tak	Słabość / obrona
1	**Źródła: MIMIC-IV (demo) + eICU-CRD (demo)**	**Synthea** (generator sztucznych pacjentów)	Prowadzący: ma nie być generatora, ma być istniejący system informatyczny. Dane syntetyczne nie mają własnego schematu operacyjnego	
		CDC PLACES jako główne źródło	Dane silnie zagregowane (jedna wartość na hrabstwo), bez transakcji. Wykład: hurtownia przechowuje dane mało zagregowane, silnie zagregowane są cechą składnicy. Do tego żadne źródło szpitalne nie podaje hrabstwa pacjenta, więc nie ma klucza łączenia	Zmienia to zgłoszony temat (patrz #3)
		Diabetes 130 (UCI) jako źródło HD	To jedna płaska tabela z jednego zbioru, a prowadzący wymaga wielu baz. Zostaje jako zbiór do części ED	
		OpenMRS demo (5000 pacjentów)	Jest bliżej „prawdziwego systemu" (dump bazy działającego oprogramowania). Wg wyników wyszukiwania oryginalne dane demo pochodzą z prawdziwych danych, mocno zdeanonimizowanych: **imiona, wiek i płeć są przemieszane**, a tekst swobodny usunięty. Osobno aplikacja referencyjna potrafi generować pacjentów demo. Przemieszany wiek i płeć psują wymiar Pacjent (grupa wiekowa, płeć)	Rezerwa, jeśli prowadzący odrzuci MIMIC/eICU. **Częściowo zweryfikowane:** strona dokumentacji nie załadowała się w całości, a samego dumpu nie pobieraliśmy. Nie wiemy, czy zawiera cukrzycę, nadciśnienie ani HbA1c
		Pełny MIMIC-IV	Wymaga szkolenia i umowy na PhysioNet, więc niedostępny na czas	Przez to demo ma tylko 100 pacjentów
		MIMIC-IV-ED (izba przyjęć) jako trzecie źródło	To moduł tej samej bazy (łączy się po `subject_id`), więc nie jest niezależnym źródłem. Nie sprawdzaliśmy jego zawartości	Opcjonalnie, jeśli starczy czasu

#	Decyzja	Rozważone i odrzucone	Dlaczego tak	Słabość / obrona
2	**Dwa niezależne systemy**	jedno źródło	Wymóg: odpowiedź ma wymagać kilku źródeł. Pacjenci się nie pokrywają, więc integracja = uzgodnienie wymiarów, nie łączenie rekordów	Prowadzący może zapytać, gdzie „prawdziwa" integracja. Odpowiedź: różne ID, ICD-9/ICD-10, różne modele czasu, różne nazwy pól. **Główne ryzyko:** MIMIC i eICU to bazy badawcze zbudowane z systemów szpitalnych, a nie same systemy, co trzeba potwierdzić u prowadzącego
3	**Zostajemy przy temacie cukrzyca + nadciśnienie**	zmiana tematu	Temat był już zgłoszony, a zmiana jest ryzykowna. Domena szpitalna pasuje do obu części projektu	Znika „tło regionalnych wskaźników z CDC". Zastępuje je porównanie systemów i regionów. Trzeba to powiedzieć wprost
4	**Porównujemy tylko pobyty na OIOM**	wszystkie przyjęcia MIMIC	eICU zawiera tylko OIOM. Porównanie całych przyjęć MIMIC z OIOM eICU byłoby nieuczciwe (inna populacja). W MIMIC bierzemy `icustays`	Zmniejsza liczebność MIMIC (jeszcze nie policzona)

Część HD: model

#	Decyzja	Rozważone i odrzucone	Dlaczego tak	Słabość / obrona
5	**Osobna gwiazda dla każdego źródła + wymiary uzgodnione (konstelacja)**	jedna wspólna tabela faktów „Pobyt" z kolumną źródła	Prowadzący pytał o osobne gwiazdy dla każdego zbioru. Źródła mają różne ziarno i miary (przyjęcie do szpitala vs pobyt na oddziale, HbA1c tylko w MIMIC)	Wspólna tabela byłaby prostsza dla zapytań międzysystemowych. Ratują nas wymiary uzgodnione
6	**Wymiar Czas jest względny** (grupa lat / rok wypisu, dzień pobytu, godzina doby)	wymiar kalendarzowy dzień → miesiąc → rok	**Sprawdzone:** MIMIC przesuwa daty (lata 2110–2201) i podaje tylko przedział `anchor_year_group` (2011–13, 2014–16). eICU ma offsety w minutach i rok wypisu (2014, 2015). Kalendarza z tego nie zbudujemy	Brak analizy trendów w czasie. To cecha źródeł, nie błąd modelu
7	**Placówka: porównujemy regiony, nie szpitale**	porównanie szpital vs szpital	**Sprawdzone:** eICU demo ma 186 szpitali po 10–40 pobytów (maks. 16 z cukrzycą w jednym szpitalu). Statystycznie bez sensu. Region ma 14–125 pobytów z cukrzycą	Northeast to tylko 14 pobytów z cukrzycą. 18 szpitali nie ma regionu (wartość „nieznany", 210 pobytów)
8	**Diagnozy: tabela mostkowa lub flagi cukrzyca/nadciśnienie**	jedna diagnoza na fakt	Jedno przyjęcie ma wiele rozpoznań (relacja wiele do wielu)	Tabela mostkowa komplikuje zapytania, flagi tracą szczegóły. Wybór zostawiamy do implementacji
9	**Diagnoza definiowana kodami ICD (z mapowaniem ICD-9 i ICD-10)**	definicja po wyniku HbA1c	HbA1c nie ma w eICU (0 wierszy). Kody są w obu źródłach. MIMIC ma mieszankę: 2313 kodów ICD-10 i 2193 kodów ICD-9	Kod rozpoznania nie równa się rzeczywistej chorobie. Mapowanie ICD-9 → ICD-10 jest przybliżone

#	Decyzja	Rozważone i odrzucone	Dlaczego tak	Słabość / obrona
10	**Nadciśnienie definiowane rozpoznaniem** (pomiar ciśnienia tylko jako opcjonalna miara)	definicja po pomiarze ciśnienia	**Sprawdzone:** pomiary są w obu systemach, ale znaczą co innego. MIMIC: tabela `omr` (866 pomiarów, 70 pacjentów, zapisy ambulatoryjne). eICU: `vitalAperiodic` (nieinwazyjne ciśnienie, 2328 z 2520 pobytów) i `vitalPeriodic` (inwazyjne, tylko 430 pobytów). To monitorowanie na OIOM, nie kontrola ciśnienia. Dane zawierają wartości 0 (szum)	Porównanie wartości ciśnienia między systemami byłoby mylące (inny kontekst pomiaru), więc kontrolę ciśnienia tylko opcjonalnie, z czyszczeniem zer
11	**Pytanie o HbA1c tylko w MIMIC (pytanie 5)**	pytanie o HbA1c w obu systemach	eICU nie ma HbA1c. W MIMIC jest 20 pacjentów z cukrzycą i wynikiem	Zbyt mało na wniosek statystyczny. Traktujemy jako pokaz działania miary
12	**PostgreSQL (ROLAP), ETL w Pythonie, Excel (tabele przestawne)**	MOLAP	Slajdy: ROLAP to relacyjne odwzorowanie modelu wielowymiarowego, bez ograniczeń liczby wymiarów, często do centralnej hurtowni. Excel jest wymieniony w wymaganiach prowadzącego	

Część ED

#	Decyzja	Rozważone i odrzucone	Dlaczego tak	Słabość / obrona
13	**Zbiór: UCI Diabetes 130** (101 766 hospitalizacji)	eksploracja na MIMIC / eICU	Slajdy podają UCI MLR jako przykład. MIMIC demo ma 100 pacjentów, co jest za mało na uczenie modelu	Dwie części projektu opierają się na różnych danych. Obie dotyczą cukrzycy
14	**Trzy klasy: `<30`, `>30`, `NO`**	dwie klasy (`<30` vs reszta)	Prowadzący chce 3 klas. `>30` i `NO` to różne zdarzenia kliniczne, scalenie ukrywa informację. Wariant dwuklasowy zostaje jako dodatkowe porównanie	Trudniejsze zadanie, niższe wyniki. **Sprawdzone** (101 766 rekordów): `NO` 53,91%, `>30` 34,93%, `<30` 11,16%. Klasa `<30` jest mała, więc F1 dla niej będzie niski
15	**Metryki: macro-F1, F1 dla `<30`, macierz pomyłek, punkt odniesienia**	accuracy	Wykład: błąd całkowity nie jest właściwą metryką dla danych niezbalansowanych	
16	**Walidacja krzyżowa grupowana po `patient_nbr`**	zwykła walidacja krzyżowa	**Sprawdzone:** 71 518 pacjentów, 16 773 z więcej niż jednym pobytem (do 40), co daje 47 021 rekordów (46%). Przy zwykłym podziale ten sam pacjent byłby w uczeniu i teście (wyciek)	Zmniejsza liczbę efektywnych próbek
17	**Usuwamy pobyty zakończone zgonem lub hospicjum**	zostawienie wszystkich	Taki pacjent nie może wrócić do szpitala, więc to szum w klasie `NO`	**Sprawdzone** w `IDS_mapping.csv`: kody 11 (Expired), 13, 14 (Hospice), 19, 20, 21 (Expired, hospicjum). Usuwa to 2423 rekordów (zostaje 99 343), z czego 2337 miało `NO`. 43+43 z nich ma jednak `<30` / `>30` (anomalia w danych, nie umiemy jej wyjaśnić)

#	Decyzja	Rozważone i odrzucone	Dlaczego tak	Słabość / obrona
18	**Modele: regresja logistyczna → drzewo → las losowy → gradient boosting**	tylko jeden złożony model	Wykład: zacząć od prostych, porównać wiele modeli. Twierdzenie „no free lunch”: żaden algorytm nie jest uniwersalny	
19	**Hiperparametry: random search**	grid search; optymalizacja bayesowska	Wykład: grid search tylko przy małej liczbie przeszukiwań. Random search ogranicza przestrzeń. Bayesowska jest zaawansowana i nie jest potrzebna na tym etapie	Wynik zależy od dobrze dobranych przedziałów
20	**Niezbalansowanie: wagi klas, oversampling tylko na zbiorze uczącym**	oversampling na całości	Oversampling przed podziałem powoduje wyciek	
21	**„Definition of done” ustalona z góry**	brak progu	Wykład: trzeba ustalić, jaka wartość metryki uznaje model za wystarczający	Próg do wybrania po policzeniu punktu odniesienia

---

Najsłabsze miejsca, na które trzeba się przygotować

1. **„To bazy badawcze, nie systemy”** (#1, #2). Najgroźniejsze. Dobrze zapytać prowadzącego, zanim zbudujemy ETL.
2. **Zmiana tematu** (#3). Powiedzieć wprost i uzasadnić uwagami o zagregowanych danych.
3. **Mała liczebność** (#7, #11): Northeast 14 pobytów, HbA1c 20 pacjentów. Zbiór UCI: klasa `<30` to 11,16%.
4. **Czas względny** (#6). Zadbać, żeby nie obiecywać analiz trendów.
5. **Częściowo zweryfikowane**: OpenMRS (#1), dump nie był pobierany ani sprawdzany pod kątem cukrzycy i nadciśnienia.