Słowniczek do projektu

Najważniejsze pojęcia z propozycji projektu, prostym językiem

Projekt w trzech zdaniach

> Bierzemy sztucznych pacjentów z cukrzycą i nadciśnieniem (Synthea) i prawdziwe dane o zdrowiu mieszkańców hrabstw USA (CDC). Łączymy je po hrabstwie w hurtowni danych, żeby sprawdzić, jak nasi pacjenci wypadają na tle swojego regionu. W drugiej części na prawdziwych danych szpitalnych uczymy model przewidywać, kto wróci do szpitala w ciągu 30 dni.

Baza danych a hurtownia danych

	Zwykła baza danych	Hurtownia danych
Po co	bieżąca praca: zapisać wizytę, dodać wynik	analiza: odpowiadać na pytania o całość
Dane	aktualne, z jednego systemu	historyczne, z wielu źródeł, oczyszczone i połączone
Operacje	dużo małych zapisów i zmian	głównie odczyt i duże zapytania (sumy, średnie)
Przykład	system rejestracji w przychodni	„jaki % cukrzyków ma dobry wynik, w podziale na hrabstwa i lata?”

Hurtownia danych

Pojęcie	Co to znaczy
ETL	Extract, Transform, Load: pobieramy dane ze źródeł, czyścimy i przeliczamy je, a potem ładujemy do hurtowni.
Pytanie analityczne	Pytanie biznesowe, na które ma odpowiadać hurtownia. Wymaganie prowadzącego: odpowiedź musi łączyć dane z kilku źródeł.
Fakt	Zdarzenie, które liczymy, np. pomiar ciśnienia albo wizyta. Tabela faktów ma najwięcej wierszy.
Miara	Liczba w fakcie, którą sumujemy lub uśredniamy, np. wartość HbA1c, liczba wizyt.
Wymiar	Przekrój, według którego grupujemy fakty, np. czas, pacjent, hrabstwo. Odpowiada na pytanie „według czego?”.
Atrybut	Cecha opisująca wymiar, np. płeć i grupa wiekowa pacjenta.
Hierarchia	Poziomy w wymiarze od szczegółu do ogółu, np. dzień → miesiąc → rok. Pozwala „zwijać” i „rozwijać” wyniki.
Schemat gwiazdy	Układ tabel: tabela faktów w środku, tabele wymiarów dookoła. Na rysunku wygląda jak gwiazda.
Konstelacja faktów	Kilka tabel faktów, które dzielą te same wymiary. U nas: Pomiar, Wizyta i Wskaźnik CDC.
Model logiczny	Konkretne tabele w bazie: kolumny, typy danych, klucze.
Klucz główny / obcy (PK / FK)	PK jednoznacznie identyfikuje wiersz. FK wskazuje na wiersz w innej tabeli i łączy tabele.
GROUP BY / ROLLUP	SQL: GROUP BY grupuje i liczy np. średnią. ROLLUP dokłada sumy częściowe i ogólną, np. dla hrabstwa, stanu i łącznie.
Tabela przestawna	Narzędzie Excela, które jednym przeciągnięciem grupuje i sumuje dane.
KPI	Kluczowy wskaźnik, jedna liczba mówiąca, jak idzie, np. % pacjentów z ciśnieniem pod kontrolą.

Dane i medycyna

Pojęcie	Co to znaczy
Synthea	Darmowy program, który generuje sztucznych pacjentów z realistyczną historią leczenia i adresem w USA.
HL7 FHIR	Standard zapisu danych medycznych. Każda informacja (pacjent, wizyta, wynik) ma ustalony format.
CDC PLACES	Prawdziwe, publiczne dane amerykańskiego CDC: jaki % dorosłych w danym hrabstwie ma np. cukrzycę albo otyłość. Pochodzą z dużej ankiety BRFSS.
Hrabstwo i kod FIPS	Hrabstwo (county) to jednostka podziału stanu USA, coś jak nasz powiat. FIPS to jego numer, np. 25013. Po nim łączymy oba źródła.
Wskaźnik surowy / standaryzowany	Surowy: zwykły odsetek w populacji. Standaryzowany: przeliczony tak, jakby wszędzie była ta sama struktura wieku. Nie mieszamy ich ze sobą.
HbA1c	Badanie krwi pokazujące średni cukier z ostatnich 2–3 miesięcy. Poniżej 7% oznacza dobrze kontrolowaną cukrzycę.

Nadciśnienie pod kontrolą	Ciśnienie poniżej 140/90 mmHg.
BMI i otyłość	BMI to waga podzielona przez wzrost do kwadratu. BMI ≥ 30 oznacza otyłość.
LOINC, ICD-10, SNOMED CT	Słowniki kodów: LOINC dla badań (HbA1c to 4548-4), ICD-10 i SNOMED CT dla chorób (cukrzyca typu 2 w ICD-10 to E11).
Pseudonimizacja	Zamiana danych identyfikujących osobę na sztuczny identyfikator.

Eksploracja danych

Pojęcie	Co to znaczy
Eksploracja danych	Szukanie wzorców w danych i budowanie modeli, które coś przewidują albo grupują.
Klasyfikacja nadzorowana	Model uczy się na przykładach ze znaną odpowiedzią i przewiduje ją dla nowych przypadków. U nas: czy pacjent wróci do szpitala.
Nienadzorowana	Bez znanej odpowiedzi: model sam grupuje podobne przypadki (klasteryzacja).
Zmienna celu / cechy	Zmienna celu to to, co przewidujemy (u nas readmitted). Cechy to dane wejściowe, np. wiek i liczba leków.
Readmisja	Ponowne przyjęcie do szpitala po wypisie, u nas w ciągu 30 dni.
UCI MLR	Repozytorium darmowych zbiorów danych do uczenia maszynowego, z którego bierzemy zbiór o cukrzycy.
Hiperparametr	Ustawienie algorytmu wybierane przed uczeniem, np. głębokość drzewa decyzyjnego.
Walidacja krzyżowa	Dzielimy dane na części i uczymy oraz testujemy model kilka razy, żeby wynik był wiarygodny.
Accuracy / F1	Miary jakości modelu. Accuracy to % trafnych odpowiedzi. F1 lepiej sprawdza się, gdy jednej klasy jest mało (mało osób wraca do szpitala).