Projekt po ludzku

Wyjaśnienie bez żargonu. Czytaj od góry do dołu, każda część opiera się na poprzedniej.

---

1. O co w ogóle chodzi

Projekt ma dwie niezależne części.

Część pierwsza (hurtownia danych): zbieramy dane o pacjentach z dwóch szpitali w jednym uporządkowanym miejscu, żeby móc łatwo odpowiadać na pytania, np. „czy pacjenci z cukrzycą leżą dłużej niż inni?”.

Część druga (eksploracja danych): uczymy komputer zgadywać, którzy pacjenci z cukrzycą wrócą do szpitala po wypisie.

Obie części dotyczą cukrzycy, ale używają **innych danych** i nie zależą od siebie.

2. Co się zmieniło po uwagach prowadzącego

Było	Jest	Dlaczego
dane ze Syntheą (program, który wymyśla pacjentów)	dane z prawdziwych baz szpitalnych	prowadzący chce istniejącego systemu, a nie generatora
dane z CDC (jedna liczba na całe hrabstwo)	dane o pojedynczych pacjentach	hurtownia ma liczyć z drobnych danych, a nie z gotowych sum
przewidujemy: wróci albo nie wróci (2 możliwości)	przewidujemy: wróci szybko, wróci później, nie wróci (3 możliwości)	w danych są trzy odpowiedzi, a my dwie sklejaliśmy w jedną

Temat zostaje ten sam: cukrzyca i nadciśnienie.

---

3. Część pierwsza: hurtownia, krok po kroku

Po co ona jest

Szpital prowadzi swoją bazę do codziennej pracy: przyjęcie pacjenta, wynik badania, wypis. Taka baza jest szybka w zapisywaniu, ale kiepska w odpowiadaniu na pytania typu „jak to wygląda ogółem”.

Hurtownia to osobna kopia danych, poukładana tak, żeby łatwo było liczyć i porównywać. Przenoszenie danych ze szpitala do hurtowni (z oczyszczaniem po drodze) nazywa się **ETL**.

Obraz do zapamiętania: szpital to zeszyt, do którego wpisuje się wszystko na bieżąco. Hurtownia to segregator, w którym to samo jest przepisane tak, żeby dało się policzyć.

Skąd bierzemy dane

Dwie otwarte bazy szpitalne z USA:

- **MIMIC-IV:** jeden szpital w Bostonie. W naszej wersji demo jest tylko 100 pacjentów.
- **eICU:** wiele szpitali z całych Stanów, ale tylko oddziały intensywnej terapii (OIOM). W demo jest 2520 pobytów.

Pacjenci w obu bazach to **różni ludzie**. Nie łączymy więc „tego samego pacjenta z dwóch miejsc". Łączymy dane tak, żeby dało się je porównać.

Dlaczego to nie jest takie proste

Obie bazy opisują to samo inaczej. Trzy przykłady:

1. **Choroby są zapisane kodami w dwóch wersjach** (starszej i nowszej). Trzeba je sprowadzić do jednego sposobu, żeby „cukrzyca" znaczyła to samo w obu.
2. **Daty są ukryte** (dla ochrony prywatności). MIMIC podaje tylko przedział lat, np. 2011–2013. eICU podaje, ile minut po przyjęciu coś się stało. Nie mamy więc prawdziwego kalendarza.
3. **Badania cukrzycy (HbA1c) są tylko w MIMIC.** W eICU ich nie ma w ogóle.

To wszystko jest właśnie **pracą ETL** i dlatego projekt ma sens.

Najważniejsze pojęcia na jednym przykładzie

Wyobraź sobie paragon ze sklepu. Jeden wiersz na paragonie to jedna rzecz kupiona.

U nas jeden wiersz to **jeden pobyt pacjenta na OIOM**.

Pojęcie	Co to znaczy	U nas
Fakt	jedno zdarzenie, które zapisujemy (wiersz na paragonie)	jeden pobyt na OIOM
Miara	liczba przy tym zdarzeniu, którą można dodawać lub uśredniać (cena na paragonie)	ile dni trwał pobyt, czy pacjent zmarł (0 lub 1)
Wymiar	„według czego" chcemy to oglądać (kto, gdzie, kiedy)	pacjent, choroba, miejsce, czas
Atrybut	szczegół opisujący wymiar	pacjent: płeć, wiek. Miejsce: region
Hierarchia	drabinka od szczegółu do ogółu	szpital → region → cały system

Jak to rozpoznać: jeśli możesz to **zsumować lub uśrednić**, to miara. Jeśli według tego **grupujesz**, to wymiar lub jego atrybut.

Jedno zdanie, które używa wszystkiego naraz:

> „Średni czas pobytu (miara) pacjentów z cukrzycą (atrybut wymiaru *choroba*) w regionie South (poziom hierarchii *miejsce*)."

Gwiazda

Tabela z faktami jest w środku, a wokół niej wymiary. Tak to wygląda na rysunku, stąd nazwa **schemat gwiazdy**:

```
              Pacjent
                |
  Czas ——— [ POBYT NA OIOM ] ——— Choroba
                |
             Miejsce
```

U nas są **trzy gwiazdy**, bo mamy trzy rodzaje zdarzeń:

1. przyjęcie do szpitala (MIMIC),
2. pobyt na OIOM (eICU),
3. wynik badania HbA1c (MIMIC).

Wymiary **Choroba** i **Miejsce** są wspólne dla gwiazd. Dzięki temu można porównywać dane z MIMIC i eICU. Kilka gwiazd ze wspólnymi wymiarami to **konstelacja**. Prowadzący prosił właśnie o „osobne gwiazdy dla każdego zbioru".

Dwa drobiazgi, które mogą paść w pytaniach:

- **Ziarno** to odpowiedź na pytanie „co dokładnie znaczy jeden wiersz?". U nas: jedno przyjęcie albo jeden pobyt.
- Jedno przyjęcie ma często kilka chorób naraz, więc potrzebna jest dodatkowa tabela łącząca pobyty z chorobami (tabela mostkowa).

Na jakie pytania odpowiadamy

Pytania muszą wymagać **obu** baz naraz:

1. Czy cukrzyca jest częstsza w jednych regionach USA niż w innych?
2. Jak często cukrzyca idzie w parze z nadciśnieniem, i czy w obu bazach tak samo?
3. Czy pacjenci z cukrzycą częściej umierają w szpitalu niż pozostali?
4. Czy leżą dłużej na OIOM?
5. (tylko MIMIC) Ilu pacjentów z cukrzycą ma dobrze wyrównany cukier? Tutaj danych jest mało (20 osób), więc to tylko pokaz, że miara działa.

Czego nie da się zrobić (i trzeba to uczciwie powiedzieć)

- **Nie zrobimy trendów w czasie**, bo nie mamy prawdziwych dat.
- **Nie porównamy pojedynczych szpitali**, bo na jeden szpital w eICU przypada tylko 10–40 pobytów. Porównujemy regiony.
- **Nie porównamy wartości ciśnienia** między bazami, bo w jednej to pomiary z wizyt, a w drugiej z monitora na OIOM. Dlatego nadciśnienie definiujemy rozpoznaniem lekarza.

---

4. Część druga: zgadywanie, kto wróci do szpitala

Co robimy

Mamy gotowy zbiór: **ponad 100 tysięcy pobytów w szpitalach z cukrzycą**. Przy każdym wiemy, co się potem stało. Są trzy możliwości:

- `<30`: wrócił w ciągu 30 dni,
- `>30`: wrócił później,
- `NO`: nie wrócił.

Komputer uczy się na części pobytów, a potem sprawdzamy, jak zgaduje na pobytach, których nie widział.

Rozkład odpowiedzi: nie wrócił 54%, wrócił później 35%, wrócił szybko tylko 11%.

Dlaczego „procent trafnych odpowiedzi" oszukuje

Jeśli komputer **zawsze** odpowie „nie wróci", będzie miał rację w 54% przypadków, nie umiejąc nic. To wygląda przyzwoicie, a jest bezwartościowe.

Dlatego liczymy miarę, która bierze pod uwagę **każdą z trzech odpowiedzi osobno** (to się nazywa macro-F1) i patrzymy, co z czym się myli (macierz pomyłek).

Dlaczego jeden pacjent nie może być w nauce i w sprawdzianie naraz

To jak egzamin z zadań, które uczeń już widział. W zbiorze jest 71 tysięcy pacjentów, a prawie połowa pobytów (47 tysięcy) należy do osób, które były w szpitalu **więcej niż raz**. Gdyby ta sama osoba trafiła i do uczenia, i do testu, komputer „podejrzałby" odpowiedź. Dlatego dzielimy dane **po pacjentach, a nie po pobytach**.

Inne decyzje po ludzku

- **Usuwamy pobyty zakończone śmiercią lub hospicjum** (2423 z ponad 100 tysięcy), bo taki pacjent nie ma jak wrócić do szpitala.
- **Zaczynamy od prostego modelu** (regresja logistyczna), żeby mieć punkt odniesienia. Potem próbujemy trudniejszych (drzewo, las, boosting) i sprawdzamy, czy naprawdę są lepsze.
- **Ustawienia modelu** (np. jak głębokie ma być drzewo) to „pokrętła", które ustawiamy sami przed nauką. Nie testujemy wszystkich kombinacji, tylko losowe, bo to szybsze (random search).
- **Z góry ustalamy, co uznamy za „wystarczająco dobry wynik"**, żeby nie szukać w nieskończoność.

---

5. Co powiedzieć, gdy prowadzący zapyta „dlaczego”

Zasada prowadzącego: *jeśli robicie A, a nie B, musicie umieć powiedzieć dlaczego.* Zestaw gotowców:

- **Dlaczego nie Synthea?** Bo to program, który wymyśla pacjentów, a my mamy użyć istniejącego systemu.
- **Dlaczego nie CDC?** Bo to gotowe sumy dla całych hrabstw, a hurtownia ma liczyć z drobnych danych. Poza tym w bazach szpitalnych nie ma adresu pacjenta, więc nie ma jak ich połączyć.
- **Dlaczego trzy klasy?** Bo „wrócił po miesiącu” i „nie wrócił” to różne sytuacje. Sklejenie ich ukrywałoby informację.
- **Dlaczego region, a nie szpital?** Bo na jeden szpital przypada za mało pobytów, żeby coś porównywać.
- **Dlaczego nie ma trendów w czasie?** Bo dane celowo ukrywają prawdziwe daty.

Najsłabsze miejsce projektu (lepiej powiedzieć to pierwsze, niż żeby prowadzący to znalazł): MIMIC i eICU to bazy przygotowane do badań z prawdziwych systemów szpitalnych. Trzeba zapytać prowadzącego, czy uzna je za „istniejący system”.

---

6. Co dalej

1. **Zapytać prowadzącego** o to jedno pytanie z końca punktu 5. Od odpowiedzi zależy, czy budujemy na MIMIC i eICU.
2. **Przepisać propozycję projektu** w prostym języku, na bazie tego dokumentu.
3. **Zbudować hurtownię** i ETL.
4. **Zrobić eksperymenty** w części drugiej.

Dokładne liczby, alternatywy i uzasadnienia są w pozostałych plikach:

- `Rejestr_decyzji`: dlaczego tak i co odrzuciliśmy,
- `Sciagawka_QA`: pytania i odpowiedzi,
- `Propozycja_projektu_HD_ED_v2`: wersja do oddania (gęsta).